

Universidad Internacional de La Rioja (UNIR)
Máster en Inteligencia Artificial
Investigación y Gestión de Proyectos en Inteligencia Artificial

**Sistema de Predicción de Demanda e Inventario con Inteligencia Artificial para
una Distribuidora de Acero: Propuesta de Proyecto Aplicado a Tubos y
Perfiles de Occidente S.A.S.**

Pablo Alberto Duque Marín

Actividad 1 — Elaboración de una propuesta de proyecto de IA con enfoque
empresarial

Abril de 2026

Declaración de Uso de Inteligencia Artificial Generativa

Identificación de la herramienta

Para la elaboración del presente trabajo se utilizó Claude (claude.ai), modelo de inteligencia artificial generativa desarrollado por Anthropic, en su versión Sonnet 4, accedido a través de la interfaz web de claude.ai durante el mes de abril de 2026.

Propósito y alcance del uso

La herramienta de IA se empleó como apoyo en las siguientes tareas específicas y delimitadas:

- Corrección de estilo, coherencia gramatical y fluidez en la redacción académica en español, sin alterar el contenido conceptual ni los argumentos desarrollados por el autor.
- Apoyo en la búsqueda y organización de referencias bibliográficas recientes sobre modelos de series de tiempo, gestión de inventarios con IA y supply chain management, a partir de consultas dirigidas por el autor. Todas las referencias fueron verificadas individualmente en sus fuentes originales antes de ser incluidas en el documento.
- Sugerencias de estructura y orden de presentación para algunas secciones del documento, que fueron evaluadas, modificadas y aprobadas por el autor según su criterio académico.
- Generación de código JavaScript para la maquetación del documento en formato Word (.docx), bajo instrucciones precisas del autor que especificaron el contenido, el formato APA 7 y los requisitos de UNIR.

Aporte personal y producción propia

La totalidad del contenido intelectual, analítico y argumentativo de este trabajo es de autoría propia. De manera específica, son resultado del trabajo personal del autor los siguientes elementos:

- La identificación del problema empresarial y su diagnóstico, basado en el análisis directo de documentos internos reales de la empresa: el archivo PROMEDIO_2025 del ERP UNO, el inventario al corte del 13 de septiembre de 2025, la Orden de Compra OC-3083 a DIACO S.A. y facturas de venta individuales.

- La selección del enfoque metodológico —predicción de demanda con modelos de series de tiempo sobre referencias categoría A— y la justificación de cada decisión de diseño experimental, incluyendo la elección de Prophet frente a LSTM y la definición del horizonte de predicción mensual.
- La formulación de la hipótesis de investigación y la calibración del umbral de WAPE ($\leq 25\%$) como criterio de éxito, con base en la revisión crítica de la literatura y el conocimiento del contexto operativo de la empresa.
- El análisis de riesgos del proyecto, la estrategia de adquisición de datos en tres escenarios, y el diseño del roadmap con hitos explícitos.
- Todas las conclusiones y recomendaciones estratégicas del documento.
- El trabajo de campo previo a este documento, que incluyó entrevistas semiestructuradas al jefe logístico, coordinador de patio, conductores y operarios de carga, y una visita directa a las instalaciones de la empresa en Dosquebradas, Risaralda, en septiembre de 2025.

Declaración de transparencia

Certifico que el uso de la herramienta de inteligencia artificial descrito anteriormente fue en todo momento supervisado y subordinado al criterio académico propio. La IA no fue utilizada para suplantar el razonamiento, el análisis crítico ni la producción intelectual que son el objeto de evaluación de esta actividad. El contenido de este trabajo refleja mi comprensión personal de los temas tratados y mi capacidad para aplicar los conceptos metodológicos de la asignatura a un caso empresarial real.

Pablo Alberto Duque Marín

Máster en Inteligencia Artificial — UNIR

Manizales, Caldas, Colombia — Abril de 2026

Resumen

Las distribuidoras de materiales de construcción operan bajo una tensión permanente entre la velocidad de la demanda de sus clientes y los tiempos de reposición de sus proveedores. Tubos y Perfiles de Occidente S.A.S., empresa distribuidora de acero y materiales metálicos con sede en Manizales, Colombia, gestiona un inventario de más de 900 referencias activas usando un sistema de promedios simples que ignora la estacionalidad de la demanda del sector constructor. Esta propuesta plantea el diseño y validación, en entorno simulado, de un sistema de predicción de demanda basado en modelos de series de tiempo —Prophet y SARIMA— aplicado a las referencias de categoría A identificadas mediante análisis ABC multicriterio. La hipótesis central sostiene que el modelo propuesto logrará un error de predicción $WAPE \leq 25\%$ en horizonte mensual, superando el desempeño estimado del sistema de promedios actual. La metodología emplea validación cruzada temporal (walk-forward validation) sobre el histórico de doce meses disponible en el ERP UNO de la empresa. El plan de implementación se estructura en cuatro fases de dieciséis semanas, con métricas simuladas, análisis de riesgos y criterios explícitos de viabilidad técnica y operativa. Los resultados esperados incluyen reducción de quiebres de stock en referencias críticas y liberación de capital inmovilizado en sobrestock.

Palabras clave: predicción de demanda, series de tiempo, Prophet, SARIMA, análisis ABC, gestión de inventarios, inteligencia artificial, distribución de acero, Colombia

1. Introducción y Definición del Problema

1.1 Presentación de la Empresa y el Sector

Tubos y Perfiles de Occidente S.A.S. es una distribuidora de materiales metálicos y de construcción fundada el 30 de abril de 2015, con sede principal en Manizales, Caldas, y sucursales operativas en Dosquebradas (Risaralda) y Chinchiná (Caldas). Con 56 empleados y clasificada como empresa mediana según el DANE, opera bajo el CIIU 4663 (comercio al por mayor de materiales de construcción y ferretería). Su portafolio activo supera las 900 referencias —tubería cuadrada, rectangular y redonda en acero frío y caliente; perfiles PTS estructurales; perlinas; varillas corrugadas, lisas y grafiladas; láminas galvanizadas, CR y HR; ángulos; platinas; mallas electrosoldadas; cubiertas metálicas y plásticas, entre otros— distribuidas en tres bodegas con un inventario que registró 978.764 unidades al corte del 13 de septiembre de 2025 (ERP UNO, 2025).

El sector de distribución de acero en el Eje Cafetero colombiano es intensivo en capital de trabajo y altamente sensible a los ciclos del sector constructor. Sus clientes principales son constructoras, ferreterías mayoristas y contratistas que exigen despachos casi inmediatos, mientras que los proveedores clave —DIACO S.A., Ternium Colombia— operan con lead times de entre dos y siete días y sin cláusulas contractuales de penalización por incumplimiento, según la Orden de Compra OC-3083 analizada.

1.2 Identificación del Problema Estratégico

El sistema ERP UNO (versión 8.5) que utiliza la empresa calcula un promedio mensual de salidas por referencia y lo emplea como proxy de la demanda futura para sugerir cantidades de reposición. Este enfoque tiene un defecto estructural documentado: el promedio simple aplanar la señal temporal (Hyndman y Koehler, 2006). No distingue si las 566 unidades mensuales promedio de Tubo Cuadrado 1" C.18 (1.00 mm) se distribuyeron uniformemente o si se concentraron en meses de obra activa —marzo a junio y agosto a noviembre en el Eje Cafetero, antes y después de las temporadas de lluvia— que correlacionan con el Índice de Costos de la Construcción Pesada (ICCP) publicado por el DANE.

La evidencia documental es directa. El archivo PROMEDIO_2025 del ERP registra stock cero en referencias de alta rotación como Tubo Cuadrado 1.1/2" C.20

(0.80 mm) en bodega principal, y columnas de "pedido sugerido" negativas —por ejemplo, -74 unidades en Tubo Rectangular 2"×1" C.18 (1.00 mm)— que evidencian sobrestock en algunos meses y desabastecimiento en otros. Estas asimetrías no aparecen en ningún reporte de alerta del sistema actual.

1.3 Impacto Económico, Operativo y Competitivo

El impacto del problema opera en tres dimensiones. En lo económico, la empresa reportó una caída en ingresos netos del 5,56% en 2024 en un mercado en desaceleración; cada quiebre de stock en una referencia categoría A representa ventas perdidas no registradas y potencial pérdida de clientes constructores, cuyos proyectos tienen plazos inflexibles. En lo operativo, el jefe logístico debe reorganizar despachos y extender turnos cuando los proveedores se demoran, generando costos ocultos por horas extra y cargadores externos. En lo competitivo, los distribuidores con sistemas de reposición reactiva quedan expuestos frente a competidores que sí anticipan la demanda estacional y garantizan disponibilidad en temporadas pico.

La oportunidad es concreta: la empresa ya dispone de doce meses de histórico transaccional en el ERP UNO. Lo que no tiene es un modelo que aprenda los patrones temporales de esa demanda. La inteligencia artificial —específicamente los modelos de series de tiempo con descomposición estacional— puede resolver este problema sin reemplazar la infraestructura existente, complementándola con predicciones mensuales accionables.

2. Estado del Arte y Análisis de Tendencias en IA

2.1 Aplicaciones de IA en Distribución de Materiales Industriales

La predicción de demanda en distribución de materiales de construcción y acero ha sido abordada desde enfoques complementarios. Laksono et al. (2024) aplicaron Prophet, SVR, CNN y LSTM a demanda de malla de acero, encontrando que el ensemble RNN-LSTM alcanzó MAPE de 1,20%, mientras Prophet mostró mejor interpretabilidad para gestores no técnicos —argumento clave para la adopción en PyMEs—. Prastuti et al. (2025) demostraron que los modelos estadísticos clásicos siguen siendo competitivos en horizontes mensuales con datos limitados, en un estudio sobre cemento con estacionalidad comparable a los materiales de

construcción metálicos. Feizabadi (2022) documentó que un método híbrido ARIMAX mejora estadísticamente el desempeño del supply chain en un fabricante de acero frente a métodos tradicionales.

2.2 Comparativa de Modelos: SARIMA, Prophet, LSTM y Enfoques Híbridos

La literatura comparativa reciente converge en que ningún modelo domina universalmente: la selección debe responder al volumen de datos disponibles, el horizonte de predicción y la capacidad técnica del equipo. Chaturvedi et al. (2022) evaluaron SARIMA, LSTM y Prophet sobre 108 meses de demanda energética —serie con estacionalidad análoga a materiales de construcción— encontrando que Prophet alcanzó el menor error (MAPE = 3,3%) gracias a su descomposición en tendencia y componentes estacionales múltiples. Feng et al. (2022) confirmaron el ranking LSTM > Prophet > SARIMA para series con cambios estructurales. Catalán-Navarrete et al. (2024) demostraron que SARIMA es quince veces más rápido computacionalmente que Prophet, argumento relevante para una PyME sin infraestructura cloud. Douaioui et al. (2024), en la revisión crítica más comprehensiva disponible —119 artículos de 2018 a 2024— reportan que modelos híbridos SARIMA-LSTM reducen el error en 18% frente a LSTM puro, y XGBoost mejora la precisión entre 8 y 10% al incorporar variables exógenas como indicadores de actividad constructora.

2.3 Análisis ABC con Machine Learning

Kartal et al. (2016) establecieron el referente fundacional al demostrar que SVM mejora la consistencia de la clasificación ABC multicriterio sobre métodos univariados. Kaabi et al. (2023) avanzaron con una propuesta de ABC con inteligencia artificial explicable (XAI), resolviendo el problema de la caja negra: los gestores comprenden qué variables determinan la clasificación de cada referencia. Para demanda intermitente —referencias categoría C en distribución de acero—, Kenaka et al. (2025) demuestran que ensembles con SMOTE y función de pérdida focal reducen el MSE en 47%.

2.4 Ventajas, Riesgos y Vacíos del Estado del Arte

Las ventajas de aplicar IA al problema son claras: Prophet y SARIMA son open source, interpretables y operables sin infraestructura cloud (Catalán-Navarrete et al., 2024); la literatura reporta reducciones de error de 15 a 20% respecto a promedios

simples en contextos industriales (Douaioui et al., 2024); y el análisis ABC automatiza una tarea hoy manual y subjetiva.

Los riesgos documentados son igualmente importantes. Primero, los modelos de series de tiempo requieren históricos de al menos 24 meses para capturar ciclos anuales completos; con 12 meses disponibles, el riesgo de sobreajuste al único ciclo observado es real (Petropoulos et al., 2022). Segundo, la adopción organizacional es frecuentemente el factor limitante, no la precisión del modelo: cuando el equipo logístico no confía en la predicción, la herramienta no se usa (Albayrak Ünal et al., 2023). Tercero, la demanda intermitente de referencias C puede generar errores MAPE no informativas cuando la demanda es cero (Hyndman y Koehler, 2006).

El vacío principal identificado en la literatura es la escasez de estudios en revistas Q1/Q2 específicamente sobre distribución B2B de acero en PyMEs latinoamericanas —las investigaciones disponibles se concentran en producción industrial o retail de gran escala— lo que constituye una contribución original de esta propuesta (Seyedan y Mafakheri, 2020).

3. Estrategia de Investigación Aplicada a IA

3.1 Alcance del Proyecto

Este proyecto propone el diseño y validación —en entorno simulado— de un sistema de predicción de demanda para las referencias de categoría A del inventario de Tubos y Perfiles de Occidente S.A.S., usando modelos de series de tiempo con capacidad de capturar estacionalidad. El alcance está deliberadamente acotado a categoría A porque el principio de Pareto aplicado al valor de consumo anual concentra aproximadamente el 80% del riesgo financiero en el 20% de referencias. Las referencias B y C conservan el sistema de punto de reorden fijo del ERP actual. Esta arquitectura de combinación acotada es la que la literatura recomienda para maximizar el retorno sobre la inversión en IA en entornos con datos históricos limitados (Kenaka et al., 2025).

3.2 Hipótesis de Investigación

La hipótesis central de este proyecto es la siguiente: un modelo de series de tiempo —Prophet o SARIMA— entrenado sobre el historial de salidas de las

referencias de categoría A, identificadas mediante análisis ABC multicriterio sobre el inventario ERP UNO, logrará un error de predicción $WAPE \leq 25\%$ en horizonte mensual, superando el desempeño estimado del sistema de promedios simples actual, cuyo error en distribuidoras de materiales industriales con demanda estacional ronda el 35% según la literatura (Douaioui et al., 2024).

Esta hipótesis es falsable, cuantitativa y con criterio de éxito explícito. El umbral del 25% WAPE está calibrado con la literatura: valores entre 15% y 25% son considerados útiles para Fase 1 en industrias con demanda variable y proyectos externos como determinantes (Fildes et al., 2022).

3.3 Objetivos del Proyecto

Objetivo general.

Diseñar y validar en condiciones simuladas un sistema de predicción de demanda basado en modelos de series de tiempo, aplicado a las referencias de categoría A del inventario de Tubos y Perfiles de Occidente S.A.S., con el propósito de reducir los quiebres de stock y el inventario ocioso en las referencias de mayor impacto financiero.

Objetivos específicos.

- Clasificar las referencias mediante análisis ABC multicriterio —valor de consumo anual, variabilidad de demanda y costo de oportunidad de quiebre— para identificar las referencias categoría A como foco del modelo predictivo.
- Construir series de tiempo mensuales por referencia A a partir del histórico disponible en el ERP UNO (septiembre 2024 – septiembre 2025).
- Entrenar y comparar modelos Prophet y SARIMA usando walk-forward validation con los últimos tres meses como conjunto de prueba.
- Evaluar el desempeño con WAPE, MAE y RMSE, declarando el modelo viable si $WAPE \leq 25\%$ en Fase 1.
- Proponer un protocolo de integración del modelo con el ERP UNO sin reemplazar la infraestructura existente.

3.4 Metodología General

La metodología sigue un diseño cuantitativo aplicado estructurado en cuatro etapas. La Etapa 1 es la preparación de datos: extracción y limpieza del histórico ERP UNO, construcción de series temporales por referencia en unidades vendidas por mes, y ejecución del análisis ABC multicriterio. La Etapa 2 es el modelado: para cada referencia A se estima un modelo Prophet —que descompone la serie en tendencia, estacionalidad anual y estacionalidad mensual sin requerir estacionariedad— y un modelo SARIMA siguiendo el procedimiento Box-Jenkins (identificación ACF/PACF, estimación por máxima verosimilitud, diagnóstico de residuales). La Etapa 3 es la evaluación mediante walk-forward validation con ventanas de nueve meses de entrenamiento y predicción al mes siguiente, iterando hasta cubrir los tres meses de prueba. La Etapa 4 es la simulación de impacto: con las predicciones del mejor modelo se recalcula el punto de reorden por referencia A y se estima el capital inmovilizado potencial frente al inventario actual.

3.5 Fuentes de Datos y Estrategia de Adquisición

La disponibilidad de datos para este proyecto se estructura en tres escenarios que corresponden a etapas distintas del ciclo de vida del proyecto. Esta estrategia escalonada responde a una realidad frecuente en investigación aplicada con PyMEs: los datos existen pero no siempre están organizados en el formato que el modelo requiere, y su obtención formal demanda tiempo y negociación institucional (Seyedan y Mafakheri, 2020).

Escenario A — Datos disponibles actualmente.

Constituyen la base para el diseño y validación simulada en Fase 1: (a) el archivo PROMEDIO_2025 del ERP UNO con balance de inventario septiembre 2024 – septiembre 2025 —saldo anterior, entradas, salidas, stock actual y promedio mensual por referencia—; (b) el inventario al 13 de septiembre de 2025 desagregado por referencia en las tres bodegas; (c) la Orden de Compra OC-3083 a DIACO S.A. con cantidades, precios y condiciones de pago a 30 días, que permite estimar el lead time del proveedor principal; y (d) facturas de venta individuales con fecha, referencia, cantidad y cliente. Estos datos son suficientes para ejecutar el análisis ABC, construir las series temporales mensuales y realizar la validación walk-forward de la Fase 1.

Escenario B — Datos solicitables a corto plazo (semana 1–2).

El ERP UNO conserva el histórico transaccional completo desde 2015. Dado el acceso directo a la organización, es factible solicitar formalmente la exportación de salidas por referencia para el período enero 2023 – septiembre 2025, lo que aportaría entre 24 y 33 meses de datos mensuales —el mínimo recomendado para que Prophet capture al menos dos ciclos anuales completos y SARIMA estime parámetros estacionales con suficiente confianza (Petropoulos et al., 2022)—. Esta solicitud es el primer hito del proyecto (H1, semana 1) y no requiere inversión adicional: el ERP ya dispone de la funcionalidad de exportación de balances históricos, como evidencia el archivo PROMEDIO_2025 disponible. Con este histórico extendido, el Escenario B se convierte en la base de entrenamiento de Fase 1, desplazando al Escenario A a un rol de validación inicial.

Escenario C — Datos ideales para Fase 2.

Para una implementación en producción con mayor precisión, el escenario óptimo incluiría: salidas semanales por referencia en lugar de agregados mensuales; el ICCP-DANE como regresor externo en Prophet para capturar los ciclos del sector constructor; el calendario de lluvias del IDEAM para el Eje Cafetero, que correlaciona inversamente con la actividad constructora regional; y registros de pedidos fallidos por quiebre de stock para corregir el sesgo de demanda censurada —el ERP actual solo registra lo que se vendió, no lo que se intentó vender sin disponibilidad de inventario —.

3.6 Análisis de Riesgos del Proyecto

Tabla 1

Análisis de riesgos del proyecto de predicción de demanda

Riesgo	Probabilidad	Impacto	Mitigación
Datos históricos insuficientes (12 meses < 24 meses óptimos)	Alta	Alto	Comenzar con referencias de mayor volumen; incorporar variables exógenas (ICCP-DANE) para reforzar el modelo
Resistencia del equipo logístico a confiar en predicciones automatizadas	Alta	Medio	Usar Prophet por su interpretabilidad visual; presentar resultados en unidades físicas, no en métricas estadísticas abstractas

Riesgo	Probabilidad	Impacto	Mitigación
Sobreajuste al único ciclo anual disponible	Media	Alto	Validación walk-forward estricta; comparar siempre contra baseline Naïve estacional
Cambios estructurales en el mercado (caída del sector constructor en Colombia)	Media	Alto	Reentrenar el modelo trimestralmente con datos frescos; incluir indicadores líderes del sector
Rotación de personal técnico que mantiene el modelo	Media	Medio	Documentar el pipeline completo; transferencia de conocimiento al equipo interno en Fase 2

Nota. Elaboración propia con base en Albayrak Ünal et al. (2023) y Petropoulos et al. (2022).

4. Plan de Implementación, Validación y Evaluación de Resultados

4.1 Roadmap por Fases e Hitos

Tabla 2

Roadmap del proyecto: fases, hitos y entregables

Fase	Semanas	Hitos clave	Entregable
1. Diagnóstico y datos	1–3	H1 (S2): ABC ejecutado y top-20% referencias A identificadas · H2 (S3): Dataset limpio validado por el jefe logístico	Informe ABC + dataset estructurado por referencia
2. Modelado y validación	4–8	H3 (S5): Modelos Prophet y SARIMA entrenados · H4 (S7): Walk-forward validation completa · H5 (S8): Modelo ganador seleccionado con WAPE reportado	Modelos entrenados + reporte de métricas (WAPE, MAE, RMSE)
3. Simulación de impacto	9–12	H6 (S10): Puntos de reorden recalculados · H7 (S12): Reporte financiero simulado con estimación de capital liberado y reducción de quiebres	Reporte de impacto financiero simulado (fill rate, inventario promedio)
4. Integración y escalamiento	13–16	H8 (S14): Protocolo de integración ERP documentado · H9 (S16): Presentación a gerencia + hoja de ruta Fase 2 aprobada	Manual de integración + hoja de ruta para cobertura categorías A+B

Nota. Elaboración propia. S = semana del proyecto.

4.2 Métricas de Evaluación y Criterios de Éxito

Tabla 3

Indicadores de éxito con línea base, metas y fórmula de cálculo

Indicador	Línea base	Meta Fase 1	Meta Fase 2	Fórmula
WAPE — Error ponderado por volumen	~35% (promedio simple)	$\leq 25\%$	$\leq 20\%$	$\frac{\sum \text{real} - \text{pred} }{\sum \text{real}} \times 100$
MAE — Error absoluto medio (unidades)	Sin medir	< 50 und/mes	< 30 und/mes	$\frac{\sum \text{real} - \text{pred} }{n}$
Fill rate simulado (% pedidos sin quiebre)	Sin registro	$\geq 85\%$	$\geq 92\%$	Pedidos cubiertos / total pedidos
Reducción capital inmovilizado en sobrestock	Sin cuantificar	Estimación simulada	$\geq 15\%$ real	$(\text{Stock actual} - \text{Stock óptimo}) \times \text{Precio unitario}$

Nota. WAPE: Weighted Average Percentage Error. MAE: Mean Absolute Error. Umbrales calibrados con base en Douaioui et al. (2024) y Fildes et al. (2022).

4.3 Validación de la Solución

La validación opera en entorno estrictamente simulado. El procedimiento central es el walk-forward validation: se entrena el modelo con los primeros nueve meses del histórico y se predice el mes diez; luego se reentraña incluyendo el mes diez y se predice el mes once; así hasta cubrir tres meses de prueba. Este procedimiento respeta la dirección causal del tiempo —nunca se usa información futura para predecir el pasado— y produce una estimación conservadora del error real en producción (Petropoulos et al., 2022). Adicionalmente, todos los modelos se comparan contra un baseline Naïve estacional —que predice la demanda del mismo mes del año anterior— para verificar que la IA agrega valor real y no solo ruido.

4.4 Viabilidad Técnica y Operativa

El proyecto es técnicamente viable con recursos disponibles en una PyME. Prophet (Meta AI, licencia MIT) y SARIMA (librería statsmodels de Python) operan en un computador de escritorio estándar sobre los datos de las referencias categoría A. El ERP UNO exporta el balance de inventario en formato texto estructurado, como evidencia el archivo PROMEDIO_2025 disponible. No se requiere infraestructura cloud en Fase 1.

En lo operativo, la viabilidad depende de dos condiciones que la empresa ya cumple parcialmente: disponer de un responsable técnico —un científico de datos externo en Fase 1, con transferencia de conocimiento en Fase 2— y mantener la actualización mensual del histórico de ventas, que el ERP realiza de manera rutinaria. El mayor riesgo operativo, como señala la Tabla 1, no es tecnológico sino organizacional: la resistencia del equipo logístico a confiar en predicciones automatizadas. La estrategia de mitigación es usar Prophet por su descomposición visual interpretable (Kaabi et al., 2023) y presentar los resultados en unidades físicas mensuales, no en estadísticas abstractas.

5. Conclusiones y Recomendaciones Estratégicas

Esta propuesta parte de evidencia documental concreta —el PROMEDIO_2025 muestra stocks en cero y pedidos sugeridos negativos— y llega a una solución metodológicamente coherente y viable para una PyME de 56 empleados. La elección de Prophet como modelo principal frente a LSTM responde a una consideración que la academia suele subestimar: un modelo que el equipo logístico no puede interpretar no se usa, por más preciso que sea. Prophet produce descomposiciones visuales que el jefe logístico puede entender sin formación estadística, y eso determina la adopción real en el piso de la bodega.

El análisis ABC como filtro previo no es un atajo: es la condición que hace sostenible el proyecto en una empresa sin equipo de datos interno. Concentrar el modelado en el 20% de referencias que concentra el 80% del valor garantiza impacto financiero visible desde las primeras semanas, que es el argumento que la gerencia necesita para aprobar una Fase 2.

Dos recomendaciones estratégicas antes de implementar. Primera: solicitar en la semana 1 la exportación del histórico extendido del ERP UNO (2023–2025) —ya identificada como Escenario B— pues es la acción de mayor retorno sin costo adicional. Segunda: incorporar el ICCP-DANE como regresor externo en Prophet desde el inicio de la Fase 1; este índice captura los ciclos del sector constructor que doce meses de datos internos no alcanzan a reflejar por sí solos.

Referencias

- Aguilera Martínez, J. (2023). Pronóstico de demanda utilizando inteligencia artificial [Trabajo de grado, Universidad Icesi]. Repositorio ICESI. https://repository.icesi.edu.co/biblioteca_digital/bitstream/10906/87548/1/TG03014.pdf
- Albayrak Ünal, Ö., Erkeyman, B., & Usanmaz, B. (2023). Applications of artificial intelligence in inventory management: A systematic review of the literature. *Archives of Computational Methods in Engineering*, 30, 2605–2625. <https://doi.org/10.1007/s11831-022-09879-5>
- Catalán-Navarrete, V., Martínez-Gómez, J., Sánchez-Pérez, E. A., Fernández-Vilas, A., & Díaz-Redondo, R. P. (2024). Prediction of footwear demand using Prophet and SARIMA. *Expert Systems with Applications*, 253, 124408. <https://doi.org/10.1016/j.eswa.2024.124408>
- Chaturvedi, S., Rajasekar, E., Natarajan, S., & McCullen, N. (2022). A comparative assessment of SARIMA, LSTM RNN and Fb Prophet models to forecast total and peak monthly energy demand for India. *Energy Policy*, 168, 113097. <https://doi.org/10.1016/j.enpol.2022.113097>
- Douaioui, K., Ouchekh, R., Benmoussa, O., & Mabrouki, C. (2024). Machine learning and deep learning models for demand forecasting in supply chain management: A critical review. *Applied System Innovation*, 7(5), 93. <https://doi.org/10.3390/asi7050093>
- Feizabadi, J. (2022). Machine learning demand forecasting and supply chain performance. *International Journal of Logistics Research and Applications*, 25(2), 119–142. <https://doi.org/10.1080/13675567.2020.1803246>
- Feng, T., Zheng, Z., Xu, J., Liu, M., Li, M., Jia, H., & Yu, X. (2022). The comparative analysis of SARIMA, Facebook Prophet, and LSTM for road traffic injury prediction in Northeast China. *Frontiers in Public Health*, 10, 946563. <https://doi.org/10.3389/fpubh.2022.946563>
- Fildes, R., Ma, S., & Kolassa, S. (2022). Retail forecasting: Research and practice. *International Journal of Forecasting*, 38(4), 1283–1318. <https://doi.org/10.1016/j.ijforecast.2019.06.004>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Kaabi, H., Jabeur, K., & Ladhari, T. (2023). An explainable artificial intelligence approach for multi-criteria ABC item classification. *Journal of Theoretical and Applied Electronic Commerce Research*, 18(2), 848–866. <https://doi.org/10.3390/jtaer18020044>
- Kartal, H., Oztekin, A., Gunasekaran, A., & Cebi, F. (2016). An integrated decision analytic framework of machine learning with multi-criteria decision making for multi-attribute inventory classification. *Computers & Industrial Engineering*, 101, 599–613. <https://doi.org/10.1016/j.cie.2016.06.004>
- Kenaka, S. P., Cakravastia, A., Diawati, L., & Bahagia, S. N. (2025). Enhancing intermittent spare part demand forecasting: A novel ensemble approach with focal loss and SMOTE. *Logistics*, 9(1), 25. <https://doi.org/10.3390/logistics9010025>
- Laksono, D. R., Kartikasari, P., & Tjahjono, B. (2024). An open innovative inventory management based demand forecasting approach for the steel industry. *Journal of Open Innovation: Technology, Market, and Complexity*. <https://doi.org/10.1016/j.joitmc.2024.100392>
- Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., Barrow, D. K., Ben Taieb, S., Bergmeir, C., Bessa, R. J., Bijak, J., Boylan, J. E., Browell, J., Carnevale, C., Castle, J. L., Cirillo, P., Clements, M. P., Cordeiro, C., Cyrino Oliveira, F. L., De Baets, S., Dokumentov, A., ... Ziel, F. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. <https://doi.org/10.1016/j.ijforecast.2021.11.001>
- Prastuti, M., Pujawan, I. N., Widodo, E., & Astuti, W. (2025). Machine learning methods for accurate demand forecasting in the cement industry. En *Lecture Notes on Data Engineering and Communications Technologies*: Vol. 257 (pp. 665–680). Springer. https://doi.org/10.1007/978-981-96-7749-8_43
- Seyedan, M., & Mafakheri, F. (2020). Predictive big data analytics for supply chain demand forecasting: Methods, applications, and research opportunities. *Journal of Big Data*, 7(53). <https://doi.org/10.1186/s40537-020-00329-2>
- Toorajipour, R., Sohrabpour, V., Nazarpour, A., Oghazi, P., & Fischl, M. (2021). Artificial intelligence in supply chain management: A systematic literature review. *Journal of Business Research*, 122, 502–517. <https://doi.org/10.1016/j.jbusres.2020.09.009>
- Tubos y Perfiles de Occidente S.A.S. (2025). Balance de inventario septiembre 2025 [Archivo ERP UNO versión 8.5]. Documento interno.