

Universidad Internacional de La Rioja (UNIR)  
Máster en Inteligencia Artificial  
Investigación y Gestión de Proyectos en Inteligencia Artificial

**Sistema de Predicción de Demanda e Inventario con Inteligencia Artificial para  
una Distribuidora de Acero: Propuesta de Proyecto Aplicado a Tubos y  
Perfiles de Occidente S.A.S.**

Pablo Alberto Duque Marín

Actividad 1 — Elaboración de una propuesta de proyecto de IA con enfoque  
empresarial

Abril 21 de 2026

## **Declaración de Uso de Inteligencia Artificial Generativa**

### **Identificación de la herramienta**

Para la elaboración del presente trabajo se utilizó Claude (claude.ai), modelo de inteligencia artificial generativa desarrollado por Anthropic, en su versión Sonnet 4, accedido a través de la interfaz web de claude.ai durante el mes de abril de 2026.

### **Propósito y alcance del uso**

La herramienta de IA se empleó como apoyo en las siguientes tareas específicas y delimitadas:

- Corrección de estilo, coherencia gramatical y fluidez en la redacción académica en español, sin alterar el contenido conceptual ni los argumentos desarrollados por el autor.
- Apoyo en la búsqueda y organización de referencias bibliográficas recientes sobre modelos de series de tiempo, gestión de inventarios con IA y supply chain management, a partir de consultas dirigidas por el autor. Todas las referencias fueron verificadas individualmente en sus fuentes originales antes de ser incluidas en el documento.
- Sugerencias de estructura y orden de presentación para algunas secciones del documento, que fueron evaluadas, modificadas y aprobadas por el autor según su criterio académico.
- Generación de código JavaScript para la maquetación del documento en formato Word (.docx), bajo instrucciones precisas del autor que especificaron el contenido, el formato APA 7 y los requisitos de UNIR.

### **Aporte personal y producción propia**

La totalidad del contenido intelectual, analítico y argumentativo de este trabajo es de autoría propia. De manera específica, son resultado del trabajo personal del autor los siguientes elementos:

- La identificación del problema empresarial y su diagnóstico, basado en el análisis directo de documentos internos reales de la empresa: el archivo PROMEDIO\_2025 del ERP UNO, el inventario al corte del 13 de septiembre de 2025, la Orden de Compra OC-3083 a DIACO S.A. y facturas de venta individuales.

- La selección del enfoque metodológico —predicción de demanda con modelos de series de tiempo sobre referencias categoría A— y la justificación de cada decisión de diseño experimental, incluyendo la elección de Prophet frente a LSTM y la definición del horizonte de predicción mensual.
- La formulación de la hipótesis de investigación y la calibración del umbral de WAPE ( $\leq 25\%$ ) como criterio de éxito, con base en la revisión crítica de la literatura y el conocimiento del contexto operativo de la empresa.
- El análisis de riesgos del proyecto, la estrategia de adquisición de datos en tres escenarios, y el diseño del roadmap con hitos explícitos.
- Todas las conclusiones y recomendaciones estratégicas del documento.
- El trabajo de campo previo a este documento, que incluyó entrevistas semiestructuradas al jefe logístico, coordinador de patio, conductores y operarios de carga, y una visita directa a las instalaciones de la empresa en Dosquebradas, Risaralda, en septiembre de 2025.

### **Declaración de transparencia**

Certifico que el uso de la herramienta de inteligencia artificial descrito anteriormente fue en todo momento supervisado y subordinado al criterio académico propio. La IA no fue utilizada para suplantar el razonamiento, el análisis crítico ni la producción intelectual que son el objeto de evaluación de esta actividad. El contenido de este trabajo refleja mi comprensión personal de los temas tratados y mi capacidad para aplicar los conceptos metodológicos de la asignatura a un caso empresarial real.

**Pablo Alberto Duque Marín**

Máster en Inteligencia Artificial — UNIR

Manizales, Caldas, Colombia — Abril 21 de 2026

## Resumen

Las distribuidoras de acero operan en una tensión que no siempre se ve en los estados financieros: el cliente necesita el material hoy, el proveedor lo entrega en tres a siete días, y el sistema de inventario (si solo usa promedios simples) no anticipa cuándo esa brecha va a afectar. Tubos y Perfiles de Occidente S.A.S., con sede en Manizales y un portafolio de más de 900 referencias activas, enfrenta exactamente ese problema. Su ERP UNO calcula promedios mensuales de salidas sin distinguir la estacionalidad propia del sector constructor en el Eje Cafetero. El resultado son stocks en cero en referencias críticas y capital inmovilizado en otras que nadie pidió. Esta propuesta plantea el diseño y validación, en entorno simulado, de un sistema de predicción de demanda basado en modelos de series de tiempo (Prophet y SARIMA) aplicado a las referencias de categoría A identificadas mediante análisis ABC multicriterio. La hipótesis central plantea que el modelo logrará un error WAPE  $\leq 25\%$  en horizonte mensual, superando el desempeño estimado del sistema de promedios actual. La metodología emplea walk-forward validation sobre el histórico disponible en el ERP. El plan se estructura en cuatro fases de dieciséis semanas, con métricas simuladas, análisis de riesgos y criterios explícitos de viabilidad. Los resultados esperados apuntan a reducir quiebres de stock en referencias críticas y liberar capital inmovilizado en sobrestock.

*Palabras clave:* predicción de demanda, series de tiempo, Prophet, SARIMA, análisis ABC, gestión de inventarios, inteligencia artificial, distribución de acero, Colombia

## **1. Introducción y Definición del Problema**

### **1.1 Presentación de la Empresa y el Sector**

Tubos y Perfiles de Occidente S.A.S. es una distribuidora de materiales metálicos y de construcción fundada el 30 de abril de 2015, con sede principal en Manizales, Caldas, y sucursales operativas en Dosquebradas (Risaralda) y Chinchiná (Caldas). Con 56 empleados y clasificada como empresa mediana según el DANE, opera bajo el CIIU 4663 (comercio al por mayor de materiales de construcción y ferretería). Su portafolio activo supera las 900 referencias: tubería cuadrada, rectangular y redonda en acero frío y caliente; perfiles PTS estructurales; perlinas; varillas corrugadas, lisas y grafiladas; láminas galvanizadas, CR y HR; ángulos; platinas; mallas electrosoldadas; cubiertas metálicas y plásticas, entre otros. Tres bodegas distribuyen ese inventario, que al corte del 13 de septiembre de 2025 registraba 978.764 unidades (según el sistema ERP UNO versión 8.5 que gestiona la operación).

El sector de distribución de acero en el Eje Cafetero colombiano es intensivo en capital de trabajo y altamente sensible a los ciclos del sector constructor. Los clientes principales son constructoras, ferreterías mayoristas y contratistas que exigen despachos casi inmediatos. Los proveedores clave DIACO S.A., Ternium Colombia operan con lead times de entre dos y siete días, y sin cláusulas contractuales de penalización por incumplimiento: así lo confirma la Orden de Compra OC-3083 analizada en el marco de este proyecto.

### **1.2 Identificación del Problema Estratégico**

El sistema ERP UNO (versión 8.5) calcula un promedio mensual de salidas por referencia y lo usa como proxy de la demanda futura para sugerir cantidades de reposición. El defecto estructural de ese enfoque está documentado: el promedio simple aplanar la señal temporal (Hyndman y Koehler, 2006). No distingue si las 566 unidades mensuales promedio de Tubo Cuadrado 1" C.18 (1.00 mm) se vendieron de manera uniforme o si se concentraron entre marzo y junio (temporada de obra activa antes de las lluvias en el Eje Cafetero) y luego entre agosto y noviembre. Ambos períodos correlacionan con el Índice de Costos de la Construcción Pesada (ICCP) publicado mensualmente por el DANE. El sistema, en cambio, trata enero igual que julio.

La evidencia está en los archivos. El PROMEDIO\_2025 del ERP registra stock cero en referencias de alta rotación (Tubo Cuadrado 1.1/2" C.20 (0.80 mm) en bodega principal y columnas de pedido sugerido negativas: 74 unidades en Tubo Rectangular 2"x1" C.18 (1.00 mm). Eso no es un error del sistema; es el síntoma de un modelo que sobreestima demanda en meses bajos y la subestima en meses pico. Ningún reporte de alerta lo captura.

### **1.3 Impacto Económico, Operativo y Competitivo**

El impacto se mueve en tres planos. En lo económico: la empresa reportó una caída del 5,56% en ingresos netos en 2024, en un mercado de construcción que desacelera; cada quiebre de stock en una referencia categoría A son ventas que se van con el cliente que no esperó. En lo operativo: el jefe logístico reorganiza despachos y extiende turnos cuando el proveedor llega tarde, generando horas extra y uso de cargadores externos, costos que no aparecen en ninguna línea del presupuesto logístico, En lo competitivo: si la empresa anticipa la demanda estacional garantiza disponibilidad en temporada pico.

La oportunidad es concreta. La empresa ya tiene meses de histórico transaccional en el ERP UNO; lo que no tiene es un modelo que aprenda los patrones de ese histórico. La inteligencia artificial, específicamente los modelos de series de tiempo con descomposición estacional pueden complementar la infraestructura existente sin reemplazarla, produciendo predicciones mensuales que el sistema de reposición pueda usar directamente.

## **2. Estado del Arte y Análisis de Tendencias en IA**

### **2.1 Aplicaciones de IA en Distribución de Materiales Industriales**

No es que falte literatura sobre el tema. Sukolkit et al. (2024) aplicaron Prophet, SVR, CNN y LSTM a demanda de malla de acero y encontraron que el ensemble RNN-LSTM alcanzó MAPE de 1,20%; pero Prophet, con un error algo mayor, resultó más interpretable para gestores no técnicos un argumento que importa mucho cuando la adopción depende del jefe logístico, no del científico de datos. Prastuti et al. (2025) demostraron que los modelos estadísticos clásicos siguen siendo competitivos en horizontes mensuales con datos limitados, en un estudio sobre cemento con

estacionalidad comparable a los materiales de construcción metálicos. Feizabadi (2022), en un fabricante de acero, documentó que un método híbrido ARIMAX mejora estadísticamente el desempeño del supply chain frente a métodos tradicionales. El patrón que emerge es consistente: la IA ayuda, pero el modelo óptimo depende del contexto, no del benchmark global.

## **2.2 Comparativa de Modelos: SARIMA, Prophet, LSTM y Enfoques Híbridos**

La literatura comparativa reciente es bastante clara en algo que a veces se pierde en el entusiasmo por el deep learning: ningún modelo domina universalmente. La selección depende del volumen de datos, el horizonte de predicción y la capacidad técnica del equipo que va a mantenerlo. Chaturvedi et al. (2022) evaluaron SARIMA, LSTM y Prophet sobre 108 meses de demanda energética y Prophet alcanzó el menor error (MAPE = 3,3%) gracias a su descomposición en tendencia y componentes estacionales múltiples. Feng et al. (2022) confirmaron el ranking LSTM > Prophet > SARIMA para series con cambios estructurales. Catalán-Navarrete et al. (2024) aportaron un dato que en PyMEs pesa: SARIMA es quince veces más rápido computacionalmente que Prophet, y en una empresa sin infraestructura cloud eso no es menor.

## **2.3 Análisis ABC con Machine Learning**

El análisis ABC clásico tiene una limitación conocida: clasificar por un solo criterio (valor de consumo) puede dejar fuera referencias estratégicas que rotan poco pero son críticas para un proyecto específico. Kartal et al. (2016) resolvieron eso demostrando que SVM mejora la consistencia de la clasificación ABC multicriterio sobre métodos univariados. Kaabi et al. (2023) fueron más lejos aún con una propuesta de ABC con inteligencia artificial explicable (XAI): el gestor ve exactamente qué variables determinaron la clasificación de cada referencia, lo que elimina la resistencia típica ante decisiones que parecen salir de una caja negra. Para la demanda intermitente (las referencias categoría C que en una distribuidora de acero pueden pasar semanas sin movimiento), Kenaka et al. (2025) demostraron que ensembles con SMOTE y función de pérdida focal reducen el MSE en 47%.

## **2.4 Ventajas, Riesgos y Vacíos del Estado del Arte**

Las ventajas de aplicar IA a este problema son reales: Prophet y SARIMA son open source, interpretables y operables sin infraestructura cloud (Catalán-Navarrete

et al., 2024); la literatura reporta reducciones de error de 15 a 20% respecto a promedios simples en contextos industriales (Douaioui et al., 2024); y el análisis ABC automatiza una clasificación que hoy depende del criterio personal del jefe logístico.

Los riesgos también son reales, Primero: los modelos de series de tiempo necesitan al menos 24 meses de histórico para capturar ciclos anuales completos; con 12 meses disponibles, hay riesgo de sobreajuste al único ciclo observado (Petrooulos et al., 2022). Segundo: la adopción organizacional suele ser el factor limitante, no la precisión del modelo; cuando el equipo logístico no confía en la predicción, la herramienta no se usa (Albayrak Ünal et al., 2023). Tercero: la demanda intermitente de referencias C genera errores MAPE no informativos cuando la demanda es cero (Hyndman y Koehler, 2006).

El vacío principal en la literatura es la escasez de estudios en revistas Q1/Q2 sobre distribución B2B de acero en PyMEs latinoamericanas. Las investigaciones existentes se concentran en producción industrial o retail de gran escala. Eso, en lugar de ser una debilidad de esta propuesta, es su contribución más directa al estado del arte regional.

### **3. Estrategia de Investigación Aplicada a IA**

#### **3.1 Alcance del Proyecto**

El alcance está deliberadamente acotado. No propongo modelar las 900 referencias del inventario: propongo diseñar y validar un sistema de predicción para las referencias de categoría A, que son las que concentran aproximadamente el 80% del riesgo financiero según el principio de Pareto aplicado al valor de consumo anual. Las referencias B y C conservan el sistema de punto de reorden fijo del ERP actual. Esta arquitectura de combinación acotada no es una limitación de recursos; es la que la literatura recomienda para maximizar el retorno sobre la inversión en IA cuando los datos históricos son limitados (Kenaka et al., 2025).

#### **3.2 Hipótesis de Investigación**

La hipótesis central es la siguiente: un modelo de series de tiempo —Prophet o SARIMA— entrenado sobre el historial de salidas de las referencias de categoría A, identificadas mediante análisis ABC multicriterio sobre el inventario ERP UNO, logrará



un error de predicción  $WAPE \leq 25\%$  en horizonte mensual. Ese umbral supera el desempeño estimado del sistema de promedios simples actual, cuyo error en distribuidoras de materiales industriales con demanda estacional ronda el 35% según la literatura (Douaioui et al., 2024).

La hipótesis es falsable y tiene criterio de éxito cuantitativo. El umbral del 25% está calibrado: la literatura considera útiles para una Fase 1 los valores entre 15% y 25% en industrias donde la demanda depende de proyectos externos (Fildes et al., 2022). No es un umbral arbitrario, es el que tiene sentido para este contexto.

### 3.3 Objetivos del Proyecto

#### ***Objetivo general.***

Diseñar y validar en condiciones simuladas un sistema de predicción de demanda basado en modelos de series de tiempo, aplicado a las referencias de categoría A del inventario de Tubos y Perfiles de Occidente S.A.S., con el propósito de reducir los quiebres de stock y el inventario ocioso en las referencias de mayor impacto financiero.

#### ***Objetivos específicos.***

- Clasificar las referencias mediante análisis ABC multicriterio, valor de consumo anual, variabilidad de demanda y costo de oportunidad de quiebre para identificar las referencias categoría A como foco del modelo predictivo.
- Construir series de tiempo mensuales por referencia A, a partir del histórico disponible en el ERP UNO (septiembre 2024 – septiembre 2025).
- Entrenar y comparar modelos Prophet y SARIMA usando walk-forward validation con los últimos tres meses como conjunto de prueba.
- Evaluar el desempeño con WAPE, MAE y RMSE, declarando el modelo viable si  $WAPE \leq 25\%$  en Fase 1.
- Proponer un protocolo de integración del modelo con el ERP UNO sin reemplazar la infraestructura existente.

### 3.4 Metodología General

La metodología sigue un diseño cuantitativo aplicado en cuatro etapas. La Etapa 1 es la preparación de datos: extracción y limpieza del histórico ERP UNO,

construcción de series temporales por referencia en unidades vendidas por mes, y ejecución del análisis ABC multicriterio. La Etapa 2 es el modelado: para cada referencia A se estima un modelo Prophet, que descompone la serie en tendencia, estacionalidad anual y estacionalidad mensual sin requerir estacionariedad y un modelo SARIMA siguiendo el procedimiento Box-Jenkins, identificación por ACF/PACF, estimación por máxima verosimilitud, diagnóstico de residuales. La Etapa 3 es la evaluación mediante walk-forward validation: ventanas de nueve meses de entrenamiento, predicción al mes siguiente, iteración hasta cubrir tres meses de prueba. La Etapa 4 es la simulación de impacto: con las predicciones del mejor modelo se recalcula el punto de reorden por referencia A y se estima el capital inmovilizado potencial frente al inventario actual.

### **3.5 Fuentes de Datos y Estrategia de Adquisición**

La disponibilidad de datos para este proyecto se estructura en tres escenarios que corresponden a etapas distintas del ciclo de vida. Esta estrategia escalonada responde a una realidad frecuente en investigación aplicada con PyMEs: los datos existen, pero no siempre están organizados como el modelo los necesita, y su obtención formal requiere tiempo y coordinación interna (Seyedan y Mafakheri, 2020).

#### ***Escenario A — Datos disponibles actualmente.***

Constituyen la base para el diseño y validación simulada en Fase 1: (a) el archivo PROMEDIO\_2025 del ERP UNO con balance de inventario septiembre 2024 – septiembre 2025 —saldo anterior, entradas, salidas, stock actual y promedio mensual por referencia—; (b) el inventario al 13 de septiembre de 2025 desagregado por referencia en las tres bodegas; (c) la Orden de Compra OC-3083 a DIACO S.A. con cantidades, precios y condiciones de pago a 30 días, que permite estimar el lead time del proveedor principal; y (d) facturas de venta individuales con fecha, referencia, cantidad y cliente. Estos datos son suficientes para ejecutar el análisis ABC, construir las series temporales mensuales y realizar la validación walk-forward de la Fase 1.

#### ***Escenario B — Datos solicitables a corto plazo (semana 1–2).***

El ERP UNO conserva el histórico transaccional completo desde 2015. Dado el acceso directo a la organización, es factible solicitar formalmente la exportación de salidas por referencia para el período enero 2023 – septiembre 2025, lo que aportaría entre 24 y 33 meses de datos mensuales —el mínimo recomendado para que Prophet

capture al menos dos ciclos anuales completos y SARIMA estime parámetros estacionales con suficiente confianza (Petropoulos et al., 2022)—. Esta solicitud es el primer hito del proyecto (H1, semana 1) y no requiere inversión adicional: el ERP ya dispone de la funcionalidad de exportación de balances históricos, como evidencia el archivo PROMEDIO\_2025 disponible. Con este histórico extendido, el Escenario B se convierte en la base de entrenamiento de Fase 1, desplazando al Escenario A a un rol de validación inicial.

### ***Escenario C — Datos ideales para Fase 2.***

Para una implementación en producción con mayor precisión, el escenario óptimo incluiría: salidas semanales por referencia en lugar de agregados mensuales; el ICCP-DANE como regresor externo en Prophet para capturar los ciclos del sector constructor; el calendario de lluvias del IDEAM para el Eje Cafetero, que correlaciona inversamente con la actividad constructora regional; y registros de pedidos fallidos por quiebre de stock para corregir el sesgo de demanda censurada —el ERP actual solo registra lo que se vendió, no lo que se intentó vender sin disponibilidad de inventario—.

## **3.6 Análisis de Riesgos del Proyecto**

**Tabla 1**

*Análisis de riesgos del proyecto de predicción de demanda*

| <b>Riesgo</b>                                                                  | <b>Probabilidad</b> | <b>Impacto</b> | <b>Mitigación</b>                                                                                                                                          |
|--------------------------------------------------------------------------------|---------------------|----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Datos históricos insuficientes (12 meses < 24 meses óptimos)                   | Alta                | Alto           | Comenzar con referencias de mayor volumen; incorporar variables exógenas (ICCP-DANE) para reforzar el modelo – Solicitar mas datos a las áreas encargadas. |
| Resistencia del equipo logístico a confiar en predicciones automatizadas       | Alta                | Medio          | Usar Prophet por su interpretabilidad visual; presentar resultados en unidades físicas, no en métricas estadísticas abstractas                             |
| Sobreajuste al único ciclo anual disponible                                    | Media               | Alto           | Validación walk-forward estricta; comparar siempre contra baseline Naïve estacional                                                                        |
| Cambios estructurales en el mercado (caída del sector constructor en Colombia) | Media               | Alto           | Reentrenar el modelo trimestralmente con datos frescos; incluir indicadores líderes del sector                                                             |

| Riesgo                                              | Probabilidad | Impacto | Mitigación                                                                                 |
|-----------------------------------------------------|--------------|---------|--------------------------------------------------------------------------------------------|
| Rotación de personal técnico que mantiene el modelo | Media        | Medio   | Documentar el pipeline completo; transferencia de conocimiento al equipo interno en Fase 2 |

*Nota.* Elaboración propia con base en Albayrak Ünal et al. (2023) y Petropoulos et al. (2022).

## 4. Plan de Implementación, Validación y Evaluación de Resultados

### 4.1 Roadmap por Fases e Hitos

**Tabla 2**

*Roadmap del proyecto: fases, hitos y entregables*

| Fase                                 | Semanas | Hitos clave                                                                                                                                        | Entregable                                                              |
|--------------------------------------|---------|----------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------|
| <b>1. Diagnóstico y datos</b>        | 1–3     | H1 (S2): ABC ejecutado y top-20% referencias A identificadas · H2 (S3): Dataset limpio validado por el jefe logístico                              | Informe ABC + dataset estructurado por referencia                       |
| <b>2. Modelado y validación</b>      | 4–8     | H3 (S5): Modelos Prophet y SARIMA entrenados · H4 (S7): Walk-forward validation completa · H5 (S8): Modelo ganador seleccionado con WAPE reportado | Modelos entrenados + reporte de métricas (WAPE, MAE, RMSE)              |
| <b>3. Simulación de impacto</b>      | 9–12    | H6 (S10): Puntos de reorden recalculados · H7 (S12): Reporte financiero simulado con estimación de capital liberado y reducción de quiebres        | Reporte de impacto financiero simulado (fill rate, inventario promedio) |
| <b>4. Integración y escalamiento</b> | 13–16   | H8 (S14): Protocolo de integración ERP documentado · H9 (S16): Presentación a gerencia + hoja de ruta Fase 2 aprobada                              | Manual de integración + hoja de ruta para cobertura categorías A+B      |

*Nota.* Elaboración propia. S = semana del proyecto.

### 4.2 Métricas de Evaluación y Criterios de Éxito

**Tabla 3***Indicadores de éxito con línea base, metas y fórmula de cálculo*

| Indicador                                           | Línea base             | Meta Fase 1         | Meta Fase 2      | Fórmula                                                                     |
|-----------------------------------------------------|------------------------|---------------------|------------------|-----------------------------------------------------------------------------|
| <b>WAPE — Error ponderado por volumen</b>           | ~35% (promedio simple) | $\leq 25\%$         | $\leq 20\%$      | $\frac{\sum  real - pred }{\sum real} \times 100$                           |
| <b>MAE — Error absoluto medio (unidades)</b>        | Sin medir              | $< 50$ und/mes      | $< 30$ und/mes   | $\sum  real - pred  / n$                                                    |
| <b>Fill rate simulado (% pedidos sin quiebre)</b>   | Sin registro           | $\geq 85\%$         | $\geq 92\%$      | Pedidos cubiertos / total pedidos                                           |
| <b>Reducción capital inmovilizado en sobrestock</b> | Sin cuantificar        | Estimación simulada | $\geq 15\%$ real | $(\text{Stock actual} - \text{Stock óptimo}) \times \text{Precio unitario}$ |

*Nota.* WAPE: Weighted Average Percentage Error. MAE: Mean Absolute Error. Umbrales calibrados con base en Douaioui et al. (2024) y Fildes et al. (2022).

### 4.3 Validación de la Solución

La validación opera en entorno estrictamente simulado. El procedimiento es el walk-forward validation: se entrena el modelo con los primeros nueve meses del histórico y se predice el mes diez; se reentraña con los primeros diez meses y se predice el mes once; así hasta cubrir tres meses de prueba. Este procedimiento respeta la dirección causal del tiempo (nunca se usa información futura para predecir el pasado) y produce una estimación conservadora del error real en producción (Petropoulos et al., 2022). Todos los modelos se comparan además contra un baseline Naïve estacional (que predice la demanda del mismo mes del año anterior) para verificar que la IA agrega valor real y no solo ruido.

### 4.4 Viabilidad Técnica y Operativa

Técnicamente, el proyecto es viable con los recursos de una PyME. Prophet (Meta AI, licencia MIT) y SARIMA (librería statsmodels de Python) corren en un computador de escritorio estándar. El ERP UNO ya exporta balances en formato texto estructurado, como lo demuestra el archivo PROMEDIO\_2025. No se necesita infraestructura cloud en Fase 1.

En lo operativo, la viabilidad depende de dos condiciones que la empresa ya cumple parcialmente: tener un responsable técnico (un científico de datos externo en Fase 1, con transferencia al equipo interno en Fase 2) y mantener la actualización mensual del histórico de ventas, que el ERP realiza de manera rutinaria. El mayor

riesgo, como señala la Tabla 1, no es tecnológico sino organizacional: la resistencia del equipo logístico a confiar en predicciones automatizadas. La estrategia de mitigación es usar Prophet por su descomposición visual (Kaabi et al., 2023) y presentar los resultados en unidades físicas mensuales, no en métricas estadísticas abstractas.

## **5. Conclusiones y Recomendaciones Estratégicas**

Esta propuesta parte de evidencia concreta (el PROMEDIO\_2025 muestra stocks en cero y pedidos sugeridos negativos) y llega a una solución viable para una PyME de 56 personas en Manizales. Propongo Prophet como modelo principal no porque sea el más preciso según la literatura, sino porque es el que el jefe logístico puede entender sin formación estadística. Un modelo que el equipo no interpreta no se usa..

El análisis ABC como filtro previo es la condición que hace sostenible el proyecto en una empresa sin equipo de datos. Concentrar el modelado en el 20% de referencias que representa el 80% del valor de consumo garantiza que el impacto sea visible desde las primeras semanas. Eso es lo que la gerencia necesita ver para aprobar una Fase 2.

Dos recomendaciones antes de arrancar. Primera: solicitar en la semana 1 la exportación del histórico extendido del ERP, ya identificada como Escenario B; es la acción de mayor retorno sin costo adicional. Segunda: incorporar el ICCP-DANE como regresor externo en Prophet desde el inicio de la Fase 1.

## Referencias

- Aguilera Martínez, J. (2023). Pronóstico de demanda utilizando inteligencia artificial [Trabajo de grado, Universidad Icesi]. Repositorio ICESI. [https://repository.icesi.edu.co/biblioteca\\_digital/bitstream/10906/87548/1/TG03014.pdf](https://repository.icesi.edu.co/biblioteca_digital/bitstream/10906/87548/1/TG03014.pdf)
- Albayrak Ünal, Ö., Erkeyman, B., & Usanmaz, B. (2023). Applications of artificial intelligence in inventory management: A systematic review of the literature. *Archives of Computational Methods in Engineering*, 30, 2605–2625. <https://doi.org/10.1007/s11831-022-09879-5>
- Catalán-Navarrete, V., Martínez-Gómez, J., Sánchez-Pérez, E. A., Fernández-Vilas, A., & Díaz-Redondo, R. P. (2024). Prediction of footwear demand using Prophet and SARIMA. *Expert Systems with Applications*, 253, 124408. <https://doi.org/10.1016/j.eswa.2024.124408>
- Chaturvedi, S., Rajasekar, E., Natarajan, S., & McCullen, N. (2022). A comparative assessment of SARIMA, LSTM RNN and Fb Prophet models to forecast total and peak monthly energy demand for India. *Energy Policy*, 168, 113097. <https://doi.org/10.1016/j.enpol.2022.113097>
- Douaioui, K., Ouchekh, R., Benmoussa, O., & Mabrouki, C. (2024). Machine learning and deep learning models for demand forecasting in supply chain management: A critical review. *Applied System Innovation*, 7(5), 93. <https://doi.org/10.3390/asi7050093>
- Feizabadi, J. (2022). Machine learning demand forecasting and supply chain performance. *International Journal of Logistics Research and Applications*, 25(2), 119–142. <https://doi.org/10.1080/13675567.2020.1803246>
- Feng, T., Zheng, Z., Xu, J., Liu, M., Li, M., Jia, H., & Yu, X. (2022). The comparative analysis of SARIMA, Facebook Prophet, and LSTM for road traffic injury prediction in Northeast China. *Frontiers in Public Health*, 10, 946563. <https://doi.org/10.3389/fpubh.2022.946563>
- Fildes, R., Ma, S., & Kolassa, S. (2022). Retail forecasting: Research and practice. *International Journal of Forecasting*, 38(4), 1283–1318. <https://doi.org/10.1016/j.ijforecast.2019.06.004>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Kaabi, H., Jabeur, K., & Ladhari, T. (2023). An explainable artificial intelligence approach for multi-criteria ABC item classification. *Journal of Theoretical and Applied Electronic Commerce Research*, 18(2), 848–866. <https://doi.org/10.3390/jtaer18020044>
- Kartal, H., Oztekin, A., Gunasekaran, A., & Cebi, F. (2016). An integrated decision analytic framework of machine learning with multi-criteria decision making for multi-attribute inventory classification. *Computers & Industrial Engineering*, 101, 599–613. <https://doi.org/10.1016/j.cie.2016.06.004>
- Kenaka, S. P., Cakravastia, A., Diawati, L., & Bahagia, S. N. (2025). Enhancing intermittent spare part demand forecasting: A novel ensemble approach with focal loss and SMOTE. *Logistics*, 9(1), 25. <https://doi.org/10.3390/logistics9010025>
- Nonthaphat Sukolkit, Sirawadee Arunyanart, Arthit Apichottanakul (2024). An open innovative inventory management based demand forecasting approach for the steel industry. *Journal of Open Innovation: Technology, Market, and Complexity*. <https://doi.org/10.1016/j.joitmc.2024.100407>
- Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., Barrow, D. K., Ben Taieb, S., Bergmeir, C., Bessa, R. J., Bijak, J., Boylan, J. E., Browell, J., Carnevale, C., Castle, J. L., Cirillo, P., Clements, M. P., Cordeiro, C., Cyrino Oliveira, F. L., De Baets, S., Dokumentov, A., ... Ziel, F. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. <https://doi.org/10.1016/j.ijforecast.2021.11.001>
- Prastuti, M., Pujawan, I. N., Widodo, E., & Astuti, W. (2025). Machine learning methods for accurate demand forecasting in the cement industry. En *Lecture Notes on Data Engineering and Communications Technologies*: Vol. 257 (pp. 665–680). Springer. [https://doi.org/10.1007/978-981-96-7749-8\\_43](https://doi.org/10.1007/978-981-96-7749-8_43)
- Seyedan, M., & Mafakheri, F. (2020). Predictive big data analytics for supply chain demand forecasting: Methods, applications, and research opportunities. *Journal of Big Data*, 7(53). <https://doi.org/10.1186/s40537-020-00329-2>
- Toorajipour, R., Sohrabpour, V., Nazarpour, A., Oghazi, P., & Fischl, M. (2021). Artificial intelligence in supply chain management: A systematic literature review. *Journal of Business Research*, 122, 502–517. <https://doi.org/10.1016/j.jbusres.2020.09.009>
- Tubos y Perfiles de Occidente S.A.S. (2025). Balance de inventario septiembre 2025 [Archivo ERP UNO versión 8.5]. Documento interno.