

GUÍA DE ESTUDIO

Tema 6

Estructura de un Proyecto IA y su Despliegue

Investigación y Gestión de Proyectos en IA — UNIR

Contenido

- 1. Análisis del problema e identificación del alcance
- 2. Evaluación de herramientas y plataformas IA
- 3. Gestión y preparación de datos para entrenamiento
- 4. Entrenamiento, validación y evaluación de modelos
- 5. Integración y despliegue en entorno productivo
- 6. Tabla comparativa: métricas de evaluación
- 7. Autoevaluación con respuestas (preguntas tipo examen)

1. Análisis del Problema e Identificación del Alcance

El análisis del problema es el **primer paso** en la definición de una solución IA. Implica entender claramente qué se quiere resolver e identificar los objetivos del negocio. Requiere un doble enfoque: empresarial y técnico.

Perspectiva	Qué contempla
Empresarial	Requisitos de negocio, presupuesto, plazos y recursos disponibles. Reuniones con directivos, empleados
Técnica	Evaluar si el problema es abordable con IA y qué modelos/algoritmos serían más adecuados.

Establecimiento de métricas de éxito

Deben definirse **desde el inicio**, ser cuantificables y alinearse con los objetivos del negocio. Ejemplos: precisión de predicciones, reducción de costes, aumento de eficiencia. Todos los interesados deben tener claro qué se considera un resultado exitoso.

Definición del alcance — arquitectura inicial de la solución

El alcance debe especificar objetivos, entregas, plazos y recursos. También debe identificar los límites del proyecto (qué no se abordará). Requiere una primera aproximación a la arquitectura de la solución:

- **Fuentes de datos:** internas (BDs, transacciones) o externas (datos públicos, proveedores). Considerar siempre aspectos éticos y legales (privacidad, protección de datos personales).
- **Selección inicial de algoritmos y diseño de modelos:** aunque no se tiene todo el detalle, es necesario identificar una primera aproximación por su impacto en recursos y restricciones empresariales.
- **Recursos de computación y almacenamiento:** anticipar necesidades coherentes con los requisitos y presupuesto disponibles.

2. Evaluación de Herramientas y Plataformas IA

Categorías principales

Categoría	Descripción	Ejemplos clave
MLaaS (Machine Learning as a Service)	Entorno cloud para desarrollo, entrenamiento y despliegue de modelos.	Google Cloud AI Platform, Azure ML, Amazon SageMaker
Frameworks y bibliotecas open-source	Permiten personalizar e implementar algoritmos de IA.	TensorFlow (Google), PyTorch (Facebook), scikit-learn, Keras
Herramientas específicas de dominio	Se especializan en casos de uso concretos (NLP, visión por computadora).	OpenAI (visión artificial), spaCy (NLP)
Plataformas RPA con capacidades de IA	Automatizan tareas repetitivas integrando funcionalidades de IA.	Automation Anywhere, Blue Prism

Beneficios y desafíos

Beneficios	Desafíos
Reducción del tiempo de desarrollo (algoritmos y recursos predefinidos).	Coste elevado en soluciones empresariales.
Facilitan la experimentación e iteración rápida.	Dependencia del proveedor (vendor lock-in).
Escalabilidad bajo demanda (especialmente en cloud).	Complejidad técnica: algunas requieren conocimiento especializado.
Comunidad activa y soporte técnico.	Consideraciones éticas y de privacidad, especialmente en cloud con datos sensibles.

Factores clave de evaluación

- **Facilidad de uso:** Interfaz gráfica vs. codificación. Depende del nivel del equipo.
- **Escalabilidad:** Capacidad de adaptarse al crecimiento del proyecto en datos y usuarios.
- **Soporte y comunidad:** Comunidad activa, soporte técnico y compromiso del proveedor con la mejora continua.
- **Integración y compatibilidad:** Compatibilidad con tecnologías existentes. Disponibilidad de APIs.
- **Seguridad y cumplimiento:** Protección de datos (encriptación, control de acceso), cumplimiento normativo (GDPR), auditoría, gestión de incidentes.
- **Coste:** Coste inicial (licencias, hardware) + operativo (suscripciones, almacenamiento) + personal + transición/integración. Evaluar siempre el ROI potencial.

3. Gestión y Preparación de Datos para el Entrenamiento

Principio fundamental

La calidad de los datos de entrada es uno de los factores más importantes en la creación de modelos IA efectivos. Sin datos limpios y relevantes, ningún algoritmo puede compensar la deficiencia.

1. Recopilación	Datos desde sistemas de registro, sensores, BDs, redes sociales, webs, etc. Deben ser relevantes para el problema y estar en formato adecuado para el modelo.
2. Limpieza	Eliminar duplicados, valores incompletos, inconsistentes o irrelevantes. Técnicas: eliminación de valores atípicos (outliers), interpolación de valores faltantes, normalización y estandarización.
3. Selección y transformación de características	Seleccionar las variables relevantes para el problema. Transformarlas a la forma adecuada para el modelo. Técnicas: PCA (reducción de dimensionalidad), selección basada en modelos, selección basada en información, ingeniería de características (crear nuevas variables).
4. División de datos	Separar en: entrenamiento (ajustar parámetros del modelo), validación (ajustar hiperparámetros) y prueba (evaluar rendimiento final). Cada conjunto cumple un propósito específico e independiente.
5. Generación de características	Crear nuevas variables a partir de las existentes para mejorar el rendimiento. Ejemplo: a partir de ventas anuales, generar "% cumplimiento objetivo" o "% incremento respecto al año anterior".
6. Normalización	Escalar los datos para que tengan media 0 y desviación estándar 1. Necesaria porque los modelos ML son sensibles a las diferentes escalas de las variables de entrada.

4. Entrenamiento, Validación y Evaluación de Modelos

El **entrenamiento** es el proceso de ajustar los parámetros del modelo iterando sobre los datos de entrenamiento. La **validación** y la **evaluación** miden la calidad del modelo y su capacidad de **generalizar** a datos nuevos (evitar overfitting).

Etapas del proceso

Preparación de datos	Limpieza y transformación previa al entrenamiento (ver sección 3).
Selección de algoritmos	Elegir los más adecuados según el tipo de datos y problema. Conocer fortalezas y debilidades de cada enfoque.
Selección de hiperparámetros	Los hiperparámetros NO se ajustan durante el entrenamiento; se establecen antes. Ejemplos: número de capas ocultas en una red neuronal, número de árboles en un Random Forest. Su ajuste es iterativo: se prueban combinaciones y se evalúa sobre el conjunto de validación.
Entrenamiento	Iteración repetida sobre datos de entrenamiento, actualizando parámetros del modelo.
Ajuste del modelo	Si el rendimiento no es satisfactorio, se modifican hiperparámetros y se reentrena.
Evaluación	Medir calidad de predicciones en un conjunto de datos independiente no usado durante el entrenamiento. Detecta overfitting.

Concepto crítico: parámetros vs. hiperparámetros

Parámetros vs. Hiperparámetros

Parámetros: se aprenden automáticamente durante el entrenamiento (pesos de una red neuronal, coeficientes de regresión).

Hiperparámetros: se definen ANTES del entrenamiento y controlan el proceso de aprendizaje.

Ejemplos de hiperparámetros: tasa de aprendizaje, número de capas, número de árboles, profundidad máxima.

Ajuste de hiperparámetros (hyperparameter tuning): proceso iterativo de búsqueda de la mejor combinación evaluando en el conjunto de validación.

Métricas de evaluación por tipo de problema

Tipo de problema	Métrica	Fórmula / descripción	Cuándo usarla
Clasificación	Accuracy (precisión)	Predicciones correctas / Total predicciones	Clases balanceadas.
Clasificación	Recall (sensibilidad)	Verdaderos positivos / (VP + Falsos negativos)	Cuando los falsos negativos tienen alto costo (ej. diagnóstico médico).
Clasificación	F1-score	Media armónica de precisión y recall: $2 \cdot (P \cdot R) / (P + R)$	Clases desbalanceadas o cuando importan tanto FP como FN.
Regresión	MAE (Error Medio Absoluto)	Promedio de $ \text{valor real} - \text{valor predicho} $	Interpretable directamente en unidades del problema.
Regresión	MSE (Error Cuadrático Medio)	Promedio de $(\text{valor real} - \text{predicho})^2$	Penaliza más los errores grandes.
Regresión	R2 (Coef. de determinación)	Proporcion de varianza explicada por el modelo ($0 \leq R^2 \leq 1$)	Para interpretar qué tan bien el modelo explica la variabilidad.

Elección de métricas: el contexto importa

No existe una métrica universal. La elección depende del problema y sus consecuencias.

Ejemplo: en predicción de enfermedades, un falso negativo (no detectar una enfermedad) es mucho más grave que en predicción de churn (abandono de clientes). Por eso en diagnóstico médico se prioriza el Recall.

En clases desbalanceadas, la Accuracy puede ser engañosa: un modelo que siempre predice "negativo" en un dataset 95% negativo tiene 95% de accuracy pero es inútil.

5. Integración y Despliegue en Entorno Productivo

Una vez entrenado y evaluado el modelo, debe integrarse en el entorno productivo para que pueda ser utilizado en aplicaciones empresariales reales. Este proceso es crucial para la adopción efectiva de la IA en la organización.

1. Selección del entorno de producción	Elegir el entorno adecuado para cargar, ejecutar y escalar el modelo. Debe cumplir requisitos de seguridad y privacidad de la empresa. Normalmente ya identificado en la fase de análisis inicial.
2. Preparación del modelo	Convertir el modelo al formato adecuado para integrarse con el software del entorno de producción.
3. Creación del servicio de predicción	Exponer el modelo como un servicio que: acepta solicitudes, pasa datos al modelo, devuelve predicciones. Debe gestionar la carga y escalar con el tráfico.
4. Integración en la aplicación empresarial	Crear una API para que la aplicación solicite predicciones. Integrar el servicio en el flujo de trabajo de la aplicación.
5. Pruebas y validación	Pruebas unitarias, de integración y de rendimiento para garantizar que el servicio cumple con los requisitos de calidad de la empresa.
6. Despliegue y monitorización	Puesta en producción + monitorización continua. Se vigila: (a) rendimiento del modelo (accuracy, R2, etc.) y (b) desempeño como software (tiempos de respuesta, carga simultánea). Se establecen umbrales de alerta que notifican al equipo responsable si se superan.
7. Actualización y mantenimiento	A medida que los modelos y necesidades del negocio cambian, puede ser necesario reentrenar el modelo o modificar el servicio. Establecer un plan de mantenimiento y actualización es esencial para garantizar la eficacia a largo plazo.

Monitorización en producción: dos dimensiones

- Rendimiento del modelo: mismas métricas de la fase de evaluación (accuracy, R2, etc.). Detecta degradación del modelo por cambio en los datos o en el comportamiento de los usuarios.
 - Rendimiento como software: tiempos de respuesta, carga simultánea, disponibilidad. El modelo en producción es también un componente de software que debe funcionar de forma fiable.
- Si se superan los umbrales de alerta definidos, se notifica al equipo responsable para tomar acción.

6. Tabla Comparativa: Métricas de Evaluación

Métrica	Tipo	Rango	Interpreta bien	Limitación
Accuracy	Clasificación	0–1 (mayor es mejor)	Clases balanceadas	Engañosa con clases desbalanceadas
Recall	Clasificación	0–1 (mayor es mejor)	Minimizar falsos negativos (diagnósticos)	No penaliza falsos positivos
F1-score	Clasificación	0–1 (mayor es mejor)	Clases desbalanceadas, trade-off FP/FN	No considera verdaderos negativos
MAE	Regresión	0 a +inf (menor es mejor)	Interpretación directa en unidades del problema	No penaliza errores grandes
MSE	Regresión	0 a +inf (menor es mejor)	Penalizar errores grandes (outliers)	Unidades al cuadrado, difícil de interpretar directamente
R2	Regresión	0–1 (mayor es mejor; puede ser negativo)	Proporción de varianza explicada	Puede mejorarse artificialmente al agregar variables irrelevantes

7. Autoevaluación con Respuestas (Tipo Examen)

P1. La fase de análisis del problema dentro de la estructura de un proyecto:

✓ D — Todas las respuestas son válidas. El análisis incorpora tanto el enfoque empresarial (necesidades, objetivos, presupuesto, plazos) como el técnico (viabilidad con IA, selección de algoritmos). Es el primer paso en la definición de la solución.

P2. Las plataformas RPA con capacidades IA:

✓ A — Se consideran posibles herramientas en proyectos IA por su capacidad de automatizar tareas repetitivas. No son plataformas MLaaS ni herramientas orientadas exclusivamente a NLP o análisis de datos.

P3. Las herramientas y plataformas IA open source:

✓ A y B — Reducen costes de desarrollo y tiempo de desarrollo. La opción C es INCORRECTA: las herramientas open source populares SÍ tienen comunidades activas de soporte. La opción D sería correcta solo si C fuera cierta.

P4. Las herramientas y plataformas IA presentan desafíos:

✓ D — Todas las anteriores son correctas: coste elevado en soluciones empresariales, dependencia del proveedor (vendor lock-in) y complejidad técnica.

P5. La selección de herramientas y plataformas IA debe considerar:

✓ A — Escalabilidad para adaptarse al crecimiento del proyecto. Las opciones B, C y D son parciales o incorrectas: el menor coste no es el único criterio; la ausencia de sesgo es relevante pero no es un factor de evaluación de plataformas per se.

P6. La gestión y preparación de datos para entrenamiento:

✓ C — Incorpora recopilación, limpieza, selección/transformación de características y normalización. La opción D es incorrecta: el entrenamiento y validación son fases posteriores y separadas.

P7. La selección de algoritmos y técnicas de aprendizaje automático:

✓ A — Implica conocer fortalezas y debilidades de los diferentes enfoques para seleccionar el mejor para el problema específico. No forma parte del despliegue (B incorrecta) ni incluye directamente la evaluación del rendimiento (C incorrecta).

P8. La selección de métricas de evaluación:

✓ A — Varía según el tipo de problema que se está abordando. No existe una métrica universal (B incorrecta). El "error exponencial mínimo" no existe en el temario (C incorrecta). Las métricas SÍ permiten identificar overfitting (D incorrecta).

P9. La creación de servicios de predicción de un modelo:

✓ D — Es una de las fases propias de la integración y despliegue en entornos de producción. La normalización pertenece a la preparación de datos (A incorrecta). Auditoría/seguridad son factores de la evaluación de plataformas, no del servicio de predicción.

P10. Las plataformas MLaaS proporcionan entorno cloud. Algunas de ellas son:

✓ A — Google Cloud AI Platform es MLaaS. scikit-learn (B) es una biblioteca open source Python. OpenCV (C) es una herramienta específica de visión artificial. Blue Prism (D) es una plataforma RPA.

P11. ¿Qué diferencia hay entre parámetros e hiperparámetros? ¿Por qué importa esta distinción?

✓ Los parámetros se aprenden automáticamente durante el entrenamiento (pesos, coeficientes). Los hiperparámetros se definen ANTES del entrenamiento y controlan el proceso de aprendizaje (número de capas, tasa de aprendizaje, número de árboles). La distinción importa porque los hiperparámetros no pueden aprenderse del mismo modo; requieren un proceso de búsqueda y validación separado (hyperparameter tuning).

P12. ¿Por qué es necesario dividir los datos en tres conjuntos: entrenamiento, validación y prueba?

✓ Entrenamiento: ajusta los parámetros del modelo. Validación: ajusta los hiperparámetros sin contaminar la evaluación final. Prueba: mide el rendimiento final del modelo en datos completamente nuevos. Si se usara el mismo conjunto para entrenamiento y evaluación, el modelo parecería funcionar bien pero podría estar sobreajustado (overfitting) y fallar en producción.

P13. ¿Qué se monitoriza en producción y por qué se necesitan dos dimensiones de monitorización?

✓ 1a dimensión: rendimiento del modelo (accuracy, R2, etc.) para detectar data drift (cuando los datos de producción difieren de los de entrenamiento) o comportamientos no previstos. 2a dimensión: desempeño como software (tiempos de respuesta, disponibilidad, carga). Ambas son necesarias porque un modelo puede ser preciso pero inutilizable si responde en 30 segundos, o puede responder rápido pero estar dando predicciones erróneas por degradación del modelo.