

GUIA DE ESTUDIO

Tema 1: Introduccion al Procesamiento del Lenguaje Natural

Procesamiento del Lenguaje Natural - UNIR

Material de apoyo para evaluacion final

Contenido: Definicion del PLN, aplicaciones principales, historia y evolucion (6 etapas), conocimiento del lenguaje (6 niveles).

1. QUE ES EL PROCESAMIENTO DEL LENGUAJE NATURAL (PLN)

El **Procesamiento del Lenguaje Natural (PLN)** es un campo de la **inteligencia artificial** que tiene como objetivo que las maquinas sean capaces de realizar tareas que involucren el **lenguaje humano**.

Definicion clave: El PLN es un campo **interdisciplinario** que une a informaticos, ingenieros electronicos y de telecomunicaciones con linguistas, sociologos y psicologos.

Diferentes nombres del campo: Procesamiento del lenguaje y del habla, Tecnologia del lenguaje, Linguistica computacional, Reconocimiento y sintesis del habla.

Tareas principales de una maquina en PLN:

- Habilitar la comunicacion maquina-persona
- Mejorar la comunicacion entre humanos
- Procesar texto o habla

Disciplinas y sus aportes:

Disciplina	Aporte al PLN
Ingenieria electronica/telecom	Reconocimiento de la voz, procesamiento de la senal
Informatica	Analisis sintactico e interpretacion semantica de palabras y frases
Linguistica computacional	Morfologia, fonologia y pragmatica
Psicolinguistica	Mecanismos cognitivos para la adquisicion del lenguaje
Sociolinguistica	Como la sociedad influye en el uso de la lengua

2. APLICACIONES DEL PLN

El PLN es una de las areas mas importantes dentro de la IA y la Ciencia de Datos. Principales aplicaciones:

Aplicacion	Descripcion	Ejemplo / Detalle clave
1. Busqueda de respuestas (QA) y autocompletado	Recuperacion de informacion basada en lenguaje natural. Va mas alla de palabras clave.	Requiere: extraccion de informacion, inferencia, sintesis de multiples fuentes.
2. Filtrado de mails	Clasificar correos automaticamente (spam, promociones, importantes).	Usa PLN + aprendizaje automatico sobre remitente, asunto, contenido.
3. Traduccion automatica	Traducir documentos o habla de un idioma a otro.	Mejores resultados con metodos estadisticos basados en frases. Requiere desambiguacion.
4. Agentes conversacionales	Programas que conversan con personas (chatbots). Toman turnos de conversacion.	Deben: analizar lenguaje, mantener estado de conversacion, generar nuevas frases.
5. Analisis de redes sociales	Analizar opinion de usuarios (tweets, posts). Analisis de sentimiento.	PLN + aprendizaje automatico para clasificar sentimiento: positivo, negativo, neutro.
6. Correctores gramaticales	Corregir errores ortograficos y proponer mejoras usando informacion sintactica y semantica.	Tiene en cuenta palabras previas y conocimiento de la lengua.
7. Analisis de encuestas	Procesar texto libre en encuestas cuando el volumen es muy elevado.	Extrae informacion relevante de feedback en texto libre.

8. PLN para casos de uso concretos	Aplicaciones en dominios especificos.	Ej: criba curricular en RR.HH., analisis de historias clinicas en medicina.
------------------------------------	---------------------------------------	---

3. HISTORIA DEL PLN (6 ETAPAS)

Periodo	Etapa	Hitos clave
1940-1950	Paradigmas fundacionales	Dos paradigmas: (1) Automatas: Turing (1936), McCulloch-Pitts (1943), Kleene (1951), Shannon aplica cadenas de Markov, Chomsky define gramaticas de estados finitos (1956), gramaticas libres de contexto. (2) Teoria de la informacion: teorema de codificacion de canal de Shannon, concepto de entropia. Primera maquina de reconocimiento de voz (Bell Labs, 1952, 97-99% precision en digitos).
1957-1970	Paradigma simbolico y estocastico	SIMBOLICO: (a) Teoria del lenguaje formal y sintaxis generativa (Chomsky), analisis top-down y bottom-up, TDAP de Zelig Harris (1958-59). (b) IA: simposio de 1956 (McCarthy, Minsky, Shannon, Rochester), primeros sistemas de comprension basados en patrones y heurísticas. ESTOCASTICO: metodo bayesiano para reconocimiento optico, primeros modelos psicologicos, Brown Corpus (1963, 1 millon de palabras, 500 textos).
1970-1983	Cuatro paradigmas de investigacion	(1) Estocastico: HMM para reconocimiento de voz (IBM, CMU, Bell Labs). (2) Basado en logica: Q-system (Colmerauer), DCG en Prolog, gramatica lexico funcional (LFG, Bresnan y Kaplan). (3) Comprension del lenguaje natural: SHRDLU (Winograd, 1972), Escuela de Yale (Schank), redes semanticas (Quillian), gramatica de casos (Fillmore), sistema LUNAR. (4) Modelado del discurso: estructura del discurso (Grosz), resolucion de referencias (Hobbs), modelo BDI.
1983-1993	Revivir del empirismo y modelos de estados finitos	Modelos de estados finitos aplicados a fonologia, morfologia (Kaplan y Kay) y sintaxis (Church). Retorno del empirismo: modelos probabilisticos (IBM) para reconocimiento de voz, POS tagging, resolucion de ambigüedades. Se desarrollan metricas cuantitativas de evaluacion. Generacion de lenguaje natural.
1994-1999	Union de las diferentes vertientes	Modelos probabilisticos y basados en datos se vuelven estandar. Evaluacion: metodologias de reconocimiento de voz y recuperacion de informacion. Explotacion comercial: reconocimiento de voz, revision ortografica/gramatical. Comunicacion aumentativa. Crecimiento de la web impulsa recuperacion y extraccion de informacion.
2000+	Auge del aprendizaje automatico	Corpus anotados a gran escala: Penn Treebank, Prague Dependency Treebank, PropBank (via LDC). Aprendizaje supervisado: SVM, maxima entropia, regresion logistica multinomial, modelos bayesianos. Desde 2005: aprendizaje no supervisado (traduccion automatica, topic modelling, POS tagging). 2006: Hinton acuña 'deep learning'. Redes recurrentes como alternativa a HMM. Modelos seq2seq para chatbots. Deep learning para etiquetado semantico.

4. CONOCIMIENTO DEL LENGUAJE UTILIZADO EN EL PLN (6 NIVELES)

Idea central: Lo que distingue a las aplicaciones de PLN de otros sistemas de procesamiento de datos es su **uso del conocimiento del lenguaje**. Un programa que necesita saber que es una palabra (ej. contar pronombres) ya es un sistema de PLN.

Nivel	Tipo de conocimiento	Descripción y ejemplo
1	Fonética y fonología	Conocimiento sobre los sonidos lingüísticos. Como se pronuncian las palabras a partir de secuencias de sonidos. Necesario para reconocimiento y síntesis de voz.
2	Morfología	Conocimiento de los componentes significativos de las palabras. Reconocer que 'puertas' es el plural de 'puerta'. Descomponer palabras en partes con significado (raíz + terminación).
3	Sintaxis	Conocimiento de las relaciones estructurales entre palabras. Ordenar y agrupar palabras correctamente. Identificar que una secuencia no tiene sentido aunque las palabras individuales sí.
4	Semántica	Conocimiento del significado. Incluye semántica léxica (significado de cada palabra) y semántica composicional (significado de combinaciones de palabras). Se usa conjuntamente con la sintaxis.
5	Pragmática	Conocimiento de la relación del significado con los objetivos e intenciones. Determinar si una expresión es pregunta, solicitud de acción o declaración. Adaptar formalidad.
6	Discurso	Conocimiento sobre unidades lingüísticas más grandes que un solo enunciado. Interpretar referencias a términos previos en la conversación (pronombres, referencias cruzadas).

5. RESUMEN RÁPIDO PARA EL EXAMEN

PLN = Campo interdisciplinario de la IA para que máquinas realicen tareas con lenguaje humano.

8 aplicaciones: QA/autocompletado, filtrado de mails, traducción automática, agentes conversacionales, análisis de redes sociales, correctores gramaticales, análisis de encuestas, casos de uso concretos.

6 etapas históricas: Fundacionales (1940-50) -> Simbólico/Estocástico (1957-70) -> 4 paradigmas (1970-83) -> Empirismo (1983-93) -> Unión vertientes (1994-99) -> ML/DL (2000+).

6 niveles de conocimiento: Fonética/Fonología -> Morfología -> Sintaxis -> Semántica -> Pragmática -> Discurso.

Hitos clave a recordar: Turing (1936), Shannon (entropía/canal), Chomsky (gramáticas), Brown Corpus (1963), SHRDLU (1972), HMM para voz, Hinton acuña deep learning (2006), modelos seq2seq.

6. CLAVES PARA EL TEST DE AUTOEVALUACIÓN

Pregunta	Respuestas correctas	Nota clave
1. Afirmaciones correctas sobre PLN	B, C	D es incorrecta: dice 'psiquiatras' en vez de 'psicólogos'. A es solo una parte del PLN.
2. Décadas 1940-1950	B, C, D	A es falsa: aparece DESPUES de la Segunda Guerra Mundial, no antes.
3. Paradigma simbólico 1957-1970	A, B	C (bayesiano) y D (corpus) son del paradigma estocástico.

4. Cuatro paradigmas 1970-1983	A, B, C, D	Todas son correctas: HMM, discurso, logica de predicados, redes semanticas.
5. Cambios finales del milenio	A, B, C, D	Todas correctas: estados finitos, probabilisticos, basados en datos, comercializacion.
6. Auge del ML desde 2000	B, C	A es falsa: DL ya se esta explotando. D: no es mas 'eficiente', es que no requiere anotaciones.
7. Aplicaciones con PLN	A, B, C, D	Todas son aplicaciones del PLN.
8. Encadenar palabras: que conocimiento	B, D	Se necesita conocimiento sintactico (relaciones estructurales entre palabras).
9. Interpretar pregunta vs hecho	A, B, D	Pragmatica = relacion del significado con objetivos e intenciones. C (discurso) es diferente.
10. Generar plural para concordancia	A, C, D	Morfologia (componentes significativos) + Sintaxis (concordancia sujeto-verbo).