

GUIA DE ESTUDIO

Tema 2: El texto como dato

Procesamiento del Lenguaje Natural - UNIR

Material de apoyo para evaluacion final

Contenido: Características del texto como dato (principio de composicion, perspectiva distribucional, aspecto secuencial), morfología (morfemas, lexemas), técnicas de normalizacion (tokenizacion, stopwords, mayusculas, stemming, lematizacion), recursos linguisticos, corpus en espanol, herramientas y librerias.

1. CARACTERÍSTICAS DEL TEXTO COMO FUENTE DE DATOS

Característica	Definición	Ejemplo / Limitación
Principio de composición	La representación del significado de un texto se puede obtener desde el significado de los elementos que lo constituyen. Funciona a nivel de palabras, frases y documentos.	Ej: 'He aprobado el examen' = sujeto + predicado. Limitación: no funciona con ambigüedad léxica ('banco') ni frases hechas.
Perspectiva distribucional	El significado de los elementos de un texto se puede obtener de manera no supervisada con base al contexto que suele rodearlos en otros textos.	Ej: 'banco' + 'hipoteca' = entidad financiera; 'banco' + 'peces' = cardumen; 'banco' + 'madera' = asiento. Solo necesita otros textos, sin anotación.
Aspecto secuencial	Es necesario tener en cuenta la secuencialidad bidireccional del texto en la construcción de su significado. El orden de las palabras importa.	Ej: 'info de hipotecas, pero no seguros' vs 'info de seguros, pero no hipotecas'. Mismas palabras, distinto significado.
Ambigüedad sintáctica	Una misma frase puede tener distintas interpretaciones por las relaciones sintácticas entre palabras.	Ej: 'Pedro ve un cuadro de su madre' = el cuadro pertenece a la madre O en el cuadro aparece la madre.

Otros aspectos: Neologismos (palabras nuevas), Ley de Zipf (1949): algunas palabras son mucho más frecuentes que otras (determinantes/preposiciones vs verbos/sustantivos). Ontologías semánticas como **WordNet** recogen relaciones entre palabras de forma supervisada.

2. MORFOLOGÍA

La morfología estudia la forma en que las palabras se descomponen en partes indivisibles que tienen un significado.

Concepto	Definición	Ejemplo
Morfema	Unidad mínima que compone una palabra y que es capaz de expresar un significado.	'mujeres' tiene 2 morfemas: mujer + es
Lexema	Morfema que conforma la raíz o parte invariante de la palabra. Mínima unidad con significado léxico. Proporciona el significado principal.	'mujer' en 'mujeres', 'cant' en 'cantabamos'
Morfema gramatical	Tiene significado gramatical: género, número, persona, modo y tiempo.	'es' en 'mujeres' (plural), 'aba' en 'cantabamos' (indicativo pasado), 'mos' (1ª persona plural)
Morfema cero	Morfema gramatical sin realización fonética pero con significado gramatical.	'mujer' (singular) = lexema 'mujer' + morfema cero de número singular

Ejemplo detallado: 'cantabamos' = **cant** (lexema: acto de producir sonidos melódicos) + **aba** (morfema gramatical: modo indicativo, tiempo pasado) + **mos** (morfema gramatical: 1ª persona del plural).

Nota: El análisis morfológico en español es más complejo que en inglés por la mayor variedad de terminaciones y alteraciones en la raíz.

3. TECNICAS DE NORMALIZACION DE TEXTOS (PIPELINE)

La transformacion de un texto en sus elementos componentes sigue un **flujo (pipeline) de normalizacion** en distintos pasos. El orden puede variar segun el caso de uso.

Paso	Tecnica	Descripcion	Ejemplo / Detalle
1	Tokenizacion	Separar un texto en partes mas pequenas (tokens): palabras o partes de frase.	Separar por espacios en blanco tras eliminar puntuacion. Limitaciones: Dr., o'clock, fechas, nombres propios (Nueva York). Solucion: tokenizacion en 2 niveles (bajo + alto nivel).
2	Eliminacion de stopwords	Quitar tokens muy habituales que aportan poca informacion: articulos, conjunciones, preposiciones.	Se detectan mediante diccionarios especificos por lengua. No siempre se debe aplicar: depende del caso de uso.
3	Tratamiento de mayusculas	Eliminar mayusculas solo cuando sea necesario para que tokens con y sin mayuscula se representen igual.	Ej: 'Dias' y 'dias' -> mismo token. Cuidado: 'Estrella' (nombre propio) vs 'estrella' (objeto). Soluciones: reglas, algoritmos NER.
4	Tratamiento de caracteres especiales	Decidir que hacer con hashtags, @, numeros, signos no alfanumericos.	Ej: en tweets. Puede incluir conversion de numeros a texto. Depende del caso de uso si se eliminan o conservan.
5a	Lematizacion	Simplificar representaciones usando el lema (forma base) de la palabra.	'jugaron' y 'jugado' -> 'jugar'. Se usan diccionarios de equivalencias. Problema: puede perder informacion ('ingenieras' -> 'ingeniero').
5b	Stemming	Obtener el lexema eliminando el resto de morfemas.	'jugaron' -> 'jug'. Algoritmo Snowball (Porter, 2001). Problema: 'jugaron' -> 'jug' pero 'juego' -> 'jueg' (inconsistencia).

Lematizacion vs Stemming: La lematizacion obtiene la forma base de la palabra (ej: 'jugar'), mientras que el stemming obtiene el lexema/raiz cortando morfemas (ej: 'jug'). La lematizacion es mas precisa pero mas costosa. El stemming puede generar inconsistencias. Ninguno de los dos se debe aplicar siempre: depende de si se pierde informacion relevante.

Nota sobre el orden: La tokenizacion siempre es el primer paso. Los demas pueden variar. Ej: 'Principado de Asturias' se detecta como entidad antes de eliminar la stopwords 'de'. Si el texto esta en formato XML, puede no ser necesario aplicar algunas fases.

4. RECURSOS LINGUISTICOS

Recurso	Definicion	Ejemplo
Diccionario	Repertorio de palabras de una lengua con su definicion o explicacion.	Diccionario de la RAE
Lexicon	Diccionario que contiene informacion morfologica: lista de morfemas e informacion basica sobre ellos.	Diccionario morfologico
Tesauro (Thesaurus)	Diccionario con lista de significados de las palabras y relaciones entre ellos: sinonimia, antonimia, hiperonimia/hiponimia, meronimia/holonimia. Estructura jerarquica que modela relaciones is-a y parte-todo.	Tesauro de sinonimos y antonimos
Bases de datos de relaciones lexicas	Generalizacion de tesauros. Contiene lemas anotados con posibles sentidos y las relaciones entre esos sentidos.	WordNet (Fellbaum, 2010)

Corpus linguistico	Coleccion de textos (textuales) o habla (orales) representativos de una lengua para analisis linguistico. Pueden estar etiquetados (informacion sintactica, semantica, pragmatica).	Brown Corpus (1963), WSJ Corpus, Penn Treebank
---------------------------	---	--

5. CORPUS EN ESPAÑOL

Corpus	Institucion	Descripcion
Corpus de sonetos del Siglo de Oro	Biblioteca Virtual Miguel de Cervantes	Coleccion de sonetos del periodo aureo espanol.
IMPACT-es (Corpus diacronico)	Biblioteca Virtual Miguel de Cervantes	86 obras impresas entre 1482-1647. Lexicon con +10,000 lemas. Palabras anotadas con lema, categoria gramatical y forma moderna equivalente.
CREA (Corpus de Referencia del Espanol Actual)	RAE + Asociacion de Academias	Creado desde 1996. Muestra la evolucion y funcionamiento actual del espanol.
CORPES XXI (Corpus del Espanol del Siglo XXI)	RAE + Asociacion de Academias	Complementa al CREA para el espanol contemporaneo.

6. HERRAMIENTAS Y LIBRERIAS PARA PLN

Herramienta	Lenguaje	Caracteristicas clave
NLTK (Natural Language Toolkit)	Python	Open source (Apache 2.0). +50 corpus y recursos lexicos (WordNet). Clasificacion, tokenizacion, stemming, POS tagging, analisis sintactico y semantico. Desarrollado para ingles pero flexible para espanol. Permite integrar etiquetadores externos (ej: Stanford CoreNLP).
spaCy	Python	Open source (MIT). Uso academico e industrial. Flujos de normalizacion integrados. +60 idiomas. Modelos neuronales para NER, modelos preentrenados como BERT.
Gensim (Generate Similar)	Python	Topic modelling, indexado de documentos, busquedas por similitud. Usa tecnicas de vector embeddings.
Stanford CoreNLP	Java (integrable en Python)	Modelos para PLN en espanol. Separa contracciones (del = de + el). Identifica tiempos y modos verbales. Integrable con NLTK via linea de comandos.
LingPipe, Apache OpenNLP, Stanford NLP	Java	Otras librerias para desarrollo de aplicaciones de PLN en Java.
Natural	Node.js	Libreria para PLN en entorno JavaScript.

7. RESUMEN RAPIDO PARA EL EXAMEN

3 perspectivas del texto: Composicion (significado desde componentes), Distribucional (significado desde contexto, no supervisado), Secuencial (orden importa, bidireccional).

Morfema = unidad minima con significado. **Lexema** = raiz/significado lexico. **Morfema gramatical** = genero, numero, persona, modo/tiempo. **Morfema cero** = sin realizacion fonetica.

Pipeline de normalizacion: Tokenizacion -> Stopwords -> Mayusculas -> Caracteres especiales -> Lematizacion o Stemming. (El orden de 2-4 puede variar. Tokenizacion siempre primero.)

Stemming vs Lematizacion: Stemming = raiz (cortar: 'jug'), Lematizacion = forma base (diccionario: 'jugar'). Lematizacion mas precisa pero mas costosa.

5 recursos linguisticos: Diccionario, Lexicon (morfologico), Tesauro (relaciones de significado), Bases de relaciones lexicas (WordNet), Corpus.

Herramientas clave: NLTK (Python, +50 corpus), spaCy (Python, +60 idiomas, NER, BERT), Gensim (embeddings), Stanford CoreNLP (Java, espanol).

8. CLAVES PARA EL TEST DE AUTOEVALUACION

Pregunta	Respuestas correctas	Nota clave
1. Principio de composicion	A, B, C	Todas las primeras 3 son correctas: frase, documento y palabra.
2. Afirmacion correcta	D (Ninguna)	A: no siempre suficiente. B: distribucional NO dice que todas las palabras pesan igual. C: el orden SI importa.
3. Normalizacion de textos	C	La lematizacion PUEDE hacer perder info (ej: 'ingenieras'-'>'ingeniero'). A: tokenizacion es PRIMERA fase. B: no siempre stemming. D: stopwords son palabras HABITUALES, no poco habituales.
4. Stemming de 'saltabamos'	C: 'Salt'	Stemming corta morfemas y deja el lexema/raiz.
5. Lematizacion de 'saltabamos'	A: 'Saltar'	La lematizacion devuelve la forma base (infinitivo del verbo).
6. Minima unidad con significado	C: Morfema	No confundir con lexema (solo la raiz) ni morfema gramatical (solo gramatical).
7. Sobre el lexema	B, C, D	A es falsa: el lexema tiene significado LEXICO, no gramatical.
8. Recursos linguisticos	A, B, D	C es falsa: el tesauro contiene relaciones de SIGNIFICADO, no solo lexico.
9. Sobre un tesauro	A, B, C	La jerarquia is-a hace que todo termine descendiendo del concepto raiz. D no es obligatorio.
10. Sobre NLTK	A, B, C, D	Todas son correctas. NLTK es la mas utilizada en Python, con interfaz a +50 corpus, analisis en espanol e integracion externa.