

Tema 6 — Semántica Léxica

Procesamiento del Lenguaje Natural — UNIR

Guía de estudio para evaluación final · Mayo 2026

1. Conceptos Clave

Concepto	Definición
Semántica léxica	Rama de la semántica que estudia el significado de las palabras y las relaciones de sentido entre ellas.
Lema	Forma canónica de una palabra — la forma que aparece en el diccionario (ej. "banco" para "bancos").
Sentido	Representación de uno de los aspectos del significado de una palabra. Un lema puede tener múltiples sentidos.
Homonimia	Relación entre dos sentidos de la misma forma ortográfica que no tienen ninguna conexión semántica entre sí.
Homógrafo	Palabras que se escriben igual pero tienen significados distintos (banco-asiento vs banco-entidad).
Homófono	Palabras que suenan igual pero se escriben distinto y tienen significados distintos (vello/bello).
Polisemia	Relación entre múltiples sentidos de una misma palabra que están relacionados semánticamente entre sí.
Metonimia	Tipo particular de polisemia — un sentido toma el nombre de otro con el que tiene alguna conexión conceptual.
Tesaurus	

	Diccionario especializado que recoge palabras junto con sus sinónimos, antónimos y relaciones semánticas.
WordNet	Principal base de datos léxica para PLN en inglés. Organiza palabras en synsets con relaciones semánticas.
WSD	Word Sense Disambiguation — tarea de seleccionar el sentido correcto de una palabra dado su contexto.
Signature	Definición de un sentido en el diccionario, usada en el algoritmo de Lesk.
Context	Conjunto de palabras que rodean a la palabra ambigua en la oración.
IDF	Inverse Document Frequency — medida que pondera palabras dando más peso a las menos frecuentes.
LCS	Lowest Common Subsumer — ancestro común más bajo de dos conceptos en la jerarquía del tesoro.
IC	Information Content (cantidad de información) — medida basada en la probabilidad de un concepto en el corpus.

2. Significado de las Palabras

2.1 Lema y sentido

La forma más básica de representar el significado de una palabra es a través de su **lema**. Un lema puede tener múltiples **sentidos** — cada uno se representa añadiendo un superíndice: banco¹, banco², banco³.

2.2 Homonimia vs Polisemia

Distinción clave para el examen

- **Homonimia**

→ misma forma, sentidos SIN relación semántica. Ej: banco¹ (asiento) vs banco² (entidad financiera).

- **Polisemia**

→ misma forma, sentidos CON relación semántica. Ej: banco² (entidad) vs banco³ (oficina de la entidad).

- **Metonimia**

→ tipo específico de polisemia donde un sentido toma el nombre de otro por conexión conceptual. Toda metonimia es polisemia, pero no toda polisemia es metonimia.

2.3 Homógrafos y Homófonos

Tipo	Definición	Ejemplo	Impacto en PLN
Homógrafo	Se escriben igual, significados distintos	banco ¹ / banco ²	Afecta conversión texto→habla
Homófono	Suenan igual, se escriben distinto	vello / bello	Afecta reconocimiento del habla

Para PLN es necesario: (1) definir el sentido de una palabra a través de su relación con los sentidos de otras palabras, y (2) agrupar los sentidos de las palabras. Los diccionarios tradicionales no son suficientes para esto — se necesitan bases de datos de relaciones léxicas como WordNet.

3. Relaciones entre Sentidos de las Palabras

Relación	Definición	Pregunta clave	Ejemplo
Sinonimia			

	Mismo significado o muy parecido — intercambiables en contexto	¿Pueden sustituirse?	empezar / comenzar
Antonimia	Significados opuestos — extremos de una escala o binarios	¿Son opuestos?	abierto / cerrado, largo / corto
Hiponimia	Lo más específico — subclase del otro	¿Es un tipo de...?	perro IS-A animal
Hiperonimia	Lo más general — clase que incluye al otro	¿Es la clase general de...?	animal es hiperónimo de perro
Meronomia	Relación parte-todo	¿Es una parte de...?	rueda es parte de coche
Holonimia	El todo respecto a la parte	¿Es el todo que contiene...?	coche es holónimo de rueda

3.1 Hiponimia en lógica de primer orden

Definición formal de hiponimia

Un sentido A es hipónimo de B si todo lo que es A también es

B :

$$\forall x A(x) \Rightarrow B(x)$$

Ejemplo: $\forall x Perro(x) \Rightarrow Animal(x)$

La hiponimia es una **relación transitiva**: si A es hipónimo de B, y B es hipónimo de C, entonces A es hipónimo de C.

Jerarquía IS-A en ontologías: las relaciones de hiponimia/hiperonimia se representan con la expresión **A IS-A B**, que indica que A es hipónimo de B. Ejemplo: Padre IS-A Hombre, Perro IS-A Mamífero IS-A Animal IS-A Ser vivo.

3.2 Diferencia clave: Hiponimia vs Meronimia

No confundir:

- **Hiponimia** → "es un tipo de" → perro IS-A animal (el perro ES un animal)
- **Meronimia** → "es una parte de" → rueda es parte de coche (la rueda NO ES un coche)

4. Desambiguación del Sentido de las Palabras (WSD)

WSD — Word Sense Disambiguation

Tarea de seleccionar el sentido correcto de una palabra dada su aparición en un contexto particular. El algoritmo recibe la palabra ambigua en su contexto y una lista de posibles sentidos, y devuelve el sentido correcto.

Existen cuatro enfoques principales que se diferencian por el tipo de datos que utilizan:

Enfoque	Datos necesarios	Algoritmo representativo	Ventaja	Desventaja
Supervisado	Corpus grande etiquetado a mano	Clasificador con muestra léxica o corpus completo	Mejores resultados	Alto coste de etiquetado
Basado en conocimiento	Diccionarios o tesauros	Algoritmo de Lesk		

			No requiere etiquetado específico	Definiciones cortas — poco solapamiento
Semisupervisado	Corpus pequeño etiquetado + corpus grande sin etiquetar	Algoritmo de Yarowsky	Poco etiquetado inicial	Calidad depende de heurísticas
No supervisado	Solo corpus sin etiquetar	Algoritmo de Schütze	No necesita ningún recurso humano	No conoce el nombre de los sentidos

4.1 Enfoque supervisado — Extracción de características

El primer paso es siempre extraer características del contexto de la palabra ambigua usando una **ventana** de palabras a su alrededor. Se extraen dos tipos:

Características de colocación

Codifican información posicional — la palabra en sí, su categoría gramatical (POS) y los pares de palabras adyacentes. Para una ventana de 2 palabras a cada lado de la palabra objetivo

w_i :

$$[w_{i-2}, POS_{i-2}, w_{i-1}, POS_{i-1}, w_{i+1}, POS_{i+1}, w_{i+2}, POS_{i+2}, w_{i-2}^i, w_{i-1}^i, w_{i+1}^i, w_{i+2}^i]$$

Ejemplo: desambiguación de "bass"

Oración: "An electric guitar and
bass

player stand off to one side"

Ventana de 2 palabras a cada lado:

$w_i - 2$	$w_i - 1$	bass	$w_i + 1$	$w_i + 2$
guitar	and	bass	player	stand
NN	CC	—	NN	VB

Vector de características de colocación:

[guitar, NN, and, CC, player, NN, stand, VB, and guitar, player
stand]

Características sobre palabras vecinas (bag-of-words)

Representan el contexto como un **vector binario** — indica si cada palabra de un vocabulario predefinido aparece o no en la ventana, sin importar el orden.

Ejemplo: bag-of-words para "bass"

Vocabulario predefinido de las 12 palabras más frecuentes en contextos de "bass":

[fishing, big, sound, player, fly, rod, pound, double, runs,
playing, guitar, band]

En la ventana aparecen "guitar" (posición 11) y "player" (posición 4). Vector resultante:

[0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 1, 0]

Las palabras "guitar" y "player" son señal fuerte de sentido musical.

Estructura del aprendizaje supervisado: cada instancia tiene un vector de características (X) y una etiqueta de sentido (y) asignada manualmente. El vector es evidencia colectiva — la etiqueta es una sola por instancia, no una por elemento del vector.

4.2 Algoritmo de Lesk (basado en conocimiento)

Principio del algoritmo de Lesk

Seleccionar el sentido de la palabra para el cual su definición en el diccionario (*signature*) comparte la mayor cantidad de palabras con el contexto de la palabra ambigua (*context*).

Ejemplo: desambiguación de "bank"

Oración: *"The bank can guarantee deposits will eventually cover future tuition costs because it invests in adjustable-rate mortgage securities"*

- **bank¹**

(entidad financiera): definición contiene "deposits", "mortgage" → **2 palabras en común** con el contexto

- **bank²**

(terreno junto al río): definición contiene "river", "canoe" → **0 palabras en común**

Ganador →

bank¹

✓

Nota: determinantes, preposiciones, conjunciones y pronombres no se tienen en cuenta por no aportar información relevante.

Limitación y solución — Corpus Lesk

El problema de Lesk simplificado es que las definiciones del diccionario son **muy cortas** y pueden no solaparse con el contexto aunque el sentido sea correcto.

La solución es el **Corpus Lesk** — añade todas las palabras del corpus etiquetado para ese sentido a la signature. Además aplica un **peso IDF** a cada palabra coincidente:

$$idf_i = \log \frac{N_{doc}}{nd_i}$$

Donde N_{doc} es el número total de documentos y nd_i es el número de

documentos que contienen la palabra i . Las palabras poco frecuentes reciben mayor peso — son más informativas para identificar el sentido correcto.

4.3 Algoritmo de Yarowsky (semisupervisado)

Parte de un conjunto pequeño de datos etiquetados Λ_0 y un corpus grande sin

etiquetar V_0 . Proceso iterativo:

1. Entrena un clasificador con Λ_0
2. Usa el clasificador para etiquetar V_0
3. Selecciona los ejemplos con **mayor confianza** de clasificación
4. Los mueve de V a Λ — Λ crece, V decrece
5. Repite hasta alcanzar error suficientemente bajo o agotar ejemplos

Usa dos heurísticas para seleccionar el conjunto inicial:

Heurística	Idea
Un sentido por colocación	Ciertas palabras del contexto son señal fuerte de un sentido específico y no tienden a ocurrir con otros sentidos

Un sentido por discurso

Una palabra ambigua que aparece varias veces en un texto tiende a usar el mismo sentido a lo largo de todo ese texto

4.4 Algoritmo de Schütze (no supervisado)

No requiere etiquetas ni diccionarios. Aprende los sentidos directamente desde el corpus usando **clustering**.

Fase 1 — Entrenamiento:

1. Para cada aparición w_i de la palabra, calcula un **vector de contexto** c
2. Agrupa los vectores en clusters usando **agrupamiento aglomerativo** — cada cluster define un sentido
3. Calcula el **centroide** s_j de cada cluster — representa un sentido de la palabra

Fase 2 — Desambiguación de nueva instancia:

1. Calcula el vector de contexto c para la instancia nueva
2. Recupera todos los centroides s_j
3. Asigna la instancia al sentido cuyo centroide está **más cerca**

Limitación: como es no supervisado, los clusters no tienen nombre — solo se sabe que existen sentidos distintos, no cuáles son. Se llama también **inducción del sentido de las palabras**. Es útil para descubrir sentidos nuevos o cuando no existe diccionario para el idioma o dominio.

5. Similitud entre Palabras

Similitud $\neq$ Relación

- **Similares**

→ casi sinónimas, intercambiables en contexto. Ej: coche y bicicleta.

- **Relacionadas**

→ conexión semántica pero no intercambiables. Ej: coche y gasolina.

- Los antónimos están muy relacionados pero no son similares en absoluto.

- Muchos algoritmos llamados "de similitud" miden en realidad relación — por convención se mantiene el nombre.

5.1 Similitud basada en longitud del camino

Los sentidos más similares están más cerca en el grafo del tesoro. La medida de similitud entre

dos sentidos c_1 y c_2 es:

$$path(c_1, c_2) = \frac{1}{pathlen(c_1, c_2)}$$

Donde $pathlen(c_1, c_2)$ es el número de aristas en el camino más corto entre los

dos nodos. A menor distancia → mayor similitud.

Para calcular similitud entre **palabras** — no sentidos — se toma el par de sentidos que maximiza la similitud:

$$wordsim(w_1, w_2) = \max_{c_1 \in senses(w_1), c_2 \in senses(w_2)} path(c_1, c_2)$$

Limitación: asume que cada arista del grafo representa la misma distancia semántica — lo cual no es realista. Un paso en la cima de la jerarquía (entidad → ser vivo) no equivale a un paso en el fondo (perro → lobo).

5.2 Medida de Resnik — basada en cantidad de información

Resuelve la limitación anterior usando **probabilidades del corpus** en lugar de conteo de aristas.

Se define $P(c)$ como la probabilidad de encontrar el concepto c en un corpus:

$$P(c) = \frac{\sum_{w \in words(c)} count(w)}{N}$$

Donde $words(c)$ es el conjunto de palabras descendientes del concepto c y

N es el total de palabras en el corpus presentes en el tesoro.

La **cantidad de información** (IC) de un concepto c es:

$$IC(c) = -\log P(c)$$

Los conceptos más generales tienen alta probabilidad → IC baja. Los más específicos tienen baja probabilidad → IC alta.

La **medida de similitud de Resnik** usa el ancestro común más bajo (LCS):

$$resnik(c_1, c_2) = -\log P(LCS(c_1, c_2))$$

Ejemplo intuitivo

Comparando perro-lobo vs perro-animal en la jerarquía:

- $LCS(\text{perro}, \text{lobo}) =$
Mamífero
→ aparece poco en el corpus → IC alta → similitud alta
- $LCS(\text{perro}, \text{animal}) =$
Animal
→ aparece mucho en el corpus → IC baja → similitud baja

Resultado: perro y lobo son más similares que perro y animal — coherente con la intuición.

6. Resumen Rápido para Repaso

- **Homonimia:** misma forma, sentidos sin relación. **Polisemia:** sentidos con relación. **Metonimia:** caso específico de polisemia por conexión conceptual.
- **Homógrafo:** misma escritura, distinto significado. **Homófono:** mismo sonido, distinta escritura.
- **Sinonimia:** mismo significado. **Antonimia:** significado opuesto. **Hiponimia:** IS-A (más específico). **Hiperonimia:** clase general. **Meronymia:** parte-todo.
- **WSD supervisado:** corpus etiquetado + clasificador. Características de colocación (posicionales) y bag-of-words (binarias). Vector completo → una etiqueta de sentido.
- **Lesk simplificado:** signature vs context — mayor solapamiento gana. **Corpus Lesk:** firma extendida + pesos IDF.
- **Yarowsky:** bootstrapping iterativo — corpus pequeño etiquetado crece con ejemplos de alta confianza. Heurísticas: un sentido por colocación / un sentido por discurso.
- **Schütze:** clustering no supervisado — cada cluster = un sentido. No conoce el nombre del sentido.
- **Similitud ≠ Relación.** Path similarity: $1/pathlen$. Resnik:

$-\log P(LCS)$ — más específico el ancestro común → mayor similitud.

7. Test de Autoevaluación

Preguntas

1.

¿Cuál es la diferencia entre homonimia y polisemia? Da un ejemplo de cada una.

2.

¿Qué relación hay entre metonimia y polisemia? ¿Son lo mismo?

3.

¿Cuál es la diferencia entre homógrafo y homófono? ¿Cuál afecta al reconocimiento del habla?

4.

Explica la diferencia entre hiponimia y meronimia con un ejemplo propio.

5.

¿Qué significa que la hiponimia es transitiva? Da un ejemplo.

6.

En WSD supervisado, ¿qué representa el vector de características y qué representa la etiqueta? ¿Cuántas etiquetas tiene cada instancia?

7.

¿Qué son las características de colocación? ¿En qué se diferencian de las características sobre palabras vecinas?

8.

Explica el funcionamiento del algoritmo de Lesk simplificado y cuál es su principal limitación.

9.

¿Qué resuelve el IDF en el Corpus Lesk? ¿Por qué las palabras frecuentes como "the" reciben poco peso?

10.

¿Por qué el algoritmo de Schütze no puede desambiguar de forma completamente autónoma? ¿Para qué sí es útil?

11.

¿Cuál es la limitación de la medida de similitud basada en longitud del camino y cómo la resuelve Resnik?

12.

¿Qué diferencia hay entre similitud y relación entre palabras? Da un ejemplo de palabras relacionadas pero no similares.

8. Claves del Test de Autoevaluación

1. Homonimia: misma forma ortográfica, sentidos sin ninguna relación semántica (banco-asiento vs banco-entidad). Polisemia: misma forma, sentidos con alguna relación semántica (banco-entidad vs banco-oficina).
2. La metonimia es un tipo específico de polisemia — toda metonimia es polisemia, pero no toda polisemia es metonimia. La polisemia es el concepto general (múltiples sentidos relacionados); la metonimia es el mecanismo concreto por el que un sentido toma el nombre de otro con el que tiene conexión conceptual.
3. Homógrafo: se escriben igual, significados distintos (banco¹/banco²). Homófono: suenan igual, se escriben distinto (vello/bello). La homofonía afecta al reconocimiento automático del habla; la homografía afecta a la conversión de texto a habla.
4. Hiponimia es "es un tipo de" — perro IS-A animal (el perro es un animal). Meronimia es "es una parte de" — rueda es parte de coche (la rueda no es un coche). La diferencia es clase-subclase vs parte-todo.
5. Si A es hipónimo de B y B es hipónimo de C, entonces A es hipónimo de C. Ejemplo: Pastor Alemán IS-A Perro IS-A Mamífero IS-A Animal → Pastor Alemán IS-A Animal.
6. El vector de características es el conjunto de información lingüística extraída del contexto (X). La etiqueta es el sentido correcto asignado manualmente (y). Cada instancia tiene exactamente una etiqueta — no una por elemento del vector, sino una para todo el vector como unidad.
7. Las características de colocación codifican información posicional — la palabra, su POS y los pares adyacentes en posiciones específicas. Las características sobre palabras vecinas (bag-of-words) son un vector binario que indica si ciertas palabras aparecen en la ventana, sin importar su posición.
8. Lesk simplificado compara la signature (definición del sentido en el diccionario) con el context (palabras que rodean la palabra ambigua) y elige el sentido con mayor solapamiento. Limitación: las definiciones del diccionario son muy cortas y pueden no solaparse con el contexto aunque el sentido sea correcto.
9. El IDF da mayor peso a palabras poco frecuentes y menor peso a palabras muy frecuentes como "the", "a", preposiciones. Estas últimas aparecen en casi todos los documentos, así que $nd_i \approx N_{doc}$ y $idf \approx \log 1 = 0$ — no aportan información discriminativa sobre el sentido.

10. Porque los clusters no tienen nombre — el algoritmo sabe que existen sentidos distintos pero no sabe cuáles son. Es útil para detectar cuántos sentidos tiene una palabra, agrupar instancias consistentemente y descubrir sentidos nuevos en dominios o idiomas sin diccionarios.

11. La medida de longitud del camino asume que cada arista representa la misma distancia semántica, lo cual no es realista — un paso cerca de la raíz (entidad → ser vivo) no equivale a uno cerca de las hojas (perro → lobo). Resnik lo resuelve usando IC del LCS: cuanto más específico es el ancestro común, mayor IC, mayor similitud — capturando la riqueza semántica real.

12. Similitud: palabras casi sinónimas, intercambiables en contexto (coche / bicicleta). Relación: conexión semántica sin ser intercambiables (coche / gasolina — relacionadas pero no similares). Los antónimos son el caso extremo: muy relacionados, nada similares.