

Universidad Internacional de La Rioja (UNIR)

Máster en Inteligencia Artificial

IA Generativa Aplicada al Análisis de Datos

**Actividad 1 — Comparación de Modelos Generativos y Aplicación Práctica
con CTGAN y LLM**

Pablo Alberto Duque Marín

Manizales, Caldas, Colombia · Abril 25 de 2026

1. Comparación entre GAN, VAE y LLM

La IA generativa moderna integra tres paradigmas con lógicas distintas: las Redes Generativas Antagónicas (GAN, ej. CTGAN) que aprenden distribuciones implícitas mediante competencia adversarial; los Autoencoders Variacionales (VAE, ej. TVAE) que construyen un espacio latente probabilístico explícito; y los Modelos de Lenguaje de Gran Escala (LLM, ej. GPT-4) que modelan la distribución conjunta de tokens de forma autorregresiva. La Tabla 1 resume sus diferencias en cuatro dimensiones técnicas.

Tabla 1

Comparación de modelos generativos

Dimensión	GAN (CTGAN)	VAE (TVAE)	LLM (GPT-4)
Objetivo	Generar muestras de máxima fidelidad estadística vía adversarialidad.	Aprender espacio latente probabilístico para reconstrucción e interpolación.	Generar tokens condicionados al contexto vía modelado autorregresivo.
Arquitectura	Generador G y Discriminador D en juego min-max; Mode-Specific Normalization y Conditional Sampling.	Encoder $\rightarrow (\mu, \sigma^2)$ latentes $\rightarrow$ Decoder; reparametrización; pérdida ELBO con KL.	Transformer con autoatención multi-cabeza enmascarada; miles de millones de parámetros.
Datos	Miles a decenas de miles de registros del dominio.	Cientos a miles; KL regulariza el latente.	Preentrenado con terabytes; usuario solo aporta prompt.
Aplicaciones	Datos tabulares sintéticos: financieros, clínicos; aumentación de clases minoritarias.	Detección de anomalías, imputación, química computacional.	Generación de texto, código, extracción estructurada, enriquecimiento semántico.

Nota. Elaboración propia con base en Goodfellow et al. (2014), Kingma y Welling (2014), Vaswani et al. (2017) y Xu et al. (2019).

Las GAN sobresalen cuando se requiere fidelidad estadística sobre tabulares; los VAE cuando importa la estructura interpretable del espacio latente; los LLM cuando la flexibilidad de adaptación a tareas heterogéneas pesa más que la precisión distribucional. La selección depende del problema, no de cuál modelo sea “mejor” en abstracto.

2. Caso de uso profesional con LLM: cartas de rechazo crediticio en banca

En la evaluación crediticia automatizada un modelo de scoring (XGBoost, Random Forest) decide aprobación; cuando rechaza, la entidad debe comunicar las razones cumpliendo el RGPD (art. 22) y el AI Act 2024, que clasifica scoring como sistema de alto riesgo. El LLM se integra al final del pipeline: recibe los factores explicativos del rechazo (calculados con SHAP sobre el modelo de scoring) y los datos del cliente, y redacta una carta personalizada en lenguaje natural, con tono empático pero formal, explicando las razones y sugiriendo pasos de mejora.

Tres componentes son indelegables al LLM: la decisión crediticia (la toma el modelo de scoring validado), la selección de factores explicativos, y la validación por muestreo de un oficial de cumplimiento, especialmente en casos frontera (montos altos, clientes vulnerables). Los riesgos relevantes son tres: técnico — alucinación de factores inexistentes; ético — amplificación de sesgos del modelo subyacente (variables proxy correlacionadas con grupos protegidos); legal — incumplimiento del deber de información ante errores que puedan derivar en sanciones bajo AI Act.

La mitigación se estructura en cuatro controles: arquitectura con esquema cerrado (el LLM recibe JSON con factores y $\text{temperature} \leq 0.2$, sin libertad para añadir causas); validación automática post-generación que verifica correspondencia entre JSON de entrada y texto generado; auditoría regular de paridad demográfica sobre las cartas emitidas; y trazabilidad completa por carta (JSON, prompt, modelo, versión, firma de revisión humana), cumpliendo los requisitos del AI Act sobre sistemas de alto riesgo (Bhatt et al., 2020).

3. Flujo Python de análisis de reseñas con LLM

Se diseñó un prompt robusto para GPT-4o-mini que automatiza el análisis de 15 reseñas reales. El system prompt define rol funcional, cuatro reglas estrictas (basarse solo en evidencia literal, devolver lista vacía sin evidencia, exigir acciones accionables con KPI, limitar el resumen a 80–120 palabras), y un esquema JSON de salida obligatorio con cuatro secciones: `puntos_positivos`, `puntos_negativos`, `clasificados`, `resumen_ejecutivo` y `acciones_mejora`. La llamada usa `temperature=0` y `response_format JSON` para garantizar reproducibilidad y parseabilidad. La

ejecución consumió 1.413 tokens (USD 0.0005) y devolvió un JSON válido (archivo informe_resenas.json adjunto).

Reflexión crítica. El flujo demuestra que un LLM con esquema cerrado puede transformar reseñas de texto libre en un informe ejecutivo accionable en segundos y por fracciones de centavo. En contextos con miles de reseñas diarias el valor operativo es alto. Sin embargo, la ejecución expuso tres límites que obligan a mantener supervisión humana. Primero, el modelo no respetó la exclusividad de categorías: tres reseñas quedaron clasificadas en dos categorías a la vez (por ejemplo, “La batería dura muy poco” aparece en calidad_producto y durabilidad), inflando el conteo total de 15 a 17 menciones. Un director que mire el tablero sin auditar podría sobredimensionar la crisis de calidad y reasignar presupuesto incorrectamente. Segundo, la informacion_producto y documentacion se solapan, fragmentando un problema único de soporte técnico en dos categorías que parecen anecdóticas. Tercero, el resumen ejecutivo quedó en 71 palabras cuando se pidió 80–120, evidenciando que el modelo interpreta las reglas con flexibilidad, no con precisión absoluta. Estos no son errores aleatorios sino sesgos estructurales que solo detecta una persona con conocimiento del negocio. El flujo sirve como triaje exploratorio, no como reporte final.

```
✓ PROMPT_SISTEMA = """Eres un Analista Senior de Experiencia del Cliente. Tu tarea es \
analizar reseñas reales de clientes y producir un informe estructurado en formato JSON.

REGLAS Estrictas:
1. Basa tu análisis EXCLUSIVAMENTE en el contenido literal de las reseñas provistas. \
No inventes información, contexto, ni infieras causas que no estén explícitas.
2. Si una categoría no tiene evidencia en las reseñas, devuelve una lista vacía []. \
No rellenes con contenido genérico.
3. Las acciones de mejora deben ser accionables: cada una debe especificar QUÉ hacer, \
a QUÉ área corresponde, y qué KPI mediría su impacto.
4. El resumen ejecutivo debe tener entre 80 y 120 palabras, tono formal, dirigido a \
dirección general.
```

4. Análisis del código CTGAN y mejoras propuestas

Nota: el enunciado refiere “código VAE” pero el código provisto implementa CTGAN; la explicación se desarrolla sobre el código efectivo. El código original construye un dataset de juguete (10 filas × 5 columnas), declara las columnas categóricas explícitamente para que CTGAN

aplique Mode-Specific Normalization a las continuas y Conditional Sampling a las discretas, entrena 300 épocas y compara medias entre real y sintético. Tiene tres limitaciones críticas: 10 filas son insuficientes para convergencia adversarial; comparar solo medias oculta divergencias en varianza, modalidad y correlaciones; no se evalúa utilidad predictiva downstream.

Mejoras implementadas. Se sustituyó el dataset por Adult Census (UCI), benchmark estándar del paper original (Xu et al., 2019). El preprocesamiento eliminó filas con '?' (~7,4%), descartó fnlwgt (peso muestral, no atributo) y tomó muestra estratificada de 10.000 filas por income; las 20.162 restantes se reservaron como holdout para TSTR, evitando evaluación circular. Se entrenó con 300 épocas y batch_size=500 (29,5 minutos en CPU). La evaluación reemplazó la comparación de medias por cuatro métricas formales: distancia de Wasserstein para continuas, divergencia de Jensen-Shannon para categóricas, norma de Frobenius entre matrices de correlación y protocolo TSTR contra holdout real.

$$W_1(P, Q) = \sum_{-\infty}^{\infty} |F_P(x) - F_Q(x)| dx$$

$$JSD(P, Q) = \frac{1}{2} D_{KL}(P || M) + \frac{1}{2} D_{KL}(Q || M), \quad M = (P + Q)/2$$

Tabla 2

Métricas de fidelidad distribucional y utilidad predictiva

Métrica	Variables	Resultado	Lectura
Wasserstein relativo	5 continuas	0.60% – 3.15%	Excelente (< 5%)
JSD	9 categóricas	0.0002 – 0.0402	Excelente (< 0.05)
Frobenius relativo	Matriz correlación	10.38%	Aceptable, en límite
TSTR ratio (AUC)	income, holdout 20K	0.978	Utilidad alta
TSTR ratio (F1)	income, holdout 20K	0.923	Pérdida 7.7%

Hallazgo crítico: limitación en variables zero-inflated. A pesar de las métricas agregadas favorables, el análisis desagregado reveló que CTGAN no preservó la masa puntual de capital.gain (91,92% de ceros reales → 1,15% sintéticos) ni de capital.loss (95,23% → 28,51%); el máximo de capital.gain sintético fue 16.253 vs 99.999 real. La Mode-Specific Normalization, basada en mixturas gaussianas, suavizó las masas puntuales como ruido positivo pequeño. Esto identifica

una clase de variables donde CTGAN falla estructuralmente: zero-inflated con cola pesada (días de hospitalización en salud, monto de siniestro en seguros, monto de devolución en e-commerce). Mejoras futuras incluirían modelado en dos pasos (Bernoulli sobre $P(x=0)$ + distribución condicional para no-ceros), transformaciones logarítmicas previas o arquitecturas extendidas como CTAB-GAN+ (Zhao et al., 2022). Adicionalmente, la correlación $\text{age} \times \text{hours.per.week}$ pasó de 0.11 real a 0.21 sintético, casi duplicándose: una correlación espuria amplificada que en producción generaría modelos confiados en patrones inexistentes.

5. Comparación visual y estadística real vs. sintético

La triangulación entre métricas agregadas y comparación visual permite detectar fallos que las primeras ocultan. Los histogramas de las cinco continuas (Figura 1) muestran superposición casi perfecta en age , education.num y hours.per.week , replicando incluso los picos exactos en education.num (HS-grad, Some-college, Bachelors). Las categóricas representativas (Figura 2) confirman la fidelidad indicada por JSD: sex prácticamente idéntica; native.country muestra el efecto del Conditional Sampling — United-States cayó de 91% real a 74% sintético, redistribuyendo masa hacia países minoritarios para evitar mode collapse.




Figura 1. Histogramas comparativos de variables continuas (real en azul, sintético en rojo).




Figura 2. Distribución de variables categóricas representativas.

Tabla 3

Comparación de medias entre datos reales y sintéticos

Variable	Media Real	Media Sintética	Diferencia (%)
age	38.25	40.53	5.96
education.num	10.15	10.01	1.38
capital.gain	1066.31	479.94	54.99
capital.loss	88.85	25.53	71.27
hours.per.week	40.83	39.89	2.30

¿Son los datos sintéticos buenos según las medias? La respuesta depende de la variable. Para age, education.num y hours.per.week las medias coinciden con error inferior al 6% y los histogramas confirman fidelidad alta. Para capital.gain y capital.loss las diferencias superan el 54% y 71%, evidenciando el fallo estructural en variables zero-inflated. La conclusión metodológica es que ninguna métrica individual es óptima: medias detectan algunos problemas pero ocultan multimodalidad y varianza; Wasserstein puede dar valores aceptables cuando masas puntuales se transforman en distribuciones suaves; JSD no aplica a continuas; correlaciones detectan distorsiones bivariadas pero no triviales. La evaluación rigurosa requiere triangulación entre las cuatro dimensiones. Los datos generados presentan utilidad predictiva alta (ratio TSTR 0.93) y preservación excelente de marginales categóricas, pero limitaciones que

invalidarían su uso en aplicaciones financieras donde la presencia exacta del valor cero tiene significado de negocio.

Referencias

- Bhatt, U., Xiang, A., Sharma, S., Weller, A., Taly, A., Jia, Y., Ghosh, J., Puri, R., Moura, J. M. F., & Eckersley, P. (2020). Explainable machine learning in deployment. *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*, 648–657.
<https://doi.org/10.1145/3351095.3375624>
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative adversarial nets. *Advances in Neural Information Processing Systems*, 27, 2672–2680.
- Kingma, D. P., & Welling, M. (2014). Auto-encoding variational Bayes. *International Conference on Learning Representations*. <https://arxiv.org/abs/1312.6114>
- Parlamento Europeo y Consejo de la Unión Europea. (2024). Reglamento (UE) 2024/1689 sobre inteligencia artificial (AI Act). *Diario Oficial de la Unión Europea*, L Series.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Xu, L., Skoularidou, M., Cuesta-Infante, A., & Veeramachaneni, K. (2019). Modeling tabular data using conditional GAN. *Advances in Neural Information Processing Systems*, 32, 7335–7345.
- Zhao, Z., Kunar, A., Birke, R., & Chen, L. Y. (2022). CTAB-GAN+: Enhancing tabular data synthesis. *Frontiers in Big Data*, 6, 1296508.
<https://doi.org/10.3389/fdata.2023.1296508>
- Becker, B., & Kohavi, R. (1996). Adult [Dataset]. UCI Machine Learning Repository.
<https://doi.org/10.24432/C5XW20>