

Guia de Estudio — Tema 2

Modelos Generativos Aplicados a Datos

GAN, VAE y Transformers en la generacion de datos tabulares

PSU — IA Generativa Aplicada al Analisis de Datos | UNIR

Indice de contenidos

- 1. El problema central: generacion de datos estructurados sinteticos
- 2. CTGAN — GAN para datos tabulares
 - 2.1 Funcion objetivo min-max (repaso)
 - 2.2 Desafios de datos tabulares
 - 2.3 Tres mecanismos de CTGAN
- 3. TVAE — VAE para datos tabulares
 - 3.1 ELBO adaptado a datos mixtos
 - 3.2 Funcion de reconstruccion por tipo de variable
 - 3.3 Espacio latente interpretable
- 4. Transformers / LLM para datos estructurados
 - 4.1 Regla de la cadena y generacion autoregresiva
 - 4.2 Prompting para generacion estructurada
 - 4.3 Ventajas y limitaciones
- 5. Comparacion de modelos
- 6. Modelos condicionales y control de generacion
- 7. Evaluacion de calidad de datos sinteticos
 - 7.1 Divergencia de Jensen-Shannon (JSD)
 - 7.2 Distancia de Wasserstein
 - 7.3 Distancia de Variacion Total (TVD)
 - 7.4 Metricas de utilidad practica: TSTR y TRTS
 - 7.5 Ejemplo numerico completo
- 8. Resumen de metricas por modelo

- 9. Preguntas de autoevaluación

1. El problema central: generación de datos estructurados sintéticos

Definición: Datos estructurados

Datos caracterizados por seguir un esquema bien definido de variables, dispuestos en filas y columnas (hojas de cálculo, bases de datos relacionales). Constituyen la base de la mayoría de los procesos analíticos empresariales.

El objetivo de la generación sintética es aprender la distribución de probabilidad conjunta de un dataset real y generar nuevas muestras a partir de ella:

$$\hat{p}(x_1, x_2, \dots, x_d) \approx p_{\text{data}}(x_1, x_2, \dots, x_d)$$

donde d es el número de variables (columnas). Esta distribución conjunta captura todas las relaciones entre variables: marginales, correlaciones, dependencias no lineales e interacciones multivariadas.

Por qué no basta con las marginales

Aprender cada columna por separado equivale a asumir independencia entre variables. La distribución conjunta se factorizaría como un simple producto de marginales. Eso destruye las relaciones entre variables: podría generar un cliente de 20 años con ingresos de 120,000 euros, algo estadísticamente implausible.

$$\hat{p}(x_1, \dots, x_d) = \prod_{i=1}^d p(x_i) \quad (\text{incorrecto : asume independencia})$$

Motivaciones para generar datos sintéticos: restricciones legales de privacidad, escasez de datos en ciertos dominios, necesidad de ampliar conjuntos de entrenamiento, simulación de escenarios hipotéticos, mitigación de sesgos de muestreo y desbalanceo en variables críticas.

Las tres familias de modelos generativos atacan este problema con estrategias diferentes:

Modelo	Estrategia
GAN (CTGAN)	Entrenamiento adversarial: el generador transforma ruido en datos; el discriminador evalúa si son reales
VAE (TVAE)	Compresión-reconstrucción: codifica datos en espacio latente, decodifica para generar
Transformer (LLM)	Descomposición autoregresiva: genera cada campo condicionado a los anteriores

2. CTGAN — GAN para datos tabulares

Definición: CTGAN (Conditional Tabular GAN)

Variante de GAN propuesta por Xu et al. (2019), diseñada específicamente para datos tabulares con variables mixtas (continuas y categóricas). Desarrollada como parte del proyecto Synthetic Data Vault (SDV) del MIT Data to AI Lab.

2.1 Función objetivo min-max (repaso)

La arquitectura base es la GAN clásica de Goodfellow et al. (2014): un generador G y un discriminador D entrenados de forma alternada.

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}} [\log D(x)] + E_{z \sim p_z} [\log(1 - D(G(z)))]$$

Lectura de la notación min-max: se lee de adentro hacia afuera. El paso interno es la maximización por parte de D (el discriminador busca distinguir reales de falsos). El paso externo es la minimización por parte de G (el generador busca engañar al discriminador).

Entrenamiento alternado en cada iteración:

Paso 1 — Entrenar D (con G fijo): se toma un lote de datos reales y un lote de datos generados. D ajusta sus pesos con ascenso de gradiente para maximizar V:

$$V_D = \frac{1}{m} \sum_{i=1}^m \log D(x^{(i)}) + \frac{1}{m} \sum_{i=1}^m \log(1 - D(G(z^{(i)})))$$

Paso 2 — Entrenar G (con D fijo): el generador ajusta sus pesos con descenso de gradiente. Solo influye en el segundo termino (no controla los datos reales):

$$V_G = \frac{1}{m} \sum_{i=1}^m \log(1 - D(G(z^{(i)})))$$

Flujo de datos en una pasada:

$$z \sim \mathcal{N}(0, I) \xrightarrow{G} G(z) \xrightarrow{D} D(G(z)) \in [0, 1]$$

El discriminador optimo para un G fijo es:

$$D_G^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)}$$

Equilibrio de Nash

En el optimo teorico, el generador aprende la distribucion real exacta y el discriminador responde 1/2 ante cualquier muestra (no puede distinguir reales de sinteticos). Esto indica que el generador ha convergido.

2.2 Desafios de datos tabulares

Las GAN clásicas fueron diseñadas para datos continuos y espacialmente coherentes (imágenes). Los datos tabulares presentan desafíos específicos que las GAN estándar no pueden manejar correctamente:

Desafío 1 — Variables categóricas: la salida del generador es continua (números con decimales). Para una variable como "país" con valores DE, FR, ES, no existe un orden numérico natural. La codificación ordinal (DE=1, FR=2, ES=3) introduce distancias y ordenes artificiales.

Desafío 2 — Distribuciones multimodales: variables continuas como "ingresos" suelen tener múltiples picos (junior vs. senior). El generador parte de ruido gaussiano unimodal y debe aprender a mapear un solo pico a múltiples picos, lo cual genera masa de probabilidad espuria en los "valles" entre modos.

Desafío 3 — Colapso de modo: en datasets desbalanceados (90% Alemania, 10% Francia), el generador puede colapsar hacia la categoría mayoritaria porque eso ya engaña parcialmente al discriminador.

2.3 Tres mecanismos de CTGAN

Mecanismo 1: Mode-specific normalization

En lugar de normalizar variables continuas con media y desviación estándar globales, CTGAN ajusta una mezcla de gaussianas (GMM) a cada variable continua:

$$p(x_j) \approx \sum_{k=1}^K \pi_k \cdot \mathcal{N}(\mu_k, \sigma_k^2)$$

Para cada valor, se codifican dos cosas: el modo (pico) al que pertenece y la desviación normalizada respecto al centro de ese modo. Esto elimina el problema de los valles entre modos, ya que el generador no necesita "descubrir" que existen múltiples picos.

Mecanismo 2: Gumbel-softmax para variables categoricas

Las variables categoricas se representan con one-hot encoding. La funcion softmax produce probabilidades continuas (e.g., 0.82, 0.11, 0.07) en lugar de vectores discretos exactos (1, 0, 0). El mecanismo gumbel-softmax produce valores que se aproximan a one-hot durante el entrenamiento, manteniendo la diferenciabilidad para que fluyan los gradientes. Al momento de generar datos finales, se aplica argmax para obtener la categoria definitiva.

Mecanismo 3: Conditional sampling (muestreo condicional)

En cada lote de entrenamiento, se selecciona aleatoriamente una variable categorica y un valor especifico con muestreo uniforme (todas las categorias tienen igual probabilidad de ser seleccionadas, sin importar su frecuencia real). El vector de condicion se concatena con el ruido de entrada al generador:

$$\text{entrada de G} = [z \mid \text{condicion}]$$

Los datos reales del lote se filtran para que coincidan con la misma condicion. Esto obliga al generador a aprender todas las categorias por igual, evitando el colapso de modo.

Elementos necesarios para aplicar CTGAN

Variables de entrada: dataset tabular con variables categoricas y continuas. Variable objetivo: no necesaria (modelo no supervisado). Transformaciones requeridas: normalizacion de variables numericas, codificacion categorica (one-hot o embeddings), manejo de valores nulos. Modelo recomendado: CTGAN via libreria SDV. Salida esperada: nuevos registros sinteticos que preservan estructura, relaciones internas y caracteristicas estadisticas.

3. TVAE — VAE para datos tabulares

Definicion: TVAE (Tabular Variational Autoencoder)

Adaptacion del VAE clasico (Kingma y Welling, 2014) para datos tabulares con variables mixtas. Ofrece entrenamiento mas estable que CTGAN y un espacio latente explicito e interpretable.

3.1 ELBO adaptado a datos mixtos

El TVAE consta de dos componentes entrenados conjuntamente:

Codificador $q_{\phi}(z | x)$: toma una fila de datos y produce una distribución en el espacio latente, típicamente una gaussiana multivariada con parámetros μ y σ que son funciones aprendidas de la entrada.

Decodificador $p_{\theta}(x | z)$: toma un punto del espacio latente y reconstruye la fila original.

La función de entrenamiento es el ELBO (Evidence Lower Bound):

$$\mathcal{L}(\theta, \phi; x) = E_{q_{\phi}(z | x)} [\log p_{\theta}(x | z)] - D_{KL}(q_{\phi}(z | x) || p(z))$$

Primer término (reconstrucción): mide que tan bien el decodificador recupera los datos originales a partir de la representación latente.

Segundo término (regularización KL): fuerza a que la distribución latente aprendida se parezca a la distribución a priori estándar. La forma cerrada para gaussianas es:

$$D_{KL}(\mathcal{N}(\mu, \sigma^2) || \mathcal{N}(0, 1)) = -\frac{1}{2} \sum_{j=1}^J (1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2)$$

donde J es la dimensión del espacio latente.

Relación con la log-evidencia: el ELBO es una cota inferior de la log-evidencia, lo que significa que maximizar el ELBO es una forma tratable de aproximar la maximización de la verosimilitud de los datos:

$$\log p(x) \geq \mathcal{L}(\theta, \phi; x)$$

Truco de reparametrización

Para que los gradientes fluyan a través del muestreo (que normalmente no es diferenciable), se usa una reparametrización: en lugar de muestrear z directamente de la gaussiana aprendida, se muestrea un ruido epsilon de una normal estándar y se transforma:

$$z = \mu + \sigma \cdot \epsilon \quad \text{donde} \quad \epsilon \sim \mathcal{N}(0, I)$$

Así la aleatoriedad queda en epsilon, y μ y σ son funciones diferenciables del codificador.

3.2 Función de reconstrucción por tipo de variable

La adaptación clave de TVAE es usar funciones de pérdida diferentes según el tipo de variable:

Variables continuas — error cuadrático medio (MSE), asumiendo una distribución gaussiana de reconstrucción:

$$L_{\text{continua}} = (x_j - \hat{x}_j)^2$$

Variables categóricas — entropía cruzada (cross-entropy), que penaliza fuertemente cuando el modelo asigna baja probabilidad a la categoría correcta:

$$L_{\text{categorica}} = - \sum_k y_{jk} \log(\hat{y}_{jk})$$

La pérdida de reconstrucción total combina ambas:

$$L_{\text{reconstrucción}} = \sum_{j \in \text{continuas}} (x_j - \hat{x}_j)^2 + \sum_{j \in \text{categoricas}} \left(- \sum_k y_{jk} \log(\hat{y}_{jk}) \right)$$

Además, TVAE aplica la misma mode-specific normalization de CTGAN para variables continuas multimodales.

3.3 Espacio latente interpretable

La gran ventaja de TVAE sobre CTGAN es su espacio latente explícito, continuo y estructurado. Esto permite:

Interpolación: dados dos clientes codificados en el espacio latente, tomar puntos intermedios y decodificarlos produce perfiles intermedios coherentes — útil para explorar variaciones de atributos.

Manipulación dirigida: desplazarse en una dirección específica del espacio latente para modificar un atributo mientras se mantienen los demás — por ejemplo, "como sería este cliente si fuera 10 años mayor".

Visualización y agrupamiento: proyectar el espacio latente con UMAP o t-SNE para verificar que los datos sintéticos preservan la estructura de clusters de los datos reales.

Limitación principal de TVAE

Tendencia a generar muestras "promedias" — valores intermedios plausibles pero que no representan casos reales específicos. Esto se debe a que la regularización KL empuja al espacio latente hacia una distribución suave, lo cual puede diluir los extremos. Las muestras son menos precisas que las de CTGAN pero más diversas y estables.

4. Transformers / LLM para datos estructurados

4.1 Regla de la cadena y generación autoregresiva

Los LLM modelan la distribución conjunta descomponiéndola en condicionales sucesivas:

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i \mid x_1, \dots, x_{i-1})$$

Generan un token a la vez, condicionado a todos los anteriores, mediante autoatencion enmascarada (causal) que impide acceso a posiciones futuras. Si los datos tabulares se formatean como texto (JSON, CSV), el LLM puede generar filas completas de tablas con estructura coherente.

Mecanismo de autoatencion escalada:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

En modelos generativos tipo GPT, se aplica una mascara triangular inferior al producto QK transpuesto antes del softmax, garantizando que cada token solo atienda a los anteriores.

4.2 Prompting para generacion estructurada

El control de la generacion se ejerce a traves del diseno del prompt, aplicando principios de prompt engineering:

Zero-shot: instrucciones directas sin ejemplos previos. Util para generacion rapida pero con menor control sobre el formato.

Few-shot: se proporcionan ejemplos completos del formato esperado antes de pedir la generacion. El modelo interpreta el patron y lo replica. Es la tecnica principal para generacion de datos estructurados con LLM.

Elementos de un prompt efectivo: rol funcional claro (e.g., "eres un generador de eventos JSON"), ejemplos bien formateados como guia, restricciones explicitas sobre dominio de valores y coherencia.

4.3 Ventajas y limitaciones

Ventajas	Limitaciones
----------	--------------

Flexibilidad: sin reentrenamiento, se adapta a cualquier formato	Menor control estadístico: no garantiza fidelidad distribucional
Generación contextual con lenguaje natural	Posibles errores de formato o inconsistencias
Capacidad para generar datos sin dataset previo	Costo computacional elevado
Maneja campos de texto libre	Requiere validación y postprocesamiento

Capacidades complementarias de los LLM

Más allá de la generación directa: generación de código para preprocesamiento, imputación de datos faltantes basada en contexto, conversión texto-tabla y viceversa. Complementan a GAN/VAE pero no los sustituyen en tareas que requieren fidelidad estadística estricta.

5. Comparación de modelos

Aspecto	GAN (CTGAN)	VAE (TVAE)	Transformer (LLM)
Mecanismo	Adversarial: G vs D	Codificación-reconstrucción variacional	Autoregresivo con atención automática
Tipo de densidad	Implícita	Explícita (ELBO)	Explícita (regla de la cadena)
Espacio latente	No estructurado (ruido)	Estructurado, continuo, interpretable	No definido explícitamente
Usos principales	Generación realista, aumento de clases minoritarias	Imputación, exploración de variantes sintéticas	Prototipado rápido, simulación semántica
Fortaleza	Alto realismo, captura relaciones complejas	Entrenamiento estable, generación diversa, espacio interpretable	Flexibilidad, interfaz en lenguaje natural, sin reentrenamiento
Debilidad	Entrenamiento inestable, riesgo de colapso de modo	Muestras menos precisas, tendencia a promediar	Menor control estadístico, errores de formato
Requiere entrenamiento	Sí, sobre datos específicos	Sí, sobre datos específicos	No (usa modelo preentrenado)

Criterio de seleccion rapido

Maximo realismo y fidelidad estadistica con datos disponibles: CTGAN. Exploracion controlada del espacio de datos e interpretabilidad: TVAE. Prototipado rapido, datos semanticos, o sin dataset previo: LLM.

6. Modelos condicionales y control de generacion

El control sobre la generacion puede aplicarse en distintas etapas segun el modelo:

Modelo	Tecnica de control	Punto de aplicacion	Ejemplo
CTGAN	Embeddings vectoriales de categorias como entrada a G y D	Entrenamiento y muestreo	<code>ctgan.sample(10, condition_column="pais", condition_value="DE")</code>
CVAE (VAE condicional)	Variable condicional concatenada al vector de entrada y al espacio latente	Entrenamiento y generacion	Generar registros de tipo "empresarial" incluyendo tipo como variable de entrada
LLM	Prompts con condiciones explicitas en lenguaje natural	Entrada (prompt)	"Genera 3 perfiles con ciudad = Barcelona y edad mayor a 30"

Resumen sobre control

GAN y VAE ofrecen control categorico preciso y explicable, ideal para condicionar la generacion a etiquetas especificas. Los VAE permiten mejor manipulacion de variables continuas gracias al espacio latente estructurado. Los LLM destacan por escalabilidad semantica (generacion compleja a partir de descripciones en lenguaje natural), aunque con menor precision estadistica.

7. Evaluacion de calidad de datos sinteticos

La evaluacion tiene dos dimensiones complementarias: **fidelidad estadistica** (los datos sinteticos se parecen a los reales) y **utilidad practica** (los datos sinteticos sirven para tareas reales). Fidelidad alta no garantiza utilidad, y viceversa.

Notacion base para las metricas:

P = distribucion de probabilidad de los datos reales, con probabilidades p_i por categoria.

Q = distribucion de probabilidad de los datos sinteticos, con probabilidades q_i por categoria.

7.1 Divergencia de Jensen-Shannon (JSD)

Definicion: JSD

Mide la similitud entre dos distribuciones de probabilidad. Es simetrica, acotada entre 0 (identicas) y 1 (con log base 2), y se construye a partir de la divergencia KL.

Primero se calcula la distribucion promedio:

$$m_i = \frac{1}{2}(p_i + q_i)$$

Luego la JSD se define como el promedio de dos divergencias KL:

$$JSD(P, Q) = \frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M)$$

Donde cada divergencia KL es:

$$D_{KL}(P||M) = \sum_i p_i \log \frac{p_i}{m_i}$$

La formula expandida es:

$$JSD(P, Q) = \frac{1}{2} \sum_i p_i \log \frac{p_i}{m_i} + \frac{1}{2} \sum_i q_i \log \frac{q_i}{m_i}$$

Por que JSD y no KL directamente

La KL no es simetrica: medir la distancia de P a Q no da el mismo resultado que de Q a P. La JSD resuelve esto comparando ambas contra su promedio M. Ademas, la KL puede ser infinita cuando una distribucion asigna probabilidad 0 a un evento que la otra no; la JSD siempre esta acotada.

Uso: natural para variables categoricas o discretizadas. Un valor cercano a 0 indica alta fidelidad.

7.2 Distancia de Wasserstein

Definicion: Distancia de Wasserstein (Earth Mover's Distance)

Compara los valores ordenados de dos distribuciones continuas. Mide cuanto "trabajo" (distancia por cantidad de masa) se requiere para transformar una distribucion en la otra. Proporciona una medida significativa incluso cuando las distribuciones no se superponen.

Para datos en una dimension con n muestras de igual tamano, se ordenan ambos conjuntos y se comparan posicion por posicion:

$$d_W(P, Q) = \frac{1}{n} \sum_{i=1}^n |x_{(i)} - y_{(i)}|$$

donde $x_{(i)}$ e $y_{(i)}$ son los valores ordenados (cuantiles empiricos) de los datos reales y sinteticos respectivamente.

Uso: natural para variables continuas. Se calcula variable por variable. El resultado tiene las unidades de la variable (e.g., "1.2 anos", "850 euros"), lo que facilita la interpretacion directa.

Intuicion: mover montanas de arena

Imagina que la distribucion de edades reales es una montana de arena con cierta forma, y la sintetica es otra con forma ligeramente diferente. Wasserstein mide cuanta arena hay que mover, y que tan lejos, para transformar una montana en la otra. Menor distancia indica distribuciones mas similares.

7.3 Distancia de Variacion Total (TVD)

Definicion: TVD (Total Variation Distance)

Mide la maxima discrepancia global en probabilidad entre dos distribuciones. Siempre esta acotada entre 0 (identicas) y 1 (totalmente diferentes).

$$TVD(P, Q) = \frac{1}{2} \sum_i |p_i - q_i|$$

Uso: natural para distribuciones de probabilidad discretas (categoricas). Es la mas simple de interpretar: un TVD de 0.1 significa un 10% de discrepancia global en las proporciones.

7.4 Metricas de utilidad practica: TSTR y TRTS

Las metricas de fidelidad estadistica se calculan **columna por columna** (distribuciones marginales). No capturan si las relaciones entre variables se preservaron. Para evaluar la distribucion conjunta se usan metricas de utilidad practica:

TSTR — Train on Synthetic, Test on Real

Se entrena un modelo predictivo usando solo datos sinteticos y se evalua su rendimiento sobre datos reales. Si el rendimiento es bueno, los datos sinteticos capturaron las relaciones entre variables de forma suficiente.

TRTS — Train on Real, Test on Synthetic

Se entrena un modelo con datos reales y se evalúa sobre sintéticos. Si el rendimiento es bueno, los datos sintéticos son consistentes con los patrones aprendidos de los reales.

Complementos: matrices de correlación comparadas (verifican relaciones lineales), visualización en PCA/UMAP (verifican estructura global), validación de coherencia lógica (combinaciones de valores que tengan sentido semántico).

Principio clave de evaluación

La evaluación robusta requiere una estrategia multidimensional: fidelidad estadística (JSD, Wasserstein, TVD por variable) + utilidad práctica (TSTR, TRTS, correlaciones) + coherencia semántica (reglas de negocio, validación lógica). No existe una única métrica capaz de captar todos los aspectos de calidad.

7.5 Ejemplo numerico completo

Ejemplo del material del curso

Datos reales (R):

Tipo_cliente: 6 fidelizados, 4 nuevos. Edad: [25, 28, 30, 32, 35, 36, 38, 40, 42, 45]. Ingreso: [22, 25, 28, 30, 33, 34, 36, 39, 40, 44].

Datos sinteticos (S):

Tipo_cliente: 5 fidelizados, 5 nuevos. Edad: [26, 27, 31, 33, 34, 37, 39, 41, 43, 46]. Ingreso: [23, 26, 29, 31, 32, 35, 37, 38, 41, 45].

Medias y varianzas (edad):

reales = 35.1 (var = 45.2), sinteticos = 35.7 (var = 37.6). Valores proximos.

Correlacion (edad-ingreso):

reales = 0.98, sinteticos = 0.97. Relacion lineal preservada.

Chi-cuadrado (tipo_cliente):

6 vs 4 frente a 5 vs 5. p-valor mayor a 0.5: sin diferencias significativas.

KS (edad):

D = 0.2, p aproximado 0.8: distribuciones similares.

JSD (tipo_cliente):

P = (0.6, 0.4), Q = (0.5, 0.5), M = (0.55, 0.45).

$$JSD = \frac{1}{2} \left(0.6 \log \frac{0.6}{0.55} + 0.4 \log \frac{0.4}{0.45} \right) + \frac{1}{2} \left(0.5 \log \frac{0.5}{0.55} + 0.5 \log \frac{0.5}{0.45} \right) \approx 0.005$$

Valor muy cercano a 0: distribuciones muy similares.

Wasserstein (edad):

diferencias absolutas posicion a posicion = 1 en cada par. Promedio = 1.0. Se necesita desplazar menos de 1 ano para alinear ambas distribuciones.

TVD (tipo_cliente):

$$TVD = \frac{1}{2} (|0.6 - 0.5| + |0.4 - 0.5|) = \frac{1}{2} (0.1 + 0.1) = 0.1$$

10% de discrepancia global en proporciones.

8. Resumen de metricas por modelo

Modelo	Fidelidad estadistica	Utilidad practica
CTGAN (GAN)	Indicadores tradicionales: medias, varianzas, correlaciones, test KS, chi-cuadrado. Avanzados: Wasserstein, KL divergence, TVD, visualizacion PCA/UMAP	TSTR, TRTS, metricas predictivas (Accuracy, F1), pruebas de ablacion
TVAE (VAE)	Indicadores tradicionales: histogramas, boxplots, correlaciones condicionales. Avanzados: Jensen-Shannon, visualizacion en espacio latente (UMAP, t-SNE)	TSTR/TRTS, clustering sintetico, evaluacion de reconstruccion (MSE, MAE), transferencia de representaciones latentes
LLM (Transformers)	Indicadores tradicionales: validacion estructural (tipos de datos, formatos), reglas basicas de consistencia. Avanzados: validacion semantica contextual, QA automatico	Evaluacion funcional (cumplimiento del proposito), testeo automatizado, validacion con reglas de negocio, revision manual

9. Preguntas de autoevaluacion

Preguntas conceptuales

1.

Explique por que una GAN estandar disenada para imagenes no puede aplicarse directamente a datos tabulares con variables mixtas. Mencione al menos tres desafios especificos.

2.

Describe los tres mecanismos de CTGAN y el problema especifico que resuelve cada uno.

3.

En el ELBO del VAE, que sucede si el termino de regularizacion KL domina sobre el termino de reconstruccion? Como se manifiesta eso en la calidad de los datos generados?

4.

Por que se dice que la GAN es un modelo de densidad implicita mientras que el VAE es de densidad explicita?

5.

Compare TSTR y TRTS. Por que es necesario evaluar ambos para una validacion robusta de datos sinteticos?

6.

Un dataset sintetico tiene $JSD = 0.002$ y $Wasserstein = 0.5$ para todas sus variables. Sin embargo, el TSTR produce un accuracy de solo 52%. Explique como es esto posible y que indica sobre la calidad de los datos.

7.

En que escenario elegiria un LLM sobre CTGAN para generar datos sinteticos? Y en que escenario seria claramente inadecuado usar un LLM?

8.

Explique por que la mode-specific normalization de CTGAN resuelve el problema de distribuciones multimodales en variables continuas.

9.

Que ventaja tiene el espacio latente de TVAE sobre el espacio latente de CTGAN para la exploracion de datos? De un ejemplo practico.

10.

Por que las metricas de fidelidad estadistica (JSD, Wasserstein, TVD) se calculan variable por variable y no sobre toda la tabla conjuntamente? Que aspecto de la calidad no capturan?

Preguntas matematicas

11.

Calcule la JSD para una variable categorica con $P = (0.7, 0.2, 0.1)$ y $Q = (0.5, 0.3, 0.2)$. Use logaritmo natural.

12.

Dados los valores reales ordenados $x = [10, 20, 30, 40, 50]$ y sinteticos $y = [12, 18, 33, 42, 48]$, calcule la distancia de Wasserstein.

13.

Para una variable con $P = (0.3, 0.5, 0.2)$ y $Q = (0.4, 0.35, 0.25)$, calcule la TVD e interprete el resultado.

14.

En la funcion objetivo de las GAN, si el discriminador asigna $D(G(z)) = 0.8$ a un dato sintetico, calcule el valor del segundo termino de la perdida para ese dato. Es un buen o mal resultado para el generador?

15.

En un VAE con espacio latente de dimension $J = 3$, el codificador produce $\mu = (0.2, -0.5, 0.8)$ y sigma cuadrado $= (1.1, 0.9, 1.3)$. Calcule la divergencia KL con respecto a la normal estandar.

10. Diccionario de terminos

Termino	Definicion
Argmax	Operacion que selecciona el indice con el valor maximo de un vector. En CTGAN, se aplica sobre la salida softmax para convertir probabilidades continuas (e.g., 0.82, 0.11, 0.07) en un vector one-hot discreto (1, 0, 0).
Ascenso de gradiente	

	Metodo de optimizacion que ajusta los parametros en la direccion que maximiza una funcion. El discriminador lo usa para maximizar V.
Autoatencion (Self-Attention)	Mecanismo que permite a cada elemento de una secuencia calcular su relevancia respecto a todos los demas elementos simultaneamente. Base de la arquitectura Transformer.
Autoatencion enmascarada (Causal Attention)	Variante de la autoatencion donde cada token solo puede atender a los tokens anteriores, nunca a los futuros. Garantiza la propiedad autoregresiva en modelos generativos como GPT.
Autoregresivo	Tipo de generacion donde cada elemento se produce condicionado a todos los anteriores. Los LLM generan token por token siguiendo la regla de la cadena de probabilidades.
Chi-cuadrado (test)	Prueba estadistica que evalua si la distribucion observada de una variable categorica difiere significativamente de una distribucion esperada. Se usa para comparar proporciones entre datos reales y sinteticos.
Codificador (Encoder)	En un VAE, la red neuronal que toma un dato de entrada y produce los parametros (media y varianza) de una distribucion en el espacio latente.
Colapso de modo (Mode Collapse)	Problema de las GAN donde el generador produce solo unas pocas variantes en lugar de la diversidad completa de los datos reales. Por ejemplo, generar solo clientes de una categoria dominante e ignorar las minoritarias.
Conditional sampling	Tercer mecanismo de CTGAN. Fuerza al generador a producir datos de todas las categorias con igual frecuencia durante el entrenamiento, evitando el colapso de modo en clases minoritarias.
Cross-entropy (Entropia cruzada)	Funcion de perdida para variables categoricas que mide la diferencia entre la distribucion predicha y la real. Penaliza fuertemente cuando el modelo asigna baja probabilidad a la categoria correcta.
CTGAN (Conditional Tabular GAN)	Variante de GAN disenada para datos tabulares mixtos, propuesta por Xu et al. (2019). Introduce mode-specific normalization, gumbel-softmax y conditional sampling. Parte del proyecto SDV del MIT.
CVAE (Conditional VAE)	Variante del VAE que incorpora variables condicionales al codificador y decodificador, permitiendo generar datos dirigidos a categorias o atributos especificos.
D(G(z))	Composicion de funciones: el ruido z pasa por el generador G produciendo un dato sintetico, que luego pasa por el discriminador

	D que emite un veredicto entre 0 (falso) y 1 (real). El gradiente de esta composicion es lo que permite entrenar a G.
Datos estructurados	Datos organizados en un esquema definido de filas y columnas, como hojas de calculo o bases de datos relacionales. Incluyen variables numericas y categoricas.
Datos sinteticos	Datos generados artificialmente por un modelo que imitan las propiedades estadisticas de un dataset real sin contener registros reales.
Decodificador (Decoder)	En un VAE, la red neuronal que toma un punto del espacio latente y reconstruye un dato en el espacio original.
Densidad explicita	Propiedad de modelos (VAE, Transformers) que pueden evaluar directamente la probabilidad de un dato. El modelo puede calcular $p(x)$ para cualquier dato x .
Densidad implicita	Propiedad de las GAN: el modelo puede generar muestras de la distribucion aprendida, pero no puede calcular la probabilidad de un dato especifico. Solo genera, no evalua.
Descenso de gradiente	Metodo de optimizacion que ajusta los parametros en la direccion que minimiza una funcion de perdida. El generador lo usa para minimizar V .
Discriminador (D)	Red neuronal en una GAN que recibe datos (reales o sinteticos) y produce una probabilidad entre 0 y 1 indicando que tan probable es que el dato sea real. Actua como "detective".
Distribucion conjunta	Distribucion de probabilidad sobre todas las variables simultaneamente: $p(x_1, x_2, \dots, x_d)$. Captura todas las relaciones, correlaciones y dependencias entre variables. Es lo que los modelos generativos buscan aprender.
Distribucion marginal	Distribucion de probabilidad de una sola variable, ignorando las demas. Aprender solo marginales equivale a asumir independencia entre variables, perdiendo toda la estructura relacional.
Distribucion multimodal	Distribucion con multiples picos (modos). Por ejemplo, los ingresos pueden tener un pico en 25,000 (juniors) y otro en 60,000 (seniors). Las GAN estandar tienen dificultad para modelarlas porque parten de ruido unimodal.
Divergencia KL (Kullback-Leibler)	Medida de cuanto difiere una distribucion de probabilidad Q de una distribucion de referencia P . No es simetrica: $KL(P Q)$ distinto de $KL(Q P)$. Aparece en el ELBO del VAE y como componente de la JSD.

ELBO (Evidence Lower Bound)	Funcion objetivo del VAE. Cota inferior de la log-evidencia. Tiene dos terminos: reconstruccion (que tan bien se recuperan los datos) y regularizacion KL (que tan organizado esta el espacio latente).
Entrenamiento alternado	Procedimiento de entrenamiento de las GAN: en cada iteracion se alterna entre actualizar el discriminador (maximizar V) y actualizar el generador (minimizar V). No se optimizan simultaneamente.
Equilibrio de Nash	Estado optimo teorico de la GAN donde el generador ha aprendido la distribucion real y el discriminador responde 1/2 ante cualquier muestra. En la practica, nunca se alcanza perfectamente.
Espacio latente	Representacion comprimida y de menor dimension de los datos. En VAE es explicito, continuo y estructurado (permite interpolacion). En GAN es simplemente ruido aleatorio sin estructura interpretable.
Few-shot prompting	Tecnica de prompting donde se proporcionan ejemplos del formato esperado antes de pedir la generacion. El LLM interpreta el patron y lo replica. Tecnica principal para generacion de datos estructurados con LLM.
Fidelidad estadistica	Primera dimension de evaluacion de datos sinteticos: mide si las distribuciones de las variables individuales se parecen a las reales. Se evalua con JSD, Wasserstein, TVD, medias, varianzas, correlaciones.
GAN (Generative Adversarial Network)	Arquitectura generativa basada en dos redes (generador y discriminador) que compiten en un juego min-max. Propuesta por Goodfellow et al. (2014).
Generador (G)	Red neuronal en una GAN que transforma ruido aleatorio z en datos sinteticos $G(z)$. Su objetivo es producir datos que el discriminador no pueda distinguir de los reales. Actua como "falsificador".
GMM (Gaussian Mixture Model)	Modelo estadistico que representa una distribucion como combinacion ponderada de multiples gaussianas. CTGAN lo usa en la mode-specific normalization para detectar los modos de cada variable continua.
Gumbel-softmax	Segundo mecanismo de CTGAN. Variante de softmax que produce salidas mas cercanas a one-hot durante el entrenamiento, manteniendo la diferenciabilidad. Resuelve el problema de que el discriminador detecte datos falsos solo por tener decimales en lugar de 0 y 1 exactos.
Interpolacion (espacio latente)	Tomar puntos intermedios entre dos representaciones en el espacio latente y decodificarlos. En TVAE, produce perfiles intermedios coherentes. Util para explorar variaciones controladas de datos.

JSD (Jensen-Shannon Divergence)	Metrica simetrica y acotada para comparar distribuciones. Promedio de dos divergencias KL contra la distribucion media M. Valor cercano a 0 indica distribuciones muy similares.
Juego min-max	Formulacion de la funcion objetivo de las GAN. Se lee de adentro hacia afuera: primero D maximiza V, luego G minimiza el resultado. Lo que uno gana, el otro lo pierde (juego de suma cero).
Kolmogorov-Smirnov (test KS)	Prueba estadistica que evalua si dos muestras provienen de la misma distribucion continua. Se usa para comparar variables continuas entre datos reales y sinteticos.
Log-evidencia	Logaritmo de la probabilidad marginal de los datos: $\log p(x)$. El ELBO es una cota inferior de esta cantidad. Maximizar el ELBO aproxima la maximizacion de la log-evidencia.
LLM (Large Language Model)	Modelo de lenguaje de gran escala basado en Transformers. Genera texto token por token de forma autoregresiva. Puede generar datos tabulares si se formatean como texto (JSON, CSV).
Mode-specific normalization	Primer mecanismo de CTGAN. Ajusta un GMM a cada variable continua para detectar modos, y codifica cada valor como pertenencia a un modo mas desviacion normalizada. Elimina el problema de generar datos en los valles entre picos.
MSE (Mean Squared Error)	Error cuadratico medio. Funcion de perdida natural para variables continuas en el termino de reconstruccion de TVAE. Mide la distancia numerica al cuadrado entre el valor real y el reconstruido.
One-hot encoding	Representacion de variables categoricas como vectores binarios: cada categoria ocupa una dimension propia. DE = (1,0,0), FR = (0,1,0), ES = (0,0,1). No introduce orden ni distancias artificiales.
PCA (Principal Component Analysis)	Tecnica de reduccion de dimensionalidad lineal. Se usa para visualizar datos reales y sinteticos en 2D y evaluar si se solapan adecuadamente.
Regla de la cadena	Descomposicion de la distribucion conjunta en producto de condicionales sucesivas. Base matematica de la generacion autoregresiva en Transformers/LLM.
Reparametrizacion (truco de)	Tecnica para hacer diferenciable el muestreo en VAE. En lugar de muestrear z directamente, se muestrea epsilon de una normal estandar y se transforma: $z = \mu + \sigma * \epsilon$.
SDV (Synthetic Data Vault)	

	Suite de herramientas de código abierto del MIT Data to AI Lab para generar, modelar y evaluar datos sintéticos. Incluye CTGAN, TVAE, GaussianCopula y SDMetrics.
Señal de gradiente	Información que fluye desde la función de pérdida hacia los pesos de la red durante la retropropagación. En las GAN, el generador nunca ve los datos reales directamente; su única información sobre calidad llega a través del gradiente que pasa por el discriminador.
Softmax	Función que convierte un vector de valores reales en probabilidades que suman 1. Se usa en la salida del generador para variables categóricas y en la autoatención de los Transformers.
TRTS (Train on Real, Test on Synthetic)	Métrica de utilidad práctica. Se entrena un modelo con datos reales y se evalúa sobre sintéticos. Buen rendimiento indica que los sintéticos son consistentes con los patrones reales.
TSTR (Train on Synthetic, Test on Real)	Métrica de utilidad práctica. Se entrena un modelo con datos sintéticos y se evalúa sobre reales. Buen rendimiento indica que las relaciones entre variables se preservaron.
TVAE (Tabular VAE)	Adaptación del VAE para datos tabulares mixtos. Usa funciones de pérdida diferenciadas por tipo de variable (MSE para continuas, cross-entropy para categóricas) y mode-specific normalization.
TVD (Total Variation Distance)	Distancia de variación total. Mide la máxima discrepancia global entre dos distribuciones discretas. Valor entre 0 (idénticas) y 1 (totalmente diferentes). La más simple de interpretar.
UMAP / t-SNE	Técnicas de reducción de dimensionalidad no lineal. Se usan para visualizar el espacio latente de TVAE o para comparar la estructura global de datos reales y sintéticos en 2D.
Utilidad práctica	Segunda dimensión de evaluación de datos sintéticos: mide si los datos sirven para tareas reales. Se evalúa con TSTR, TRTS, métricas predictivas y validación de coherencia lógica.
Wasserstein (distancia de)	Earth Mover's Distance. Mide cuánto "trabajo" se requiere para transformar una distribución en otra. Para datos 1D, se comparan valores ordenados posición por posición. Natural para variables continuas, con resultado en las unidades de la variable.
Zero-shot prompting	Técnica donde se dan instrucciones directas al LLM sin ejemplos previos. Menos control sobre el formato que few-shot, pero más rápido.

11. Notas de sesion: dudas tratadas y explicaciones clave

Esta seccion documenta las dudas que surgieron durante el estudio guiado y las explicaciones que las resolvieron. Sirve como referencia rapida de los puntos que requirieron mayor atencion.

Duda 1: Como funcionan las GAN — "recompensas y pistas"

Confusion inicial: se pensaba que el discriminador le daba "recompensas" o "pistas" explicitas al generador, similar a un sistema de aprendizaje por refuerzo.

Aclaracion: no existe un sistema de recompensas explicito. La unica informacion que recibe el generador es una **senal de gradiente** que fluye desde la funcion de perdida, atravesando el discriminador por retropropagacion. El generador nunca ve los datos reales directamente — es como un artista ciego que solo recibe la critica de un juez, sin ver las obras originales.

Duda 2: Que significa la notacion min-max

Confusion inicial: no estaba claro como leer la expresion con dos operadores de optimizacion.

Aclaracion: se lee de adentro hacia afuera. Primero, el paso interno: el discriminador D maximiza V (hace lo mejor posible por distinguir reales de falsos). Luego, el paso externo: el generador G minimiza ese resultado (busca que incluso el mejor D posible no pueda distinguir). En la practica, esto se implementa como un entrenamiento alternado: paso 1 actualiza D , paso 2 actualiza G , y se repite.

Duda 3: Como funciona $D(G(z))$ — composicion de funciones

Confusion inicial: la notacion anidada con tres niveles no era intuitiva.

Aclaracion: se lee de adentro hacia afuera como capas de una cebolla. Capa 1: z es un vector de ruido aleatorio (e.g., 128 numeros de una normal estandar). Capa 2: $G(z)$ es la transformacion que hace el generador — convierte esos 128 numeros en un dato con la misma forma que un dato real (e.g., 4 columnas: edad, pais, ingresos, tipo). Capa 3: $D(G(z))$ es el veredicto del discriminador sobre ese dato sintetico — un numero entre 0 y 1 que indica que tan convencido esta de que es real.

Duda 4: Como maneja el generador las variables categoricas si su salida es continua

Intuicion correcta del estudiante: "tendria que esculpir las etiquetas como numeros y despues convertirlos de vuelta".

Precision: el generador produce valores continuos via softmax (e.g., 0.82, 0.11, 0.07). Esos valores nunca son exactamente 0 y 1. El discriminador podria hacer trampa detectando esa diferencia sin analizar el contenido. CTGAN resuelve esto con gumbel-softmax (valores mas cercanos a one-hot durante entrenamiento) y argmax en la generacion final (conversion definitiva a 1,0,0).

Duda 5: Por que las distribuciones multimodales son problematicas — analogia de las montanas

Analogia del estudiante: "al intentar conectar 2 picos, el generador va a dejar masas de probabilidad donde no deberia haber nada, como si conectara dos cimas de montanas por un pequeno valle".

Validacion: analogia excelente y tecnicamente correcta. El generador es una funcion continua que mapea una distribucion unimodal (ruido gaussiano) a una multimodal. Inevitablemente genera muestras en los valles entre picos. Peor aun, puede tomar un atajo y colapsar a un solo modo (mode collapse). CTGAN resuelve esto con mode-specific normalization: un GMM detecta los modos y el generador recibe explicitamente la informacion de a que modo pertenece cada valor.

Duda 6: El colapso de modo con datos desbalanceados

Respuesta correcta del estudiante: "generaria solo clientes de Alemania y engañaria facilmente al discriminador".

Expansion: con 90% de datos de Alemania, el generador obtiene puntuaciones buenas del discriminador generando solo alemanes. CTGAN resuelve esto con conditional sampling: en cada lote se selecciona una categoria con muestreo uniforme (todas las categorias tienen igual probabilidad sin importar su frecuencia real) y se fuerza al generador a aprender ese subgrupo.

Duda 7: Por que TVAE necesita funciones de error diferentes por tipo de variable

Respuesta correcta del estudiante: "tendria que generar una medida de error diferente para cada variable".

Precision: para variables continuas se usa MSE (distancia numerica tiene sentido: edad 34 vs 35.2 = error de 1.2). Para categoricas se usa cross-entropy (no hay distancia numerica entre "DE" y "FR", solo probabilidad asignada a la categoria correcta). TVAE combina ambas en una perdida total sumando las contribuciones de cada tipo.

Duda 8: Por que el control estadistico del LLM es mas debil

Confusion inicial: se penso que era porque el LLM no modela la distribucion conjunta.

Aclaracion: el LLM si modela la conjunta (la regla de la cadena es matematicamente equivalente). El problema es practico, no teorico: (1) el LLM no fue entrenado con tus datos especificos — conoce patrones generales del idioma, no tu distribucion exacta; (2) genera en formato texto, donde la distribucion de tokens no corresponde a la distribucion estadistica de la variable; (3) no tiene mecanismo intrinseco de validacion (ni discriminador ni funcion de reconstruccion).

Duda 9: La distancia de Wasserstein se calcula para cada variable por separado

Pregunta clave del estudiante: "la distancia de Wasserstein calcula para cada variable?"

Aclaracion: si, en el contexto tabular se calcula variable por variable (igual que JSD y TVD para categoricas). Esto evalua distribuciones marginales pero no la conjunta. Para evaluar relaciones entre variables se necesitan metricas de utilidad practica (TSTR, TRTS) y matrices de correlacion. Por eso se dice que la evaluacion requiere una estrategia multidimensional: fidelidad marginal no implica fidelidad conjunta.

Duda 10: Criterio de seleccion entre CTGAN, TVAE y LLM

Sintesis del estudiante: CTGAN para fidelidad maxima a la distribucion real (colas pesadas, realismo). TVAE para capturar estructura global y generar valores intermedios via interpolacion en espacio latente. LLM para datos semanticos o generar datasets desde cero sin datos previos.

Matices anadidos: CTGAN ofrece maximo realismo pero a costa de estabilidad en el entrenamiento. TVAE no solo interpola sino que permite visualizar y comprender el proceso generativo (interpretabilidad). LLM es insustituible cuando los datos incluyen campos de texto libre que CTGAN/TVAE no pueden manejar.

— Fin de la Guia de Estudio del Tema 2 —