

Inteligencia Artificial Generativa Aplicada al Análisis de
Datos

Tema 1. Fundamentos de IA generativa. Modelos generativos aplicados al análisis de datos

Índice

Esquema


Ideas clave

- 1.1. Introducción y objetivos
- 1.2. Hitos históricos importantes
- 1.3. Diferencias entre modelos generativos y predictivos
- 1.4. Algunas arquitecturas: IA generativa, GAN, VAE, difusión, transformadores
- 1.5. Aplicaciones en análisis de datos
- 1.6. Métricas de evaluación
- 1.7. Limitaciones y desafíos actuales
- 1.8. Exploración práctica
- 1.9. Referencias bibliográficas

A fondo

Applications of Generative AI

Generative Artificial Intelligence: Fundamentals and Evolution



1.1. Introducción y objetivos

El panorama del análisis de datos está experimentando una evolución sin precedentes, impulsado por avances tecnológicos que no solo expanden nuestras capacidades, sino que también redefinen el rol del analista. Dentro de este dinamismo, la inteligencia artificial generativa (IA generativa) se consolida como una de las innovaciones más transformadoras, marcando un cambio fundamental en cómo extraemos valor y significado de los datos. Esta tecnología nos permite pasar de la interpretación a la creación de conocimiento y soluciones, especialmente en el contexto de la gestión y el análisis de conjuntos de datos.

La inteligencia artificial generativa es una rama de la inteligencia artificial que se enfoca en el desarrollo de sistemas capaces de crear contenido original, novedoso y coherente. Lo que distingue a la IA generativa es su principio fundamental: aprender de conjuntos de datos existentes y aprovechar ese conocimiento para producir contenido —a menudo muy creativo— que se asemeja mucho a los datos originales o los extrapola. A diferencia de los modelos de IA discriminativa (o predictiva), que aprenden a clasificar o predecir basándose en patrones de datos existentes, por ejemplo, etiquetar un correo electrónico como spam o predecir el precio de una acción, los modelos generativos aprenden de las distribuciones subyacentes y las estructuras de los datos de entrenamiento para generar nuevas instancias que se asemejan a los datos de entrenamiento (Almeida, 2023). Esta capacidad de generar a partir de lo aprendido es lo que la hace transformadora para el análisis de datos. En el ámbito del análisis de datos, esto se traduce en la capacidad de generar nuevos conjuntos de datos sintéticos, simular escenarios complejos o incluso llegar a automatizar la creación de informes y visualizaciones.

En esta línea, esperamos que al finalizar este tema, los participantes sean capaces de:

- ▶ Objetivo número 1: explorar algunos de los principios fundamentales de la IA generativa, incluido su funcionamiento, las arquitecturas clave y su distinción de la IA predictiva.
- ▶ Objetivo número 2: identificar algunos modelos generativos como GAN, VAE, y transformers en el contexto del análisis de datos.
- ▶ Objetivo número 3: reconocer el impacto y diversas aplicaciones de los modelos generativos en el ámbito del análisis de datos, con ejemplos prácticos.
- ▶ Objetivo número 4: describir algunas limitaciones y desafíos éticos y de seguridad asociados con la implementación de la IA generativa en entornos reales de análisis de datos.

1.2. Hitos históricos importantes

La evolución de la inteligencia artificial generativa y de la inteligencia artificial en general es una historia compleja e interconectada. Sus raíces se encuentran en disciplinas como la lingüística computacional, la estadística y la teoría de la información, que sentaron las bases para el procesamiento del lenguaje natural. A lo largo de las décadas, avances clave en algoritmos, potencia computacional y disponibilidad de datos impulsaron una transformación progresiva, desde sistemas basados en reglas hasta redes neuronales profundas. Este recorrido ha culminado en lo que conocemos hoy como modelos generativos de gran escala, entre los que se incluyen los transformadores, que han redefinido lo que entendemos por generación automática de texto, imagen, código y otras actividades. Cada etapa ha contribuido de manera significativa a la capacidad actual de las máquinas de generar contenido coherente, contextualizado y cercanamente humano.

La tabla 1 presenta algunos de los hitos más relevantes de manera resumida que han marcado el camino hacia este desarrollo.

Etapa	Hito principal	Año o período	Relevancia ampliada
Fundamentos lingüísticos.	Semántica moderna (Bréal, Saussure)	1883 - 1916.	Introducen los principios estructurales y semánticos del lenguaje, base para representar significado en PLN.
Origen de la IA.	<i>Test de Turing</i> , Perceptron, <i>Machine Learning</i> .	1950 -1960.	Nace la IA como disciplina formal; se exploran conceptos de inteligencia y aprendizaje automático.
Primeros sistemas.	ELIZA, PLN simbólico, modelos estadísticos IBM.	1966 - 1980.	Primeros intentos funcionales de interacción lenguaje-máquina; inicio del modelado probabilístico.
Transformación estadística.	LSTM, Word2Vec, CoreNLP.	1997 - 2013.	Transición clave del enfoque simbólico al vectorial; mejora en la memoria secuencial y representación semántica.
Revolución de modelos.	GANs, Transformer, BERT, GPT-2/3	2014 - 2020.	Emergencia de modelos generativos altamente escalables con comprensión contextual profunda y generación realista.
IA Generativa multimodal.	GPT-4, Gemini, Claude 3, Mistral Large	2023 - 2024.	Integración de múltiples modalidades (texto, imagen, audio); salto hacia una IA más general y flexible.

Tabla 1. Algunos hitos históricos relevantes que han dado origen a la IA generativa para el análisis de datos. Fuente: elaboración propia.

1.3. Diferencias entre modelos generativos y predictivos

Para apreciar el valor distintivo de la IA generativa en el análisis de datos, es esencial distinguirla de la IA predictiva o discriminativa, que ha sido el pilar de gran parte de la analítica avanzada y el aprendizaje automático hasta ahora.

En la tabla 2 se muestra la comparativa de IA predictiva y IA generativa en el análisis de datos.

Característica	IA predictiva (discriminativa)	IA generativa
Función principal.	Clasificación y predicción: estima un resultado futuro o clasifica datos existentes en categorías predefinidas.	Generación y creación: produce contenido completamente nuevo, aprendiendo la distribución de los datos de entrada.
Tareas comunes.	Regresión (prever ventas), clasificación (detección de fraude), <i>forecasting</i> (previsión de demanda), <i>clustering</i> (segmentación).	Generación de texto (resúmenes, código SQL), imágenes sintéticas, audio, datos simulados, escenarios hipotéticos.
Pregunta clave.	«¿Qué es probable que suceda?» o «¿A qué categoría pertenece esto?».	«¿Qué contenido puedo crear que se ajuste a este patrón?» o «¿Cómo podría ser algo nuevo que siga estas reglas?».
Salida típica.	Valores numéricos, etiquetas discretas, probabilidades, predicciones de clases.	Textos estructurados, imágenes, audio, código, conjuntos de datos simulados.
Valor en análisis de datos.	Identifica patrones ocultos, automatiza decisiones, realiza estimaciones informadas (ej.: clientes con alto riesgo de abandono).	Automatiza tareas creativas y análisis profundo (ej.: generar resúmenes ejecutivos o consultas SQL a partir de lenguaje natural).

Tabla 2. Comparativa de IA Predictiva vs. IA Generativa en el análisis de datos. Fuente: elaboración propia.

Mientras la IA predictiva es fundamental para comprender patrones y hacer pronósticos, la IA generativa abre la puerta a la creación activa de «artefactos» de datos y conocimientos, revolucionando la eficiencia y el alcance del analista (Boonstra, 2024). Es importante señalar que modelos como BERT (Devlin *et al.*, 2019), si bien son predominantemente discriminativos por su naturaleza de codificador, sentaron las bases para técnicas de preentrenamiento que benefician enormemente a los LLM generativos.

1.4. Algunas arquitecturas: IA generativa, GAN, VAE, difusión, transformadores

La capacidad de la IA generativa se basa en distintas arquitecturas de modelos, cada una con sus fortalezas y principios de funcionamiento únicos, con aplicaciones específicas en el ámbito del análisis de datos. A continuación, describimos algunas de las más destacadas.

Redes generativas antagónicas (GAN)

Consisten en dos redes neuronales que compiten entre sí en un «juego de suma cero» (Goodfellow *et al.*, 2016). Es decir, constan de dos redes: un generador y un discriminador, que se entrenan simultáneamente. El generador crea datos falsos que se asemejan a los datos de entrenamiento, mientras que el discriminador intenta distinguir entre datos reales y falsos.

- ▶ Un **Generador (G)**: Crea nuevos datos aleatorios, intentando imitar la distribución de los datos reales.
- ▶ Un **Discriminador (D)**: Es una red clasificadora que intenta distinguir entre los datos reales y los datos generados por G.

Este juego antagónico lleva al generador a producir datos cada vez más realistas, hasta que el discriminador no puede diferenciar de manera fiable los datos reales de los generados.

Se utilizan ampliamente para la generación y manipulación de imágenes, como la creación de imágenes fotorrealistas, la generación de arte y, más recientemente, los *deepfakes*.

Aplicación en Análisis de Datos: Principalmente para la generación de datos sintéticos que imitan las características estadísticas de los datos reales. Esto es invaluable para:

- ▶ Aumentar conjuntos de datos escasos, aumento de datos, especialmente en escenarios de desequilibrio de clases.
- ▶ Proteger la privacidad al permitir el trabajo con datos sensibles sin exponer los originales.
- ▶ Simular escenarios hipotéticos y generar datos para pruebas y validación de modelos.
- ▶ Generación de imágenes para visualización de datos o simulación de escenarios visuales.

Autoencoders Variacionales (VAE)

Son un tipo de red neuronal que aprende a codificar datos de entrada en una representación latente (un espacio de menor dimensión) y luego a decodificar esa representación para reconstruir los datos originales. En los autoencoders variacionales (VAE), la naturaleza «variacional» se refiere a que, en lugar de codificar cada dato como un punto fijo, el modelo lo representa como una distribución de probabilidad (normalmente gaussiana). Esto introduce una aleatoriedad controlada, es decir, cada vez que se genera una muestra, se extrae un valor distinto de esa distribución, lo que permite crear múltiples variantes realistas. Gracias a esta propiedad, el modelo puede explorar de forma continua el espacio latente, una representación comprimida y estructurada del conocimiento aprendido, generando nuevas muestras coherentes pero distintas a las originales. En resumen, los VAE son un tipo de autocodificador que genera nuevos puntos de datos: funcionan codificando los datos de entrada en un espacio latente y decodificándolos a partir de este espacio para reconstruir la entrada. El aspecto variacional introduce un giro probabilístico que permite la generación de nuevos datos (Cronin, 2024).

Aplicación en Análisis de Datos: Son muy útiles para:

- ▶ Una de las ventajas de los modelos generativos, como los VAE, es que permiten crear datos sintéticos con control sobre sus características. Esto se debe a que el espacio latente —la representación interna de los datos— es interpretable, lo que significa que podemos modificar dimensiones específicas de ese espacio latente para generar variaciones deseadas, como cambiar el tamaño, el estilo o el tono del dato generado.
- ▶ La imputación de valores faltantes al poder «adivinar» datos faltantes basándose en el patrón aprendido de los datos completos.
- ▶ Reducción de la dimensionalidad y detección de anomalías al identificar puntos que se desvían de la distribución aprendida en el espacio latente.

Modelos de difusión (diffusion models)

Los modelos de difusión representan uno de los avances más recientes y potentes en IA generativa. Su funcionamiento se basa en aprender a invertir un proceso de difusión, que consiste en añadir ruido de forma progresiva a los datos reales hasta convertirlos en ruido puro. Una vez entrenados, estos modelos pueden partir de una simple muestra de ruido (como ruido gaussiano) y reconstruir datos nuevos de alta calidad, como imágenes, audio o texto, con gran nivel de detalle. El proceso de entrenamiento implica dos fases:

Forward Diffusion (Proceso de Ruido): Se añade ruido gaussiano de forma incremental a los datos de entrada en una serie de pasos.

Reverse Diffusion (Proceso de Denoising): El modelo aprende a revertir este proceso, **desruidificando** las muestras paso a paso hasta recuperar la imagen original (o dato original). En la inferencia, el modelo genera datos partiendo de ruido y aplicando este proceso inverso.

Aplicación en Análisis de Datos: Aunque inicialmente populares para la generación de imágenes y videos (ej. DALL-E, Midjourney), su capacidad para manejar datos complejos los está extendiendo a:

- ▶ La síntesis de datos estructurados complejos y datos tabulares, ofreciendo alta fidelidad a la distribución real.
- ▶ La generación de series temporales con patrones realistas.
- ▶ El aumento de datos para diversos dominios.

Modelos basados en transformers

Los transformers son la arquitectura central en los modelos de lenguaje más avanzados de la actualidad, como GPT o BERT. Introducidos por Vaswani *et al.* (2017) con el artículo «Attention Is All You Need», revolucionaron el procesamiento del lenguaje natural (PLN) al reemplazar mecanismos secuenciales por uno completamente nuevo: la autoatención. Este mecanismo permite al modelo analizar cada palabra (o elemento) de una secuencia en relación con todas las demás al mismo tiempo, sin depender del orden secuencial típico de las redes recurrentes (RNN).

Gracias a esto, los transformers pueden capturar relaciones entre palabras o conceptos que están muy separados en el texto, algo que las arquitecturas anteriores no lograban con eficacia. Por ejemplo, en una frase larga como «El libro que compré hace dos semanas, aunque un poco complejo, me pareció fascinante», el modelo puede vincular correctamente «libro» con «fascinante», ignorando la distancia entre ellas.

Además, como procesan todos los elementos en paralelo, son mucho más eficientes para el entrenamiento con grandes volúmenes de datos. Esta combinación de capacidad para comprender relaciones de largo alcance y eficiencia computacional los hace especialmente potentes en tareas como la traducción automática, la generación de texto coherente, los resúmenes automáticos y la clasificación semántica de frases o documentos, superando ampliamente a las arquitecturas anteriores tanto en calidad como en escalabilidad.

Aplicación en Análisis de Datos: Son excelentes para generar y comprender texto, lo que los hace vitales para:

- ▶ Generación de consultas y código («de texto a SQL/código»): traducir preguntas de negocio en lenguaje natural a código ejecutable: SQL, Python y R, y democratizar el acceso a los datos (Boonstra, 2024).
- ▶ Resumen y análisis de datos textuales: sintetizar rápidamente grandes volúmenes de texto (feedback de clientes, informes, transcripciones) y extraer puntos clave, sentimientos o temas recurrentes.
- ▶ Generación de narrativa analítica: a partir de resultados numéricos, tablas o gráficos, generar un texto que explique los hallazgos clave, tendencias, anomalías y recomendaciones de negocio.
- ▶ Asistencia en el preprocesamiento y limpieza de datos: identificar inconsistencias, sugerir correcciones y generar código para transformaciones de datos.
- ▶ Explicabilidad de modelos (XAI): generar descripciones en lenguaje natural que expliquen el funcionamiento interno de un modelo predictivo, sus predicciones o la importancia de sus características. Es decir, los transformers, por sí solos, no explican modelos predictivos ni calculan la importancia de variables, pero sí son muy eficaces para generar explicaciones comprensibles en lenguaje natural una vez que se les proporciona la información adecuada (desde modelos como SHAP, LIME y análisis estadístico). Es una combinación muy potente en herramientas de IA explicable modernas.

1.5. Aplicaciones en análisis de datos

La IA generativa ofrece un abanico de aplicaciones prácticas que están redefiniendo el ecosistema del análisis de datos, y trasciende la mera generación de imágenes o texto, como se vio en el apartado anterior sobre las aplicaciones de cada método. Con esto no se busca reemplazar la pericia del analista, sino potenciarla exponencialmente para liberarlo de las tareas más tediosas y rutinarias. Esto permite al analista concentrarse en la estrategia, la interpretación profunda, la validación crítica y la comunicación efectiva del valor derivado de los datos.

A continuación, se presenta una tabla que resume algunas de las principales aplicaciones de la inteligencia artificial generativa en el ámbito del análisis de datos. Cada una de estas aplicaciones representa una forma distinta en que los modelos generativos pueden aportar valor, ya sea por medio de la creación de nuevos datos, la automatización de tareas analíticas, la generación de contenido explicativo o la mejora de la transparencia de los modelos predictivos. La tabla 3 organiza estas capacidades según su función principal y los beneficios que ofrecen en entornos reales de trabajo con datos.

Aplicación	Función principal	Beneficios clave
Generación de datos sintéticos.	Crear datos artificiales coherentes con los reales.	Protección de datos sensibles; entrenamiento sin datos reales.
Aumento de <i>datasets</i> .	Generar más ejemplos para modelos de aprendizaje automático.	Mejora del rendimiento en contextos con datos escasos o desbalanceados.
Simulación de escenarios.	Producir datos hipotéticos para análisis de riesgo o planificación estratégica.	Evaluación de situaciones <i>what if</i> .
Preparación y limpieza de datos.	Automatizar transformaciones, correcciones y reestructuración de datos.	Ahorro de tiempo; reducción de errores manuales.
Generación de código y consultas (NL2SQL/NL2Code).	Traducir preguntas en lenguaje natural a código estructurado (SQL, Python, R, etc.).	Democratización del análisis; acceso sin conocimientos técnicos.
Narrativa analítica (NLG).	Crear resúmenes automáticos y explicaciones de los hallazgos analíticos.	Mejora de la comprensión por parte de usuarios no técnicos.

Tabla 3. Aplicaciones de la IA Generativa en el Análisis de Datos. Fuente: elaboración propia.

1.6. Métricas de evaluación

Evaluar la calidad de los datos o del contenido generado por modelos generativos es un desafío. Las métricas se centran en la fidelidad de las muestras, la diversidad o la variedad de las muestras generadas. Para evaluar la calidad de los datos generados por modelos de IA generativa, es necesario utilizar métricas específicas adaptadas al tipo de dato. La tabla 4 resume las más relevantes, agrupadas por dominio: imágenes, texto y datos tabulares. Estas métricas permiten medir aspectos como la fidelidad al conjunto original, la diversidad de resultados, la utilidad práctica para modelos predictivos y el cumplimiento de criterios de privacidad.

Tipo de Dato	Métricas clave	¿Qué evalúan?	Interpretación general
Imágenes	<i>Inception score (IS), Fréchet inception distance (FID), Precision y Recall</i> (cuán bien un modelo generativo cubre el espacio de datos reales sin generar muestras irreales o fuera de distribución) y <i>Perceptual metrics</i> .	Calidad, diversidad y realismo de las imágenes generadas.	IS alto y FID bajo indican imágenes realistas y variadas.
Texto	Perplejidad, BLEU, ROUGE, BERTScore, Evaluación humana.	Fluidez, coherencia, similitud semántica con texto de referencia.	Métricas altas indican mejor alineación con lenguaje natural.
Datos tabulares	Estadísticas descriptivas, correlaciones, visualización (PCA/t-SNE), utilidad en modelos, privacidad (<i>membership Attack</i>).	Fidelidad estadística, preservación de relaciones entre variables, utilidad práctica y privacidad.	Similitud estadística y rendimiento comparable indican buena calidad.

Tabla 4. Principales métricas para evaluar modelos generativos. Fuente: elaboración propia.

1.7. Limitaciones y desafíos actuales

Si bien la IA generativa ofrece un potencial inmenso para el análisis de datos, su implementación viene acompañada de importantes consideraciones éticas y desafíos iniciales. A continuación, mencionamos algunos:

- ▶ **Sesgos (bias amplification):** los modelos generativos pueden amplificar y replicar sesgos presentes en los datos de entrenamiento, lo que podría llevar a la generación de datos sintéticos o narrativas que perpetúen discriminaciones existentes (p. ej., en datos financieros o de recursos humanos). Es crucial su detección en aplicaciones sensibles.
- ▶ **Transparencia y explicabilidad (XAI):** los modelos generativos complejos a menudo funcionan como «cajas negras», lo que dificulta comprender cómo llegan a sus resultados de generación o análisis de datos y por qué. Esto es un obstáculo para la confianza y la auditabilidad en sistemas basados en datos.
- ▶ **Privacidad y seguridad de datos:** existen riesgos asociados con la generación de datos. Por ejemplo, los modelos pueden «memorizar» datos sensibles del conjunto de datos original, lo que podría llevar a la fuga de información si los datos sintéticos no están debidamente anonimizados.
- ▶ **Uso indebido (misinformation/disinformation):** la capacidad de generar datos realistas (deepfakes, textos falsos, datos fabricados) podría ser explotada para crear desinformación, manipular mercados o fabricar evidencias.
- ▶ **Costos computacionales:** el entrenamiento y la operación de modelos generativos a gran escala, especialmente con conjuntos de datos masivos, requieren recursos computacionales significativos (GPU, TPU), lo que puede ser una barrera para organizaciones más pequeñas.

- ▶ **Modo de fallo:** los modelos generativos pueden producir «alucinaciones» o resultados incoherentes o sin sentido, especialmente cuando se les pide generar contenido fuera de su distribución de entrenamiento o con prompts ambiguos.
- ▶ **Evaluación rigurosa:** como se vio en la sección 1.6, evaluar la calidad y utilidad de los resultados generados puede ser complejo y a menudo requiere una combinación de métricas automáticas y evaluación humana.

1.8. Exploración práctica

Caso práctico: generación de datos sintéticos para mejorar un modelo de riesgo crediticio

Deseamos mostrar cómo aplicar IA Generativa, específicamente el modelo CTGAN (*Conditional Tabular Generative Adversarial Network* - una arquitectura basada en redes generativas adversarias (GANs) diseñada específicamente para generar datos sintéticos tabulares), para aumentar un conjunto de datos con eventos raros o poco frecuentes (como impagos), mejorando así el entrenamiento de modelos predictivos en contextos financieros con restricciones de privacidad. No pueden compartir los datos originales por cuestiones de **protección de datos**. Por eso, buscan generar **datos sintéticos** realistas para mejorar su modelo sin comprometer la privacidad.

La entidad financiera ficticia “**Crédito Seguro**” quiere predecir el riesgo de impago. Su dataset histórico contiene muy pocos casos de impago, lo que limita la capacidad de los modelos para aprender patrones útiles.

Importar datos:

Import pandas as pd

```
# Datos reales simplificados (todos casos de impago)
datos_reales = pd.DataFrame([
    {'ID': 'P003', 'Monto Préstamo (€)': 5000, 'Tasa Interés (%)': 12.0, 'Historial Pagos (0-5)': 1,
    'Ingresos Anuales (€)': 28000, 'Días Atraso Últ. Pago': 45, 'Impago (Sí/No)': 'Sí'},
    {'ID': 'P005', 'Monto Préstamo (€)': 9000, 'Tasa Interés (%)': 10.5, 'Historial Pagos (0-5)': 2,
    'Ingresos Anuales (€)': 35000, 'Días Atraso Últ. Pago': 60, 'Impago (Sí/No)': 'Sí'},
    {'ID': 'P009', 'Monto Préstamo (€)': 6500, 'Tasa Interés (%)': 11.5, 'Historial Pagos (0-5)': 1,
    'Ingresos Anuales (€)': 32000, 'Días Atraso Últ. Pago': 50, 'Impago (Sí/No)': 'Sí'},
```

```
{'ID': 'P014', 'Monto Préstamo (€)': 7000, 'Tasa Interés (%)': 11.0, 'Historial Pagos (0-5)':
1,
  'Ingresos Anuales (€)': 29000, 'Días Atraso Últ. Pago': 65, 'Impago (Sí/No)': 'Sí'},
{'ID': 'P018', 'Monto Préstamo (€)': 9500, 'Tasa Interés (%)': 10.0, 'Historial Pagos (0-5)':
2,
  'Ingresos Anuales (€)': 37000, 'Días Atraso Últ. Pago': 40, 'Impago (Sí/No)': 'Sí'}
])
```

Generación de Datos Sintéticos con CTGAN

Pip install sdv

```
from sdv.tabular import CTGAN
```

```
# Preprocesar datos
```

```
datos_reales_ctgan = datos_reales.drop(columns=['ID'])
```

```
datos_reales_ctgan['Impago (Sí/No)'] = datos_reales_ctgan['Impago (Sí/No)'].astype(str)
```

```
# Entrenar modelo generador
```

```
modelo_ctgan = CTGAN(epochs=500)
```

```
modelo_ctgan.fit(datos_reales_ctgan)
```

```
# Generar 100 registros sintéticos
```

```
datos_sinteticos = modelo_ctgan.sample(100)
```

```
# Mostrar ejemplo de salida
```

```
print(datos_sinteticos.head())
```

Validación Visual de Datos Sintéticos: Comparación de distribuciones

Import matplotlib.pyplot as plt

Import seaborn as sns

```
# Comparar variables clave entre reales y sintéticos
```

```
fig, axes = plt.subplots(2, 2, figsize=(12, 10))
```

```
fig.suptitle('Distribuciones Reales vs Sintéticas (Impago)', fontsize=14)
```

```
# Monto
```

```
sns.histplot(datos_reales['Monto Préstamo (€)'], kde=True, color='blue', ax=axes[0, 0],
label='Reales')
```

```
sns.histplot(datos_sinteticos['Monto Préstamo (€)'], kde=True, color='orange', ax=axes[0,
0], label='Sintéticos')
```

```
axes[0, 0].set_title('Monto Préstamo')
```

```
axes[0, 0].legend()
```



```
# Tasa
sns.histplot(datos_reales['Tasa Interés (%)'], kde=True, color='blue', ax=axes[0, 1])
sns.histplot(datos_sinteticos['Tasa Interés (%)'], kde=True, color='orange', ax=axes[0, 1])
axes[0, 1].set_title('Tasa Interés')

# Ingresos
sns.histplot(datos_reales['Ingresos Anuales (€)'], kde=True, color='blue', ax=axes[1, 0])
sns.histplot(datos_sinteticos['Ingresos Anuales (€)'], kde=True, color='orange', ax=axes[1, 0])
axes[1, 0].set_title('Ingresos Anuales')

# Atrasos
sns.histplot(datos_reales['Días Atraso Últ. Pago'], kde=True, color='blue', ax=axes[1, 1])
sns.histplot(datos_sinteticos['Días Atraso Últ. Pago'], kde=True, color='orange',
ax=axes[1, 1])
axes[1, 1].set_title('Días Atraso')

plt.tight_layout()
plt.subplots_adjust(top=0.9)
plt.show()
```

En resumen

El modelo CTGAN intenta aprender patrones de un conjunto muy reducido y generar datos realistas.

El conjunto de datos sintético puede usarse para entrenar un modelo predictivo más equilibrado.


Las validaciones visuales y estadísticas ayudan a confirmar que los datos generados conservan las propiedades del original.

Esto ayuda a entrenar modelos sin compartir información sensible y a cumplir las normativas de privacidad.

Durante la elaboración del tema se empleó un modelo de IA generativa como herramienta de apoyo para optimizar la redacción y precisar conceptos técnicos. Su uso se llevó a cabo con responsabilidad y criterio académico mediante múltiples

iteraciones de consulta, análisis y reformulación que, con la debida pericia, permitieron ajustar las respuestas con rigor y precisión al contexto específico del contenido desarrollado (OpenAI, 2025). Este uso complementario no sustituyó la consulta de fuentes académicas ni el ejercicio de construcción intelectual, sino que buscó reforzar la calidad y la claridad en el marco de una práctica académica transparente y ética.

En el vídeo, *Evolución histórica de la IA generativa*, veremos una exploración de los hitos clave en la evolución de la IA generativa, desde los primeros modelos estadísticos, *perceptron* hasta los LLM actuales. Se destacan las contribuciones de GANs, Transformers y Diffusion Models.



Accede al vídeo:

<https://unir.cloud.panopto.eu/Panopto/Pages/Embed.aspx?id=04a69005-1743-4d03-8441-b34b0163cf07>

1.9. Referencias bibliográficas

Almeida, I. (2023). *Artificial intelligence fundamentals for business leaders: up to date with generative AI*. Now Next Later AI.

Boonstra, L. (2024). *Prompt engineering*. Google. <https://archive.org/details/22365-3-prompt-engineering-v-7/mode/2up>

Cronin, I. (2024). Introduction to the world of generative AI. In *Understanding generative AI business applications*. Apress. https://doi.org/10.1007/979-8-8688-0282-9_1

Devlin, J., Chang, M. W., Lee, K. y Toutanova, K. (2019). BERT: pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)* (pp. 4171-4186). <https://aclanthology.org/N19-1423/>

Goodfellow, I., Bengio, Y. y Courville, A. (2016). *Deep learning*. MIT Press. https://www.researchgate.net/publication/320703571_Ian_Goodfellow_Yoshua_Bengio_and_Aaron_Courville_Deep_learning_The_MIT_Press_2016_800_pp_ISBN_0262_035618

OpenAI. (2025). ChatGPT (Jun 25 version) [Large language model]. <https://chat.openai.com/>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L y Polosukhin, I. (2017). *Attention is all you need*. Advances in Neural Information Processing Systems, 30. <https://arxiv.org/pdf/1706.03762>

Applications of Generative AI

Lyu, Z. (Ed.). (2024). *Applications of generative AI*. Springer Nature.
<https://doi.org/10.1007/978-3-031-46238-2>

Este libro ofrece una visión amplia y actualizada de las aplicaciones prácticas de la IA generativa en el análisis de datos en múltiples sectores (salud, finanzas, educación, etc.). También ilustra los retos éticos y regulatorios emergentes.

Generative Artificial Intelligence: Fundamentals and Evolution

Mallikarjuna, B., y Chittamsetty, P. (2024). Generative artificial intelligence: Fundamentals and evolution. In Raza, K., Ahmad, N y Singh, D. (Eds.), *Generative AI: Current trends and applications*, 1177. Springer. https://doi.org/10.1007/978-981-97-8460-8_1

Este capítulo establece las bases técnicas que sustentan el uso de modelos generativos (como GAN y VAE) en análisis de datos.