

Inteligencia Artificial Generativa Aplicada al Análisis de
Datos

Tema 4. Automatización del análisis con IA generativa. Generación de insights automatizados y detección de patrones

Índice

Esquema


Ideas clave

- 4.1. Introducción y objetivos
- 4.2. Generación de insights con LLM
- 4.3. Análisis exploratorio automatizado
- 4.4. Visualización con herramientas como Power BI, Looker o Tableau Pulse
- 4.5. Identificación de patrones y correlaciones
- 4.6. Integración con notebooks y dashboards
- 4.7. Evaluación de utilidad de los insights
- 4.8. Exploración práctica: caso de análisis automatizado con IA generativa sobre datos de pingüinos
- 4.9. Referencias bibliográficas

A fondo

Una propuesta de marco novedoso para generar insights automatizados

Manual de Instrucciones de los agentes analíticos



4.1. Introducción y objetivos

En este tema abordamos la aplicación de la inteligencia artificial generativa, especialmente de los modelos de lenguaje de gran escala (LLMs) para automatizar tareas analíticas avanzadas. A diferencia de otros temas, donde el foco estaba en la preparación y generación de datos, aquí exploramos cómo estos modelos pueden transformar datos en bruto en hallazgos útiles, visualizaciones y narrativas, reduciendo la intervención manual y acelerando los ciclos de análisis.

Este enfoque da lugar al concepto de analista aumentado: un profesional respaldado por IA generativa, capaz de automatizar la exploración, el descubrimiento de patrones, la comunicación de hallazgos y la generación de reportes personalizados mediante lenguaje natural. Esta evolución no implica reemplazo, sino potenciación de habilidades. Los LLMs y sus agentes no solo permiten automatizar scripts, sino que también priorizan la comprensión del contexto y la utilidad del análisis, así generan valor estratégico a partir de datos.

A lo largo del tema, también se señalan algunas herramientas y entornos de despliegue que permiten integrar estos modelos en flujos de análisis. Se pondrá especial atención a la capacidad de los LLMs para detectar relaciones relevantes, enriquecer visualizaciones y evaluar la solidez de los hallazgos generados.

Al finalizar este tema, el estudiante será capaz de:

- ▶ Objetivo 1: generar y validar resultados a partir de datos estructurados, utilizando LLMs, principalmente a nivel programático.
- ▶ Objetivo 2: automatizar herramientas de análisis exploratorio y de visualización, mediante lenguaje natural con integración en notebooks, reportes y herramientas BI.
- ▶ Objetivo 3: conocer herramientas de evaluación de la fiabilidad, relevancia y aplicabilidad de los hallazgos producidos automáticamente por sistemas generativos.

4.2. Generación de insights con LLM

Uno de los avances más significativos que ofrece la IA generativa en el análisis de datos es la capacidad de los grandes modelos de lenguaje (LLM), como ChatGPT, LLaMa, Gemini o Claude, para interpretar directamente conjuntos de datos estructurados y devolver hallazgos relevantes en lenguaje natural. Este enfoque, conocido como *Text-to-Insight*, transforma el rol tradicional del analista: ya no es necesario programar cada paso del análisis exploratorio, sino que basta con formular preguntas o instrucciones, y el modelo responde con interpretaciones, patrones y anomalías.

Estos modelos son capaces de razonar sobre tablas como lo haría un humano, reconociendo tendencias, comparaciones entre grupos, comportamientos atípicos y relaciones implícitas. Esta capacidad es particularmente útil en las fases iniciales de análisis, en las que se desea obtener una visión general del comportamiento de los datos o generar primeras hipótesis de trabajo.

Para ilustrar esta funcionalidad, consideremos un escenario profesional en el que un analista desea obtener un resumen automatizado, de por ejemplo, el comportamiento de ventas por región. En lugar de escribir múltiples líneas de código para agrupar, calcular promedios o detectar anomalías, puede apoyarse en una herramienta como LangChain para conectar un LLM con un DataFrame de pandas y solicitar los *insights* directamente mediante lenguaje natural. A continuación, se muestra cómo sería un ejemplo en Python que realiza esta tarea:

```
# Instalación previa: pip install openai langchain pandas python-dotenv
import os
import pandas as pd
from langchain.llms import OpenAI
from langchain.agents import create_pandas_dataframe_agent
from dotenv import load_dotenv
# Carga de la clave API desde archivo .env
load_dotenv()
```

```
llm = OpenAI(temperature=0, openai_api_key=os.getenv("OPENAI_API_KEY")) # temperature=0 →
Respuesta más determinista y precisa
# Dataset simulado
data = {
    "region": ["Norte", "Sur", "Norte", "Este", "Oeste", "Sur", "Este", "Oeste", "Norte", "Sur"],
    "ventas": [12000, 9500, 14000, 7000, 6200, 10500, 7200, 6800, 13500, 11000],
    "mes": ["Enero", "Enero", "Febrero", "Febrero", "Febrero", "Marzo", "Marzo", "Marzo", "Abril", "Abril"]
}
df = pd.DataFrame(data)
# Crear agente conectado al DataFrame
agente = create_pandas_dataframe_agent(llm, df, verbose=True)
# Consultar en lenguaje natural
respuesta = agente.run("Resume las tendencias clave del dataset de ventas por región, señalando
anomalías.")
print(respuesta)
```

Una observación importante; para ejecutar este código se podría contar con una clave de API de [OpenAI](#). Y para mayor seguridad, se recomienda almacenarla en un archivo *env* con la línea:

```
OPENAI_API_KEY=sk-tu-clave-aquí
```

Este archivo se puede cargar automáticamente con la función `load_dotenv()`. Evita exponer la clave de acceso en el código fuente y garantiza una práctica segura en entornos colaborativos.

Una posible respuesta generada por el modelo podría ser:

«La región Norte lidera en volumen de ventas, con un repunte notable en febrero y abril. La región Sur muestra un crecimiento moderado. En cambio, las regiones Este y Oeste presentan volúmenes consistentemente bajos. Se detecta una posible anomalía en el descenso brusco de la región Este durante febrero, que podría estar asociado a un evento puntual».

Este tipo de interacción puede adaptarse fácilmente a nuevas preguntas: comparar la varianza entre regiones, analizar estacionalidades y preparar un resumen para una presentación. La integración con notebooks y sistemas de *business intelligence* permite que este proceso se integre directamente en flujos de trabajo. Además, este enfoque es especialmente útil cuando se trabaja con usuarios poco técnicos, ya que permite traducir datos complejos a un lenguaje comprensible. También se convierte en una herramienta para la generación de informes preliminares automatizados, ideal en contextos empresariales con alto volumen de análisis.

4.3. Análisis exploratorio automatizado

El análisis exploratorio de datos (EDA, por sus siglas en inglés, *exploratory data analysis*) es la primera etapa crítica en cualquier proyecto de ciencia de datos. Su objetivo es comprender la estructura, la distribución, las correlaciones y las posibles anomalías del conjunto de datos antes de aplicar modelos predictivos o técnicas más complejas. Tradicionalmente, este análisis requería una combinación de estadísticas descriptivas, visualización interactiva y algo de experiencia en programación.

La IA generativa y particularmente los LLM conectados a entornos de ejecución permiten automatizar gran parte de este proceso, reduciendo drásticamente el tiempo necesario para generar *insights* iniciales y facilitando una exploración guiada en lenguaje natural. Esta capacidad es parte de lo que se conoce como «EDA aumentado», donde los modelos no solo ejecutan comandos, sino que también interpretan sus resultados y proponen siguientes pasos analíticos.

Los LLM pueden integrarse con bibliotecas como pandas, seaborn o matplotlib mediante frameworks como LangChain, PandasAI, DSPy u OpenAI Code Interpreter, que permiten a los modelos leer directamente un DataFrame y ejecutar instrucciones. Un ejemplo de esto lo podemos ver con el siguiente prompt para un dataset dado:

«Genera un análisis exploratorio completo: describe las variables, encuentra outliers y muestra las correlaciones más fuertes.»

Este enfoque permite iterar análisis exploratorios, conversacionales y reproducibles con solo modificar o refinar el prompt. Un ejemplo con LangChain y LLM se observa con lo siguiente:

```
# pip install pandas openai langchain python-dotenv matplotlib seaborn

import pandas as pd
import os
from dotenv import load_dotenv
from langchain.llms import OpenAI
from langchain.agents import create_pandas_dataframe_agent

# Carga tu clave de API desde .env (OPENAI_API_KEY)
load_dotenv()
llm = OpenAI(temperature=0, openai_api_key=os.getenv("OPENAI_API_KEY"))

# Cargar dataset real desde Plotly
url = "https://raw.githubusercontent.com/plotly/datasets/master/diabetes.csv"
df = pd.read_csv(url)

# Crear agente con el DataFrame
agente = create_pandas_dataframe_agent(llm, df, verbose=True)

# Prompt para EDA automatizado
prompt_eda = """
Realiza un análisis exploratorio completo: estadísticas, correlaciones relevantes, variables numéricas
con alta varianza,
detección de outliers y recomendaciones para limpieza de datos.
"""

respuesta = agente.run(prompt_eda)
print(respuesta)
```

Como alternativa más tradicional, además del enfoque basado en LLM, existen librerías y frameworks que permiten una exploración automatizada y profunda con mínima codificación. Mencionamos un par de ellas: por ejemplo:

- ▶ **Pandas_profiling (ahora y data-profiling):** genera informes HTML interactivos con estadísticas, histograma por variable, análisis de correlaciones, duplicados, alertas de calidad y distribución de valores nulos.
- ▶ **Sweetviz:** herramienta visual muy útil para comparar datasets (por ejemplo, entrenamiento vs prueba), resalta diferencias significativas y propone acciones.
- ▶ **Autoviz:** una librería que crea automáticamente visualizaciones ricas para variables numéricas, categóricas y correlaciones, sin necesidad de parametrización compleja.

Por su parte, herramientas como Google Looker Studio, Power BI y Tableau Pulse permiten construir paneles de EDA automatizados, conectados a canalizaciones o cuadernos, integrando visualizaciones interactivas con análisis estadístico básico. Algunos de estos sistemas ya pueden utilizar autoinsights impulsados por IA, como Tableau Pulse o Power BI Copilot (Microsoft, 2024).

De esta manera, el análisis automatizado de datos permite acelerar la toma de decisiones en sectores como la salud, las finanzas o el marketing, donde cada conjunto de datos requiere exploración inmediata para priorizar acciones. Las empresas que implementan estos sistemas en sus canalizaciones logran una mejora significativa en la eficiencia analítica y la detección temprana de problemas de calidad o anomalías operativas.

Por ejemplo, en un sistema de detección de fraude, una canalización con EDA automático puede alertar sobre cambios en la distribución de importes, el origen de las transacciones y otros hallazgos. Esto desencadena procesos de validación o recalibración del modelo.

Sin embargo, aunque el EDA automatizado representa un gran avance, no reemplaza el juicio experto. Los modelos pueden omitir patrones sutiles o generar sugerencias irrelevantes si los datos contienen errores sistemáticos o falta de contexto. Por ello, debe combinarse siempre con validación manual, revisión crítica y documentación de decisiones.

4.4. Visualización con herramientas como Power BI, Looker o Tableau Pulse

La visualización de datos es una de las etapas más críticas del proceso analítico y la incorporación de modelos de lenguaje (LLM) ha transformado su alcance. La visualización de datos está experimentando una revolución con la llegada de herramientas de Business Intelligence generativa, también conocidas como Generative BI. Esta nueva generación de plataformas no solo permite crear gráficos y dashboards, sino que también incorpora LLM directamente en su interfaz, transformando la forma en que se consulta, interpreta y comunica la información de forma visual.

Herramientas como Power BI Copilot, Tableau Pulse y Looker con Gemini representan este cambio de paradigma. Permiten a los usuarios generar visualizaciones complejas, explicaciones automáticas y métricas derivadas utilizando instrucciones en lenguaje natural, sin necesidad de conocer código como DAX (*data analysis expressions*), un lenguaje de fórmulas para realizar cálculos y análisis de datos, SQL o LookML. Esta capacidad democratiza el acceso a la analítica avanzada y reduce la brecha entre usuarios técnicos y no técnicos.

Desde una perspectiva estratégica, la Generative BI ofrece ventajas sustanciales. La democratización del análisis permite que perfiles no técnicos, por ejemplo, responsables de marketing o gestión comercial de las compañías, accedan directamente a *insights* visuales complejos. El tiempo de obtención de *insights* se reduce drásticamente: tareas que antes requerían colaboración con equipos técnicos ahora se resuelven en minutos. Además, la narrativa contextual automática que ofrecen los LLM permite explicar no solo «qué ha pasado», sino también por qué ha pasado, con lenguaje humano. Las visualizaciones se ven reforzadas mediante interfaces conversacionales y asistentes virtuales dentro de los propios paneles, lo que facilita la toma de decisiones basada en datos.

No obstante, esta revolución aún enfrenta limitaciones relevantes. Estas herramientas requieren modelos semánticos de datos bien definidos, como tablas de hechos y dimensiones correctamente modeladas, para interpretar adecuadamente las consultas. Algunas capacidades, como la detección proactiva de anomalías con explicación automática, están aún en fase experimental. Finalmente, la validación de la precisión sigue siendo responsabilidad del analista humano, especialmente en contextos críticos.

Para comprender mejor estas diferencias tecnológicas entre plataformas, en la tabla 1 se muestra una comparativa de capacidades de algunas de las plataformas existentes.

Plataforma	Asistencia en lenguaje natural / LLM	Generación de Métricas y Narrativas	Alertas Inteligentes (Qué hace, cómo funciona)	Nivel de personalización semántica
Power BI Copilot	Alta: GPT-4 vía Azure.	Métricas con DAX asistido + explicaciones por IA.	Básicas: el usuario define reglas manuales (por ejemplo: si ventas bajan de X, enviar alerta). No hay monitoreo automático ni detección contextual.	Media: Limitada al modelo semántico Power BI.
Tableau Pulse	Media: Entrada limitada + Einstein GPT.	Narrativa centrada en alertas + explicación asistida.	Muy avanzadas: detecta automáticamente cambios, eventos clave y anomalías. Envía notificaciones proactivas adaptadas al contexto.	Alta: vía Tableau CRM.
Looker + Gemini	Alta: Gemini Chat + Gemini Pro (Google Cloud).	Dashboards generados con contexto y métricas clave.	Moderadas: Configuración por el usuario para monitorear ciertas métricas. Activa las alertas cuando se superan umbrales definidos.	Alta: con modelos semánticos complejos.

Tabla 1. Comparativa de capacidades entre plataformas. Fuente: elaboración propia basada en documentación oficial de Microsoft (2024), Google Cloud (2024) y Salesforce (2024).

Esta tabla sintetiza las capacidades clave de cada plataforma desde una perspectiva funcional. La entrada en lenguaje natural permite que los usuarios consulten datos o generen visualizaciones escribiendo texto simple, sin requerir conocimientos técnicos. La generación de métricas, como KPI, se refiere a la posibilidad de definir cálculos personalizados automáticamente mediante lenguajes como DAX o LookML asistidos por IA. La narrativa automática es la capacidad del sistema para interpretar los hallazgos de forma visual y explicarlos en lenguaje natural. La integración con LLM indica qué modelo utiliza cada plataforma (por ejemplo, GPT-4 o Gemini) y cómo lo integra en su infraestructura. Las alertas inteligentes evalúan si el sistema puede detectar eventos anómalos y notificar al usuario de forma proactiva. Finalmente, la personalización semántica indica hasta qué punto puede modelarse la lógica del negocio para que la IA comprenda las relaciones entre entidades y

métricas. Esta interpretación técnica permite seleccionar la herramienta más adecuada según el contexto, evaluando no solo la interfaz, sino también la profundidad analítica ofrecida por cada sistema.

Para complementar la comparativa técnica, resulta útil ilustrar cómo estas capacidades se manifiestan en situaciones de uso. A continuación, se presentan ejemplos de Power BI Copilot, Tableau Pulse y Looker con Gemini que permiten visualizar cómo se formulan consultas en lenguaje natural y qué tipo de resultados generan en un entorno de análisis de datos.

- ▶ **Power BI Copilot:** integra modelos de lenguaje (GPT-4 vía Azure) directamente en el servicio de Power BI. Una de sus funciones más destacadas es la capacidad de resumir páginas de informe en lenguaje natural, generando explicaciones comprensibles de los gráficos ya existentes.
- Ejemplo de uso. Un analista abre un informe y solicita en Copilot: «resume la página actual del informe incluyendo las tendencias principales, los valores atípicos y la comparación con el año pasado». Según Microsoft, Copilot analiza los visuales y, trabajando sobre el modelo semántico de Power BI y usando expresiones DAX cuando es necesario, devuelve una narrativa automática (https://learn.microsoft.com/en-us/power-bi/create-reports/copilot-pane-summarize-content?utm_source=chatgpt.com).
- Salida. Un texto generado en la interfaz del servicio, como: «Las ventas crecieron un 12 % en la región norte respecto al año anterior, mientras que la región sur muestra una caída del 8 % en el último trimestre». Esta funcionalidad solo puede lograrse en Power BI porque depende del motor semántico interno y del uso de DAX asistido por Copilot.

- ▶ **Tableau Pulse:** Un sistema de métricas dinámicas y alertas proactivas que complementa a Tableau Cloud. Su foco no está en generar código, sino en monitorizar indicadores clave (KPIs) y notificar al usuario sobre cambios relevantes.
 - Ejemplo de uso: un analista define en Tableau Pulse la métrica «Ventas del mes actual» y la compara automáticamente con «Ventas del mismo mes del año pasado», aplicando filtros de región (por ejemplo, Europa); Tableau Pulse genera la diferencia interanual y, si el cambio supera un umbral, dispara una alerta proactiva en la aplicación o en dispositivos móviles.
https://interworks.com/blog/2024/01/03/tableau-pulse-set-up-and-use-case-demo?utm_source=chatgpt.com
https://www.tableau.com/products/tableau-pulse?utm_source=chatgpt.com
 - Salida. un panel que muestra “Ventas: 1,2 M€, incremento del 15 % respecto al mismo mes del año anterior en Europa”, acompañado de una notificación contextual.
- ▶ **Looker + Gemini:** Looker, en su integración con Gemini Conversational Analytics, permite generar medidas y visualizaciones mediante lenguaje natural. Su rasgo diferencial es la creación de LookML (Looker Modeling Language), que describe relaciones y cálculos en el modelo semántico de datos.
 - Ejemplo de uso. un director financiero formula en el chat de Looker: “Crea una medida en LookML que muestre el total de pedidos de hoy y destácame las tres categorías de producto menos rentables este mes.” Gemini interpreta la solicitud, genera automáticamente el código LookML correspondiente y actualiza el dashboard con la nueva medida (https://cloud.google.com/looker/docs/write-lookml-gemini?utm_source=chatgpt.com&hl=es).
 - Salida: el sistema añade la medida solicitada, devuelve una tabla con las categorías menos rentables y acompaña los resultados con una explicación textual, como: «Los productos de la categoría Accesorios muestran un margen un 20 % inferior al promedio del resto de categorías este mes.».

4.5. Identificación de patrones y correlaciones

Una de las aplicaciones de la IA generativa en el análisis de datos es su capacidad para detectar patrones complejos y relaciones entre variables, incluso en conjuntos de datos de alta dimensionalidad. Los LLM con capacidad de ejecución de código, como GPT-4 en su modo «code interpreter» o Gemini Pro con Python, pueden automatizar el análisis estadístico y devolver hallazgos en lenguaje natural, guiando al analista sin necesidad de escribir código detalladamente.

Esta funcionalidad convierte a los LLMs en asistentes analíticos que ejecutan correlaciones paramétricas y no paramétricas (como Pearson o Spearman), análisis multivariado, PCA, clustering o segmentaciones no supervisadas, entre otros. Además, son capaces de explicar estos hallazgos de forma comprensible, evaluando patrones como, por ejemplo: *los clientes con bajo ingreso y alta interacción con soporte tienen mayor probabilidad de churn o las promociones impactan positivamente solo en clientes con más de seis meses de antigüedad.*

El análisis no se limita a cálculos estadísticos aislados. Un agente de IA bien configurado, usando por ejemplo LangChain o DSPy, puede combinar múltiples técnicas analíticas como si fuera un analista experto. Puede aplicar regresión multivariada para cuantificar el efecto de promociones, realizar un análisis de series temporales para detectar estacionalidad y segmentar a los clientes por perfiles usando clustering. Esto permite análisis exploratorios mediante iteraciones más rápidas sobre hipótesis, elevando la profundidad del análisis.

Además, se puede documentar todo su razonamiento paso a paso: qué pruebas se han ejecutado, qué hallazgos se han extraído y cómo se interpretan. Esto mejora la trazabilidad de los procesos y permite auditar las decisiones generadas. Plataformas como PandasAI, OpenAI Functions y las API de análisis embebido están haciendo posible esta nueva forma de trabajo.

Sin embargo, como se ha mencionado en todos los procesos asistidos por IA, la supervisión humana sigue siendo fundamental para evaluar las metodologías usadas, verificar si son las apropiadas, interpretar correctamente los patrones detectados y evitar errores como el sobreajuste o la confusión entre correlación y causalidad. La IA puede detectar regularidades, pero corresponde al analista validar su relevancia para el negocio, eliminar efectos espurios y decidir qué acciones tomar.

Este equilibrio entre automatización y juicio experto define el concepto de analista aumentado. Al delegar las tareas más tediosas a la IA, el profesional de datos puede centrarse en formular mejores preguntas, afinar hipótesis y traducir resultados en decisiones estratégicas.

A continuación se presenta un ejemplo que busca ilustrar cómo automatizar un análisis de búsqueda de patrones y relaciones usando un LLM. Este ejemplo emplea el dataset público penguins (de Seaborn), que contiene datos morfológicos de pingüinos de distintas especies.

```
# !pip install --upgrade openai
import openai
import pandas as pd
import seaborn as sns
import os

# Configurar la clave API
os.environ["OPENAI_API_KEY"] = "sk-xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx"
openai.api_key = os.environ["OPENAI_API_KEY"]

# Cargar y mostrar una muestra del dataset
df = sns.load_dataset("penguins").dropna()

# Crear el prompt
prompt = f"""
Eres un analista de datos experto. A continuación, tienes una muestra de un dataset sobre pingüinos.
Tu tarea es generar un resumen de los patrones más importantes observables entre las variables
numéricas (como masa corporal, largo y profundidad del pico, longitud de la aleta), y diferencias
relevantes por especie.

Dataset (muestra):
{df.head(10).to_markdown(index=False)}
```

Responde en lenguaje natural con conclusiones analíticas claras y comprensibles.

"""

```
# Llamada al modelo GPT-4
response = openai.ChatCompletion.create(
    model="gpt-4",
    messages=[{"role": "user", "content": prompt}],
    temperature=0.3
)

# Mostrar el resultado de solo la parte que ha escrito el modelo (sin metadatos, índices, etc.)
print(response["choices"][0]["message"]["content"])
```

El resultado esperado podría ser:

«En esta muestra del *dataset*, se observa que la especie *Gentoo* presenta en promedio mayor masa corporal (entre 5000 y 5200 gramos) y aletas más largas (aproximadamente 220 mm) en comparación con *Adelie*, cuya masa oscila entre 3750 y 3900 gramos y sus aletas son más cortas. Además, hay una relación positiva entre la longitud del pico y el peso del animal. Estas diferencias pueden estar relacionadas con adaptaciones morfológicas específicas por especie y hábitat. »

En resumen, este tipo de análisis es extremadamente valioso en contextos donde los analistas deben procesar con rapidez conjuntos de datos nuevos. Gracias a su integración con herramientas como *notebooks* y *dashboards*, estos modelos pueden ser utilizados como copilotos analíticos. Además, la capacidad de explicar hallazgos en lenguaje natural amplifica su aplicabilidad en ámbitos colaborativos y estratégicos, acercando el análisis estadístico riguroso a todo tipo de usuarios.

Aunque los LLM pueden generar descripciones narrativas detalladas sobre, por ejemplo, correlaciones detectadas en un conjunto de datos, su verdadero valor emerge cuando se combinan con validaciones estadísticas que confirmen la solidez de los patrones observados. A continuación, se muestra un ejemplo en el que el modelo primero propone un patrón entre variables y luego guía el cálculo de correlación con código en Python, asegurando así que el hallazgo no se base

únicamente en intuiciones textuales, sino en evidencia cuantitativa replicable. Este ejemplo busca mostrar cómo un LLM no solo es capaz de proponer hipótesis sobre relaciones entre variables, sino también de generar el código para validarlas. La correlación entre la masa corporal y la longitud de la aleta en el famoso conjunto de datos de pingüinos de Python sirve como caso ilustrativo: una relación intuitiva en biología que, sin embargo, requiere verificación estadística.

Código

```
import seaborn as sns
import openai, os
from scipy.stats import pearsonr

# Cargar dataset
df = sns.load_dataset("penguins").dropna()

# Prompt al LLM
prompt = f"""
Analiza el siguiente dataset de pingüinos y dime si observas alguna relación
entre la masa corporal y la longitud de la aleta. Explica en lenguaje natural.

Muestra de datos:
{df.head(10).to_markdown(index=False)}
"""

openai.api_key = "TU_OPENAI_API_KEY"

response = openai.ChatCompletion.create(
    model="gpt-4",
    messages=[{"role": "user", "content": prompt}],
    temperature=0
)

print("Insight del LLM:\n", response["choices"][0]["message"]["content"])

# Validación estadística sugerida
corr, p_value = pearsonr(df["body_mass_g"], df["flipper_length_mm"])
print(f"\nCorrelación: {corr:.3f}, p-valor: {p_value:.4f}")

Salida esperada:
Insight del LLM: Se observa una relación positiva: a mayor masa corporal, mayor longitud de aleta,
especialmente en especies Gentoo.
Correlación: 0.871, p-valor: 0.0000
```

El LLM propone un patrón y luego lo valida con evidencia estadística, confirmando una correlación fuerte y significativa.

4.6. Integración con notebooks y dashboards

La automatización del análisis no alcanza su verdadero potencial hasta que se integra en los entornos de trabajo donde realmente ocurre la toma de decisiones. En este sentido, la IA generativa redefine tanto el espacio técnico del notebook como el espacio estratégico del dashboard, cerrando el ciclo entre exploración, generación de conocimiento y comunicación de valor.

En los entornos técnicos, como Jupyter o Google Colab, los notebooks han evolucionado de simples cuadernos interactivos a sistemas cognitivos asistidos. De nuevo, herramientas como PandasAI, LangChain o DSPy permiten incorporar modelos LLM directamente en DataFrames, facilitando que el analista no solo consulte sus datos sino que dialogue con ellos. A través de un prompt en lenguaje natural, es posible generar descripciones estadísticas, detectar correlaciones significativas o incluso construir gráficos y pipelines completos sin necesidad de escribir una línea de código. Esto transforma el notebook en un espacio de razonamiento asistido, donde el LLM actúa como copiloto experto y donde cada análisis puede documentarse, trazarse y auditarse. Por ejemplo, el analista podría solicitar: «Por favor, genera un resumen estadístico de las columnas numéricas y detecta posibles outliers».

«Resume las tendencias clave del dataset de churn, detecta variables que impacten en la cancelación de contrato y genera una visualización que muestre la relación entre satisfacción y permanencia».

Con bibliotecas como PandasAI, este comando se traduce automáticamente en código Python, análisis estadístico y salida visual. Todo dentro del flujo del notebook.

Simultáneamente, los *dashboards* modernos están integrando capacidades: plataformas como Power BI Copilot, Looker Studio con Gemini o Tableau Pulse permiten a usuarios de negocio consultar datos en lenguaje natural, generar visualizaciones guiadas por IA y recibir explicaciones automáticas sobre los cambios observados. El dashboard deja de ser un tablero estático para convertirse en un asistente estratégico. No solo muestra lo que ocurre, sino que explica por qué ocurre y propone acciones, activando alertas proactivas basadas en LLM.

Lo que realmente aporta valor es la conexión entre ambos mundos. Un flujo ejemplar podría comenzar en el notebook, donde se realiza el análisis exploratorio asistido, se enriquecen los datos mediante agentes LLM y se generan visualizaciones clave. Estas salidas pueden luego publicarse directamente en un dashboard dinámico, donde los usuarios finales interactúan con los *insights* en lenguaje natural, formulan nuevas preguntas y reciben respuestas justificadas con narrativa automatizada. La trazabilidad se conserva, y el tiempo entre el dato y la decisión se reduce.

Como se ha mencionado para las diferentes herramientas de análisis, esta arquitectura integrada no solo mejora la eficiencia técnica, sino que democratiza el análisis. Un equipo comercial puede, desde el dashboard, entender patrones que antes requerían semanas de exploración. Al mismo tiempo, el científico de datos se beneficia de un entorno más ágil y enfocado, donde puede concentrarse en hipótesis de alto impacto, mientras delega tareas repetitivas al agente generativo.

En definitiva, la integración entre notebooks y dashboards a través de IA generativa representa una sinergia entre exploración profunda y comunicación estratégica. Es decir, el valor no reside únicamente en automatizar, sino en cerrar el ciclo de valor entre datos, conocimiento y acción.

4.7. Evaluación de utilidad de los insights

Como se ha visto, la IA generativa puede detectar patrones, describir correlaciones y sintetizar narrativas con gran eficiencia. Sin embargo, el volumen de *insights* generados no garantiza su valor. Un análisis riguroso requiere determinar cuáles hallazgos son verdaderamente útiles, medibles y accionables.

Un insight útil no se define, entonces, por su complejidad técnica ni por su novedad cuantitativa o estadística, sino por su capacidad para generar una acción clara y real, facilitar una decisión informada o descubrir un riesgo u oportunidad previamente ignorado. Evaluar esta utilidad es una tarea que exige tanto criterios técnicos como comprensión del negocio.

Entre las dimensiones de evaluación se encuentran la relevancia para el negocio, contestar preguntas como:

- ▶ ¿Responde el hallazgo a una pregunta estratégica o a un objetivo del análisis?
¿Está alineado con los KPI críticos?
- ▶ Un insight puede ser correcto, pero irrelevante. A su vez, debe tenerse en cuenta la accionabilidad:
- ▶ ¿Permite tomar una acción concreta? ¿Sugiere una intervención, optimización o alerta?
- ▶ Los mejores *insights* conducen a decisiones, no solo a observaciones.

Por supuesto, también se estudia la validez estadística:

- ▶ ¿Está respaldado por una muestra adecuada, una relación basada en validación estadística robusta y un razonamiento lógico?
- ▶ La IA puede detectar relaciones espurias si no se supervisa.

- ▶ También debe tenerse en cuenta la interpretabilidad:
- ▶ ¿Puede explicarse a un usuario no técnico? ¿Se comprende qué variables lo provocan y por qué?

Un hallazgo oscuro o mal comunicado pierde valor, y por último, pero no menos importante, la consistencia y reproducibilidad:

¿Se mantiene al aplicar el modelo a nuevos datos? ¿Puede replicarse el análisis?

Esto evita que las decisiones se basen en ruido.

Por ejemplo, supongamos que el modelo generativo propone el siguiente hallazgo:

«Los clientes menores de 25 años con más de 3 reclamaciones en el último semestre tienen una probabilidad 1,8 veces mayor de abandonar el servicio, especialmente si su última interacción tiene un tono negativo.»

Un analista experto debe validarlo con criterios, entre otros.

¿Esta información es nueva y no conocida por el equipo comercial? ¿Se puede segmentar y actuar sobre ese grupo de clientes? ¿Es consistente en los últimos tres meses o es un patrón puntual? ¿Está respaldado por datos reales o es una inferencia dudosa del modelo de lenguaje?

Evaluar *insights* generados por IA es tanto un reto técnico como conceptual. Ambos son necesarios. Exige métricas cuantitativas, rigor estadístico y alineación con objetivos de negocio. Reiteramos: un sistema automatizado puede generar señales, pero la decisión de actuar sobre ellas sigue siendo una competencia analítica humana y estratégica.

Como hemos estudiado, la utilidad de un insight generado por IA depende de que pueda traducirse en acciones verificables. Los LLMs no solo formulan hipótesis, sino que también pueden sugerir el código necesario para comprobarlas empíricamente

en un dataset. De este modo, el analista dispone de un ciclo completo: generación de un hallazgo, validación con datos y confirmación de su relevancia práctica. El siguiente ejemplo ilustra cómo un modelo propone un patrón de churn y, simultáneamente, guía el análisis para confirmar si este representa un riesgo real en la muestra de clientes.

El churn o abandono de clientes es uno de los problemas más críticos en sectores como telecomunicaciones, banca o seguros. Detectar de forma temprana grupos con alta propensión al abandono permite diseñar planes de retención focalizados. En este caso, el LLM sugiere que los clientes jóvenes con múltiples reclamaciones son más proclives a cancelar el servicio, y el análisis confirma que presentan un riesgo mayor.

Código:

```
import pandas as pd
import numpy as np
import openai, os
np.random.seed(42)
# Dataset simulado
df = pd.DataFrame({
    "edad": np.random.randint(18, 50, 500),
    "reclamaciones": np.random.poisson(2, 500),
    "churn": np.random.binomial(1, 0.3, 500)
})
# Prompt al LLM
prompt = """
Dado un dataset con variables 'edad', 'reclamaciones' y 'churn',
genera el código en Python para calcular la tasa de churn de los clientes menores de 25 años con
más de 3 reclamaciones,
y compárala con el resto. Devuelve también la razón de riesgo.
"""
openai.api_key = "TU_OPENAI_API_KEY"
response = openai.ChatCompletion.create(
    model="gpt-4",
    messages=[{"role": "user", "content": prompt}],
    temperature=0
)
print("Código sugerido por el LLM:\n", response["choices"][0]["message"]["content"])
```

Ejemplo de código sugerido por el LLM:

```
grupo_objetivo = df[(df["edad"] < 25) & (df["reclamaciones"] > 3)]
grupo_control = df[~((df["edad"] < 25) & (df["reclamaciones"] > 3))]
tasa_objetivo = grupo_objetivo["churn"].mean()
tasa_control = grupo_control["churn"].mean()
razon = tasa_objetivo / tasa_control
print(f"Tasa churn grupo objetivo: {tasa_objetivo:.2f}")
print(f"Tasa churn grupo control: {tasa_control:.2f}")
print(f"Razón de riesgo: {razon:.2f}")
```

Posible salida esperada:

Tasa churn grupo objetivo: 0.47

Tasa churn grupo control: 0.27

Razón de riesgo: 1.74

El LLM formula el insight sugiere el código de validación y confirma con datos que el grupo identificado presenta un riesgo aproximadamente 1,7 veces mayor de deserción. Este flujo muestra cómo un insight generado por IA puede convertirse en un criterio operativo de negocio, cerrando la brecha entre hallazgo automatizado y acción estratégica.

4.8. Exploración práctica: caso de análisis automatizado con IA generativa sobre datos de pingüinos

En esta sección buscamos consolidar algunos de los aprendizajes de este tema mediante un caso práctico. Utilizaremos el conocido conjunto de datos de pingüinos de Palmer Station (Antártida), que contiene variables morfométricas, la especie, el sexo y la ubicación de diferentes ejemplares.

Dataset utilizado

El conjunto de datos utilizado proviene de la biblioteca Seaborn y puede cargarse directamente en Python:

Objetivo

Demostramos cómo la IA generativa puede automatizar desde el análisis hasta la generación de insights con valor de negocio.

```
Import seaborn as sns
import pandas as pd
import openai
import matplotlib.pyplot as plt

# Cargar dataset
penguins = sns.load_dataset("penguins")
penguins.dropna(inplace=True) # Eliminar filas con valores nulos
```

Una muestra de los datos: una muestra de los datos.

```
Print(penguins.head())
```

Resultado:

```
Species    island    bill_length_mm    bill_depth_mm    flipper_length_mm  
body_mass_g sex
```

```
0 Adelie Torgersen 39.1 18.7 181 3750 Male
```

```
1 Adelie Torgersen 39.5 17.4 186 3800 Female
```

```
2 Adelie Torgersen 40.3 18.0 195 3250 Female
```

```
3 Adelie Torgersen 36.7 19.3 193 3450 Male
```

```
4 Adelie Torgersen 39.3 20.6 190 3650 Male
```

Usamos un modelo LLM (GPT-4) para extraer patrones de forma automática.

```
Openai.api_key = "TU_OPENAI_API_KEY"  
prompt = f"""
```

Eres un analista de datos experto. A continuación encontrarás una muestra de datos sobre pingüinos.

Tu tarea es generar un resumen de los patrones más importantes que se observan entre las variables numéricas.

(Como masa corporal, longitud y profundidad del pico, longitud de la aleta), y diferencias relevantes por especie.

Dataset (muestra):

```
{penguins.head(10).to_markdown(index=False)}
```

Responde en lenguaje natural con conclusiones analíticas claras y comprensibles.

```
"""
Response = openai.ChatCompletion.create(
    model="gpt-4",
    messages=[{"role": "user", "content": prompt}],
    temperature=0.3
)
print(response["choices"][0]["message"]["content"])
```

Ejemplo de salida esperada:

«Las especies Gentoo presentan mayor masa corporal promedio y longitud de aleta. Adelie muestra menor longitud del pico, pero mayor profundidad relativa. Las diferencias morfométricas permiten diferenciar fácilmente entre especies.»

Análisis exploratorio automatizado (alternativo). Usamos bibliotecas como Sweetviz, ydata-profiling (antes pandas-profiling) para generar análisis automatizados.

```
From ydata_profiling import ProfileReport

profile = ProfileReport(penguins, title="Informe EDA Pingüinos")
profile.to_file("eda_pingüinos.html")
```

El informe generado incluye distribuciones, correlaciones, análisis de valores atípicos y advertencias sobre la calidad de los datos. Esto sustituye horas de trabajo manual en la exploración inicial.

Visualización automatizada con lenguaje natural

Utilizando LLM conectados a bibliotecas visuales:

```
Import seaborn as sns

sns.set(style="whitegrid")
```

Ejemplo de visualización automática sugerida por LLM

```
Sns.boxplot(data=penguins, x="species", y="body_mass_g")  
plt.title("Distribución de masa corporal por especie")  
plt.show()
```

Esta visualización junto con su narrativa generada por IA ayuda a interpretar visualmente las diferencias morfológicas entre especies.

Identificación de patrones y correlaciones

El LLM puede sugerir pruebas estadísticas e interpretarlas, por ejemplo, puede recomendar una prueba adecuada y explicar sus resultados.

```
Import scipy.stats as stats
```

```
adelie = penguins[penguins["species"] == "Adelie"]["body_mass_g"]  
gentoo = penguins[penguins["species"] == "Gentoo"]["body_mass_g"]
```

```
stat, p = stats.ttest_ind(adelie, gentoo)  
print(f"P-valor entre Adelie y Gentoo (masa corporal): {p:.4f}")
```

Si $p < 0,05$, se concluye que hay diferencia estadísticamente significativa en la masa corporal.

El agente de IA puede combinar esto con segmentación automática, análisis de clústeres (k-means) basados en la morfología y análisis de componentes principales (PCA) para su visualización.

Evaluación de utilidad de los insights

La utilidad de los insights generados se evalúa en términos de novedad, aplicabilidad y consistencia. Un marco de validación técnica puede considerar la significancia estadística mediante análisis de valores p derivados de pruebas de hipótesis, ANOVA y correlaciones; la relevancia práctica, con respuestas a preguntas como: ¿aporta valor a una hipótesis

de negocio?; la evaluación de la persistencia temporal: ¿se mantiene el patrón en diferentes muestras?; y la trazabilidad: ¿puede replicarse el análisis? ¿Está documentado?

Ejemplo:

«El hallazgo de que Gentoo tiene mayor masa corporal es consistente, replicable y alineado con literatura biológica, por lo que se considera un insight válido.»


Conclusión

Este caso práctico ilustra cómo la automatización del análisis de datos mediante IA generativa permite transformar flujos en procesos reproducibles y orientados a la toma de decisiones. Desde la exploración inicial hasta la generación de visualizaciones y la evaluación de patrones estadísticamente significativos, cada fase —respaldada por herramientas y modelos— responde al lenguaje natural. En un contexto práctico, este enfoque permite, por ejemplo, que un equipo de análisis ambiental genere informes comparativos de especies o que un equipo de ciencia de datos en una empresa escale la producción de reportes descriptivos sin intervención manual. La automatización basada en LLM acelera el ciclo de descubrimiento de conocimiento, libera tiempo para tareas estratégicas y mejora la trazabilidad. Además, al integrar técnicas como la validación estadística, la generación de texto explicativo y la detección automatizada de patrones, este enfoque constituye una base para modelos analíticos más complejos.

Durante la elaboración del tema se empleó un modelo de IA generativa como herramienta de apoyo para optimizar la redacción y precisar conceptos técnicos. Su uso se llevó a cabo con responsabilidad y criterio académico mediante múltiples

iteraciones de consulta, análisis y reformulación que, solo con la debida pericia, permitieron ajustar las respuestas con rigor y precisión al contexto específico del contenido desarrollado (OpenAI, 2025). Este uso complementario no sustituyó la consulta de fuentes académicas ni el ejercicio intelectual de construcción, sino que buscó reforzar la calidad y claridad en el marco de una práctica académica transparente y ética.

En el vídeo, *Generación automática de resultados y dashboards con herramientas de IA generativa*, veremos la creación de un flujo completo donde un modelo de IA generativa interpreta los datos y genera conclusiones que se visualizan automáticamente. Se conecta la generación textual con *dashboards*.



Accede al vídeo:

<https://unir.cloud.panopto.eu/Panopto/Pages/Embed.aspx?id=077c685a-1b6e-4da1-b0e5-b37e010f0790>

4.9. Referencias bibliográficas

Google Cloud (2024). Gemini en Looker.
<https://cloud.google.com/gemini/docs/looker/overview?hl=es>

Microsoft (2025). *Overview of Copilot for Power BI*. <https://learn.microsoft.com/en-us/power-bi/create-reports/copilot-introduction>

Página de ChatGPT (<https://chat.openai.com/>)

Salesforce. (2025). *Tableau Pulse*.
<https://www.salesforce.com/es/analytics/tableau/pulse/>

Una propuesta de marco novedoso para generar insights automatizados

Pérez, A. S., Boukhary, A., Papotti, P., Lozano, L. C., y Elwood, A. (2025). An LLM-Based Approach for Insight Generation in Data Analysis. *Proceedings of the 2025 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 1, 562–582. Association for Computational Linguistics. <https://doi.org/10.18653/v1/2025.naacl-long.24>

El artículo presenta un marco novedoso para generar *insights* automatizados y accionables directamente desde una base de datos estructurada usando grandes modelos de lenguaje. El sistema opera en tres fases: primero genera hipótesis de interés en lenguaje natural; luego las traduce en consultas SQL con un agente que ejecuta directamente sobre la base; por último, utiliza un módulo de resumen para transformar los resultados en explicaciones textuales claras.

Manual de Instrucciones de los agentes analíticos

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., y Cao, Y. (2023). React: Synergizing reasoning and acting in language models. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/2210.03629>

Se propone un manual de instrucciones de los agentes analíticos. El *paper* explica el *framework* ReAct (Reason + Act), que es la técnica que permite a un LLM no solo generar texto, sino interactuar con herramientas externas (como un intérprete de Python). Detalla cómo el modelo intercala pasos de razonamiento (pensar qué hacer a continuación) con acciones (ejecutar código), que es exactamente el proceso que se describe en las secciones de análisis y correlación automatizados.