

Técnicas de Aprendizaje Automático

UNIR · Evaluación Final

TEMA 2

Análisis Descriptivo y Exploratorio de Datos (EDA)

Variables · Histogramas · Dispersión · Outliers · Correlación · Covarianza · Python

1. Tipos de Variables

Una variable es una característica observable susceptible de tomar diferentes valores. La clasificación del tipo de variable determina qué operaciones estadísticas y qué codificación se puede aplicar antes de entrenar un modelo.

Tipo	Subtipo	Definición	Ejemplo
Cualitativa	Nominal	Sin orden entre categorías	País, color, género
Cualitativa	Ordinal	Con orden significativo	Nivel dolor, calificación (excelente → malo)
Cuantitativa	Discreta	Valores enteros contables	N.º de hijos, n.º de materias
Cuantitativa	Continua	Infinitos valores en un intervalo	Peso, estatura, promedio de notas

■ **Clave para ML:** Las variables nominales NO deben codificarse como 1,2,3 porque el modelo interpretaría una jerarquía falsa. Se usa **One-Hot Encoding** — una columna binaria por categoría. Las ordinales sí admiten codificación numérica ordenada.

2. Análisis Exploratorio de Datos (EDA)

El EDA es el paso previo obligatorio antes de entrenar cualquier modelo. Combina estadística descriptiva (resumir) con estadística exploratoria (visualizar y transformar) para entender la estructura, distribución y relaciones entre variables.

Herramienta	Qué muestra	Cuándo usarla
Histograma	Distribución de frecuencias de una variable continua agrupada en bins	Entender la forma de la distribución (simetría, sesgo, outliers)
Diagrama de caja (boxplot)	Q1, mediana, Q3, bigotes y outliers de una variable	Detectar valores atípicos y comparar distribuciones entre grupos
Diagrama de dispersión	Relación entre dos variables numéricas	Identificar correlación, tendencia y outliers bivariados
SPLOM	Matriz de diagramas de dispersión para todas las parejas de variables	Explorar relaciones múltiples simultáneamente en datasets con muchas variables
Matriz de correlación	Coefficiente de Pearson entre todos los pares de variables	Seleccionar features y detectar multicolinealidad antes de modelar

3. Histograma y Tipos de Distribución

El histograma divide los datos en intervalos (bins) y representa la frecuencia de cada uno mediante barras adyacentes. Eje X = valores de la variable; Eje Y = frecuencia absoluta o relativa.

Tipo de distribución	Forma	Característica clave	Ejemplo real
Simétrica (normal/gaussiana)	Campana centrada	Media = Mediana = Moda. Cola igual a ambos lados.	Estatura de personas adultas
Asimétrica positiva (sesgo derecha)	Cola larga a la derecha	Media > Mediana. Masa de datos a la izquierda (valores bajos).	Salarios, precios de casas, ingresos
Asimétrica negativa (sesgo izquierda)	Cola larga a la izquierda	Media < Mediana. Masa de datos a la derecha (valores altos).	Notas de un examen muy fácil
Uniforme	Barras de altura similar	Los valores se distribuyen de forma pareja en todo el rango.	Lanzamiento de un dado justo

■ **Importante para ML:** El sesgo afecta la media, haciéndola poco representativa. Se aplican transformaciones como **logaritmo** para reducir el sesgo y mejorar el rendimiento de los algoritmos. El tipo de distribución también indica qué medidas de tendencia central usar.

4. Medidas de Dispersión

Las medidas de dispersión cuantifican qué tan alejados están los datos de su centro. Dos distribuciones pueden tener la misma media y mediana pero dispersiones completamente distintas.

Medida	Fórmula	Ventaja	Limitación
Rango	Máx – Mín	Simple y rápido	Muy sensible a outliers
RIC (Rango Intercuartílico)	Q3 – Q1	Robusto ante outliers. Captura el 50% central.	Ignora el 25% superior e inferior

Varianza muestral (s^2)	$\Sigma(x_i - \bar{x})^2 / (n-1)$	Penaliza desviaciones grandes (al cuadrado)	Unidades cuadradas, difícil de interpretar
Desviación estándar (s)	Raíz cuadrada de s^2	Mismas unidades que la variable original	Sensible a outliers como la varianza

■ **Corrección de Bessel:** La varianza muestral divide entre $(n-1)$ y no entre n porque al trabajar con una muestra, la estimación tiende a subestimar la varianza real. El $n-1$ corrige ese sesgo. En población se usa N .

Cuartiles

Cuartil	Percentil	Significado
Q1 (primer cuartil)	25%	El 25% de los datos está por debajo. El 75% por encima.
Q2 (segundo cuartil)	50%	Es la mediana. Divide los datos en dos mitades iguales.
Q3 (tercer cuartil)	75%	El 75% de los datos está por debajo. El 25% por encima.
RIC	$Q3 - Q1$	Rango del 50% central de los datos. Base del boxplot.

5. Detección de Outliers — Diagrama de Caja

Un valor atípico (outlier) es una observación numéricamente distante del resto. Puede indicar un error de medición o un caso extremo legítimo. Su presencia distorsiona la media y la varianza.

Regla de Tukey (1977) — la más usada en boxplot:

Límite inferior: $Q1 - 1.5 \times RIC$

Límite superior: $Q3 + 1.5 \times RIC$

Todo valor fuera de estos límites se grafica como punto individual (outlier).

Elemento del boxplot	Qué representa
Línea central de la caja	Mediana (Q2) — el valor que divide los datos en dos mitades iguales
Borde izquierdo de la caja	Q1 — percentil 25
Borde derecho de la caja	Q3 — percentil 75
Amplitud de la caja	$RIC = Q3 - Q1$ — contiene el 50% central de los datos
Bigotes	Se extienden hasta el último valor dentro de $Q1 - 1.5 \times RIC$ y $Q3 + 1.5 \times RIC$
Puntos individuales	Outliers — valores fuera de los límites de los bigotes

■ **¿Por qué RIC y no desviación estándar para detectar outliers?** Porque los propios outliers distorsionan la media y la desviación estándar, haciendo que el criterio sea inconsistente. El RIC (basado en Q1 y Q3) es robusto — los outliers no lo afectan. El método de Z-score (n desviaciones estándar de la media) también existe pero es menos robusto.

6. Correlación entre Variables y Coeficiente de Pearson

La correlación mide el grado de variación conjunta entre dos variables y evalúa si existe una tendencia lineal entre ellas.

Tipo	Valor de P	Interpretación
Positiva perfecta	$P = 1$	Cuando X sube, Y sube proporcionalmente. Relación lineal directa perfecta.
Positiva fuerte	$0.7 < P < 1$	Tendencia positiva clara pero con dispersión.
Positiva débil	$0 < P < 0.7$	Ligera tendencia positiva, mucha dispersión.
Nula	$P \approx 0$	No existe relación lineal (puede haber relación no lineal).
Negativa débil	$-0.7 < P < 0$	Ligera tendencia negativa, mucha dispersión.
Negativa fuerte	$-1 < P < -0.7$	Tendencia negativa clara.
Negativa perfecta	$P = -1$	Cuando X sube, Y baja proporcionalmente. Relación lineal inversa perfecta.

Fórmula del Coeficiente de Pearson:

$$P = \text{Cov}(X,Y) / (S_x \times S_y)$$

Donde $\text{Cov}(X,Y)$ es la covarianza entre X e Y, S_x es la desviación estándar de X, y S_y es la desviación estándar de Y.

■ **Tres reglas de oro para el examen:** 1. Correlación NO implica causalidad (el helado y los ahogamientos correlacionan, pero el helado no causa ahogamientos — ambos aumentan en verano). 2. Pearson = 0 NO implica independencia (puede existir una relación no lineal perfecta con $P=0$). 3. Pearson solo mide relaciones LINEALES y solo aplica a variables cuantitativas continuas.

En Python:

`iris.corr()` → matriz de correlación de todas las variables

`corr_mat.loc["petal_length", "sepal_width"]` → correlación entre dos variables específicas

7. Covarianza y Matriz de Covarianza

Condición	Tipo de relación lineal
$\text{Cov}(X,Y) = 0$	Relación lineal inexistente entre X e Y
$\text{Cov}(X,Y) > 0$	Relación lineal positiva (directa) — cuando X sube, Y tiende a subir
$\text{Cov}(X,Y) < 0$	Relación lineal negativa (inversa) — cuando X sube, Y tiende a bajar

La **matriz de covarianza** es una matriz cuadrada y simétrica donde:

- La diagonal principal contiene las **varianzas** de cada variable (covarianza de una variable consigo misma).
- Los elementos fuera de la diagonal contienen las **covarianzas** entre pares de variables.
- Es simétrica porque $\text{Cov}(X,Y) = \text{Cov}(Y,X)$, por eso cada covarianza aparece dos veces.

■ **Diferencia clave Covarianza vs Pearson:** La covarianza mide la dirección de la relación pero sus valores dependen de las unidades de medida (no es comparable entre pares de variables). Pearson normaliza la covarianza dividiéndola entre las desviaciones estándar, obteniendo siempre un valor entre -1 y 1 , comparable entre cualquier par de variables.

En Python:

`iris.cov()` → matriz de covarianza completa

`cov_mat.loc["petal_width", "sepal_width"]` → covarianza entre dos variables específicas

8. Preguntas Tipo Examen con Respuestas

? ¿Cuál es la diferencia entre variable nominal y ordinal?

✓ La nominal no tiene orden entre categorías (país, color). La ordinal sí tiene un orden significativo (malo < regular < bueno < excelente) pero las diferencias entre categorías no son necesariamente iguales.

? ¿Por qué no se puede codificar una variable nominal como 1, 2, 3 directamente?

✓ Porque el modelo interpretaría una jerarquía numérica falsa ($3 > 2 > 1$). Se debe usar One-Hot Encoding: una columna binaria por categoría.

? ¿Qué muestra la forma de un histograma?

✓ La distribución de frecuencias de la variable: si es simétrica (normal), asimétrica positiva (cola derecha, sesgo derecha) o asimétrica negativa (cola izquierda, sesgo izquierda). También revela outliers y modas.

? ¿Cómo se identifica un outlier en un boxplot según Tukey?

✓ Todo valor que cae fuera de los límites: Límite inferior = $Q1 - 1.5 \times RIC$; Límite superior = $Q3 + 1.5 \times RIC$. Los valores fuera se grafican como puntos individuales.

? ¿Por qué se prefiere el RIC sobre la desviación estándar para detectar outliers?

✓ Porque el RIC (basado en $Q1$ y $Q3$) es robusto — los outliers no lo distorsionan. En cambio, los outliers sí afectan la media y la desviación estándar, haciendo inconsistente el criterio de Z-score.

? ¿Qué indica la varianza muestral? ¿Por qué divide entre $n-1$?

✓ Indica el promedio de las desviaciones al cuadrado respecto a la media muestral. Divide entre $n-1$ (corrección de Bessel) porque con una muestra la varianza tiende a subestimarse; $n-1$ corrige ese sesgo.

? ¿Qué es el coeficiente de correlación de Pearson y cuál es su rango?

✓ Es un estadístico que mide la fuerza y dirección de la relación lineal entre dos variables cuantitativas continuas. Su rango es $[-1, 1]$: cercano a 1 = positiva fuerte; cercano a -1 = negativa fuerte; cercano a 0 = sin relación lineal.

? ¿Correlación 0 implica independencia?

✓ No. $P=0$ solo indica ausencia de relación LINEAL. Pueden existir relaciones no lineales perfectas (ej: U invertida) con $Pearson = 0$.

? ¿Qué diferencia hay entre covarianza y correlación de Pearson?

✓ La covarianza mide la dirección de la relación lineal pero sus valores dependen de las unidades de medida. Pearson normaliza la covarianza dividiendo entre el producto de las desviaciones estándar, obteniendo un valor entre -1 y 1 , comparable entre cualquier par de variables.

? ¿Qué contiene la diagonal principal de la matriz de covarianza?

✓ Las varianzas de cada variable (la covarianza de una variable consigo misma). Los elementos fuera de la diagonal son las covarianzas entre pares de variables. La matriz es simétrica porque $\text{Cov}(X,Y) = \text{Cov}(Y,X)$.

9. Resumen Rápido — Repaso Final

Concepto	Dato clave para el examen
Variable nominal	Sin orden. Usar One-Hot Encoding en ML.
Variable ordinal	Con orden. Admite codificación numérica ordenada.
Variable discreta	Valores enteros contables.
Variable continua	Infinitos valores en un rango. Para Pearson.
Histograma	Distribución de frecuencias en bins. Revela forma, sesgo y outliers.
Sesgo derecha (positivo)	Cola larga a la derecha. Media > Mediana. Ej: salarios.
Sesgo izquierda (negativo)	Cola larga a la izquierda. Media < Mediana. Ej: notas de examen fácil.
RIC	$Q3 - Q1$. Rango del 50% central. Robusto ante outliers.
Regla de Tukey	Outlier si $< Q1 - 1.5 \times \text{RIC}$ o $> Q3 + 1.5 \times \text{RIC}$.
Varianza muestral s^2	$\sum (x_i - \bar{x})^2 / (n-1)$. Corrección de Bessel.
Desviación estándar s	Raíz cuadrada de la varianza. Mismas unidades que la variable.
Pearson P	$\text{Cov}(X,Y) / (S_x \times S_y)$. Rango $[-1,1]$. Solo variables cuantitativas continuas.
Correlación $\neq$ causalidad	Dos variables pueden correlacionar sin que una cause la otra.
$P = 0 \neq$ independencia	Puede haber relación no lineal perfecta con Pearson = 0.
Matriz covarianza	Cuadrada y simétrica. Diagonal = varianzas. Fuera = covarianzas.
<code>iris.corr()</code>	Calcula matriz de correlación en Python con pandas.
<code>iris.cov()</code>	Calcula matriz de covarianza en Python con pandas.
SPLM	Scatterplot Matrix — todas las parejas de variables en una pantalla.
EDA	Exploratory Data Analysis — paso previo obligatorio antes de modelar.