

Tema 4 — Regresión y Evaluación de Algoritmos de Regresión

Técnicas de Aprendizaje Automático · Maestría en IA — UNIR · Abril 2026

1. Introducción

La **regresión** es una tarea del aprendizaje supervisado cuyo objetivo es predecir un valor numérico continuo (variable respuesta) a partir de un conjunto de variables predictoras (features). Ejemplos: precio de vivienda, consumo energético, puntuación de riesgo.

Notación estándar

- y — variable respuesta (target, outcome, variable dependiente)
- $\mathbf{x} = (x_1, x_2, \dots, x_p)$ — vector de p predictores (features, covariables)
- $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$ — conjunto de entrenamiento con N observaciones
- $\hat{y}_i$ — valor predicho por el modelo para la observación i

La regresión asume que el valor de y se puede descomponer como:

$$y = f(\mathbf{x}) + \epsilon$$

donde $f(\mathbf{x})$ describe la contribución de los predictores al resultado y ϵ es el error irreducible (ruido inherente en los datos).

2. Regresión Lineal

2.1 Regresión Lineal Simple

Cuando existe un único predictor X , el modelo se expresa como una combinación lineal:

$$f(x) = \hat{y} = \beta_0 + \beta_1 X$$

Parámetros del modelo

- β_0 — intercepto (bias): valor esperado de y cuando $X = 0$
- β_1 — coeficiente (pendiente, peso): cambio en y por unidad de cambio en X

Ambos deben *aprenderse* a partir de los datos de entrenamiento.

2.2 Regresión Lineal Múltiple

Con p predictores, el modelo generaliza a:

$$f(\mathbf{x}) = \hat{y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$$

En notación matricial compacta, se construye la **matriz de diseño** X agregando una

columna de unos (para absorber el intercepto β_0):

Observación	Col. bias (=1)	X_1	X_2	...	X_p
1	1	$x_{1,1}$	$x_{1,2}$	...	$x_{1,p}$
2	1	$x_{2,1}$	$x_{2,2}$	...	$x_{2,p}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
N	1	$x_{N,1}$	$x_{N,2}$	...	$x_{N,p}$

El vector de parámetros es $\beta = (\beta_0, \beta_1, \dots, \beta_p)^\top$ y el modelo completo se

escribe $\hat{y} = X\beta$.

El modelo completo se escribe simplemente como $\hat{y} = X\beta$.

¿Por qué la columna de unos? Permite expresar β_0 como un coeficiente más dentro del producto matricial: $\beta_0 \times 1 = \beta_0$. Sin ella, el intercepto no tendría feature que lo multiplique.

2.3 Función de Pérdida Cuadrática

El objetivo es encontrar el vector β que minimiza el error. Primero se define la **función de pérdida cuadrática** (squared loss):

$$L(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - p_i)^2$$

¿Por qué elevar al cuadrado y no sumar directo? Los residuos positivos y negativos se cancelarían. El cuadrado garantiza que todos los errores contribuyan positivamente y penaliza errores grandes más que pequeños.

2.4 Método de Mínimos Cuadrados (OLS)

Minimizando $L(\beta)$ — derivada parcial respecto a cada parámetro igualada a cero — se obtienen las **ecuaciones normales** (solución cerrada):

$$\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Conexión con Tema 2: El numerador de β_1 es la covarianza entre X e Y ; el denominador es la varianza de X . Esto conecta directamente con la correlación de Pearson: $\beta_1 = \rho \cdot \frac{s_y}{s_x}$. Si las variables están estandarizadas ($\sigma = 1$), la pendiente de regresión es igual a la correlación de Pearson.

En notación matricial para el caso múltiple, la solución cerrada es:

$$\beta = (X^\top X)^{-1} X^\top y$$

Limitación: Calcular $(X^\top X)^{-1}$ tiene complejidad $O(p^3)$. Para datasets con muchas features, se vuelve costoso computacionalmente.

2.5 Descenso por Gradiente (Gradient Descent)

Alternativa iterativa a la solución cerrada. Los parámetros se actualizan en cada iteración siguiendo la dirección de máximo descenso del gradiente:

$$\beta_j := \beta_j - \eta \cdot \frac{\partial L}{\partial \beta_j}$$

donde η (eta) es la **tasa de aprendizaje** (learning rate) — controla el tamaño del paso.

Analogía geométrica:

Es como bajar una montaña a ciegas siguiendo la pendiente más pronunciada, paso a paso. Con features no normalizadas, la función de pérdida forma un valle elongado y el algoritmo zigzaguea. Con normalización (StandardScaler), la función de pérdida forma un tazón esférico y la convergencia es directa.

Conexión con Tema 3: La normalización (Z-score con StandardScaler) es condición necesaria para que el Descenso por Gradiente converja eficientemente. Sin ella, features con escalas muy distintas generan gradientes sesgados.

3. Métricas de Evaluación

Todas las métricas se calculan a partir de los **residuos**: $e_i = y_i - \hat{y}_i$. El principio general: valores pequeños de la métrica indican buena capacidad predictiva.

3.1 MSE — Error Cuadrático Medio (Mean Squared Error)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Características:

- Penaliza errores grandes cuadráticamente (no robusto a outliers)
- Unidades: cuadrado de la variable objetivo (difícil de interpretar directamente)
- Función de pérdida natural para optimización (muchos algoritmos minimizan MSE)

3.2 RMSE — Raíz del Error Cuadrático Medio (Root Mean Squared Error)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Características:

- Mismas unidades que la variable objetivo — interpretable como distancia promedio entre predicciones y valores reales
- Penaliza errores grandes cuadráticamente (no robusto a outliers)
- Métrica preferida para comunicar el error en términos comprensibles

3.3 R^2 — Coeficiente de Determinación

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Interpretación:

Proporción de la varianza del resultado que explica el modelo. Un $R^2 = 0.75$

significa que el modelo explica el 75% de la variabilidad de y .

¡Cuidado! R^2 es una medida de *correlación*, no de *precisión*. Un R^2 alto no garantiza que el modelo sea preciso — puede haber patrones sistemáticos de error que R^2 no detecta. Además, R^2 depende de la varianza del conjunto de prueba: el mismo modelo puede dar R^2 distintos en datasets con diferente dispersión.

3.4 MAE — Error Absoluto Medio (Mean Absolute Error)

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Características:

- Robusto ante outliers (no penaliza cuadráticamente)
- Interpretación directa en las mismas unidades que la variable objetivo
- Sobreestimaciones y subestimaciones contribuyen por igual

Cuándo usarlo: Cuando los outliers no deben tener peso desproporcionado en la evaluación.

3.5 RMSLE — Raíz del Logaritmo Cuadrático del Error Medio (Root Mean Squared Logarithmic Error)

$$RMSLE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(y_i + 1) - \log(\hat{y}_i + 1))^2}$$

Cuándo usarlo:

Variables objetivo con escala muy amplia o distribuciones de cola larga (precios de acciones, ventas). Las diferencias *relativas* importan más que las absolutas. Penaliza más la subestimación (underprediction) que la sobreestimación.

3.6 MAPE y MPE — Métricas Porcentuales

$$MAPE = \frac{100}{n} \sum \left| \frac{y - \hat{y}}{y} \right|$$

$$MPE = \frac{100}{n} \sum \left(\frac{y - \hat{y}}{y} \right)$$

MAPE:

Equivalente porcentual de MAE. Intuitivo para comunicar resultados. Limitación:

indefinido cuando $y = 0$; sesgado hacia subestimaciones.

MPE: Sin valor absoluto — los errores positivos y negativos se cancelan. Útil para detectar si el modelo *sistemáticamente sobreestima* (MPE positivo) o *subestima* (MPE negativo).

3.7 Tabla Resumen de Métricas

Acrónimo	Nombre completo	Cálculo residuos	Robusto a outliers	Unidades
MSE	Error cuadrático medio	Cuadrado	No	Cuadradas
RMSE	Raíz del error cuadrático medio	Cuadrado	No	Originales
R ²	Coeficiente de determinación	—	—	Adimensional [0,1]
MAE	Error absoluto medio		Sí	Originales

		Valor absoluto		
RMSLE	Raíz del logaritmo cuadrático del error medio	Cuadrado (log)	Sí	Log
MAPE	Error porcentual absoluto medio	Valor absoluto	Sí	Porcentaje
MPE	Error porcentual medio	N/A	Sí	Porcentaje

4. Equilibrio Sesgo-Varianza (Bias-Variance Tradeoff)

El error de generalización esperado de cualquier modelo supervisado se descompone en tres términos:

$$E_{total} = Sesgo^2 + Varianza + E_{irreducible}$$

Sesgo (Bias)

: Error por suposiciones erróneas en el modelo. Un sesgo alto implica que el modelo no captura la relación real entre features y target — *underfitting* (subajuste). El modelo es demasiado simple.

Varianza

: Error por sensibilidad excesiva a los datos de entrenamiento. Una varianza alta implica que el modelo captura hasta el ruido aleatorio y no generaliza — *overfitting* (sobreajuste). El modelo es demasiado complejo.

Error irreducible

: Ruido inherente en los datos (ϵ). Ningún modelo puede eliminarlo, sin importar su complejidad.

El dilema: Reducir el sesgo (añadir complejidad al modelo) tiende a aumentar la varianza, y viceversa. El objetivo es encontrar el punto de equilibrio óptimo que minimiza el error total en datos no vistos.

Situación	Sesgo	Varianza	Problema	Solución
Underfitting	Alto	Baja	Modelo muy simple	Más features, modelo más complejo
Overfitting	Bajo	Alta	Modelo demasiado ajustado	Regularización, más datos, menos features
Óptimo	Medio	Media	Balance adecuado	Validación cruzada para encontrarlo

5. Visualización de Errores

5.1 Gráfico de Valores Observados vs. Predichos

Diagrama de dispersión 2D donde el eje X son los valores reales y el eje Y los valores predichos. En predicciones perfectas, todos los puntos caerían sobre la diagonal.

- **Puntos sobre la diagonal:** sobreestimaciones (overpredictions)
- **Puntos bajo la diagonal:** subestimaciones (underpredictions)

5.2 Gráfico de Residuos

Residuos en el eje vertical vs. valores predichos en el eje horizontal. Permite detectar patrones que las métricas numéricas no capturan.

Interpretación del gráfico de residuos:

- **Dispersión aleatoria alrededor del eje horizontal:**
el modelo lineal es apropiado
- **Patrón en abanico (varianza creciente):**
heterocedasticidad — el error no es constante a lo largo del rango de predicción
- **Patrón curvo:**
la relación no es lineal — considerar modelo no lineal
- **Puntos extremos aislados:**
outliers influyentes

Lección clave: Nunca evaluar un modelo solo con una métrica numérica. Un

$R^2 = 0.91$ puede coexistir con heterocedasticidad severa. El gráfico de residuos es indispensable.

6. Comandos Python Clave

```
from sklearn.metrics import (
    mean_squared_error,      # MSE
    root_mean_squared_error, # RMSE
    r2_score,                # R2
    mean_absolute_error,     # MAE
    root_mean_squared_log_error # RMSLE
)
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.model_selection import train_test_split

# Pipeline completo: escalado + regresión
pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('regressor', LinearRegression())
])
pipeline.fit(X_train, y_train)
y_pred = pipeline.predict(X_test)
```

```
# Calcular métricas
mse = mean_squared_error(y_test, y_pred)
rmse = root_mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
rmsle = root_mean_squared_log_error(y_test, y_pred)
```

7. Preguntas Tipo Examen

P1.

¿Cuál es la diferencia fundamental entre MSE y MAE en presencia de outliers?

R: MSE eleva los residuos al cuadrado, penalizando desproporcionadamente los errores grandes. MAE usa valor absoluto, siendo robusto ante outliers.

P2.

¿Por qué R^2 no es suficiente para evaluar un modelo de regresión?

R: Porque es una medida de correlación, no de precisión. No detecta patrones sistemáticos de error (ej: heterocedasticidad) y depende de la varianza del conjunto de prueba.

P3.

¿Qué indica un gráfico de residuos con patrón en abanico?

R: Heterocedasticidad — la varianza del error no es constante, crece con el valor predicho. El modelo lineal puede no ser apropiado.

P4.

¿Para qué sirve la columna de unos en la matriz de diseño X ?

R: Para absorber el intercepto β_0 dentro del producto matricial $X\beta$,

permitiendo expresar todo el modelo como una multiplicación matricial compacta.

P5.

Un modelo tiene $R^2=0.91$ en entrenamiento y $R^2=0.45$ en test. ¿Qué problema tiene?

R: Overfitting (alta varianza) — el modelo memorizó los datos de entrenamiento pero no generaliza a datos nuevos.

P6.

¿Cuándo preferirías RMSLE sobre RMSE?

R: Cuando la variable objetivo tiene escala muy amplia o distribución de cola larga, y las diferencias relativas importan más que las absolutas (ej: precios de acciones).

P7.

¿Qué información adicional aporta MPE que no aporta MAPE?

R: MPE detecta el sesgo sistemático del modelo: si MPE es negativo, el modelo subestima sistemáticamente; si es positivo, sobreestima.

8. Conexiones con CS229 Stanford

- Ecuación normal $\beta = (X^\top X)^{-1} X^\top y$: derivada explícitamente en la Lecture 2 de CS229 mediante álgebra matricial y cálculo de gradientes.
- **Descenso por gradiente:** tema central del CS229; la misma lógica iterativa de minimización se aplica a todos los modelos del curso.
- **Bias-variance tradeoff:** principio fundamental que reaparece en regularización (Ridge, Lasso), redes neuronales y ensemble methods.
- **Normalización pre-GD:** el CS229 demuestra formalmente que features en escalas distintas generan superficies de pérdida elípticas que degradan la convergencia.