

Tema 5 — Evaluación de Algoritmos de Clasificación

Guía de Estudio · Técnicas de Aprendizaje Automático · UNIR

Maestría en Inteligencia Artificial · Abril 2026 · Metodología socrática interactiva

1. Clasificación vs. Regresión

Definición — Problema de Clasificación

Dado un conjunto de observaciones de entrenamiento

$(x_1, y_1), \dots, (x_n, y_n)$, el objetivo es aprender una función

$f: \mathcal{X} \rightarrow \mathcal{Y}$ que mapee características de entrada a una etiqueta discreta

$y \in \{c_1, c_2, \dots, c_k\}$. A diferencia de la regresión, el espacio de salida es

categórico, no numérico continuo.

1.1 Tipos de clasificación

Tipo	Descripción	Ejemplo
Clasificación binaria	Dos clases posibles: positiva y negativa	Spam / No spam · Maligno / Benigno
Clasificación multiclase	$n > 2$ clases posibles	Deportes / Política / Entretenimiento
Clasificación multietiqueta	Una instancia pertenece a múltiples clases simultáneamente	Imagen con "playa", "persona" y "perro"

1.2 Dos tipos de output de un clasificador

Todo clasificador produce dos salidas complementarias:

- **Probabilidad de pertenencia:** valor continuo $P(y = c \mid x) \in [0, 1]$ para cada clase. Representa la confianza del modelo.
- **Clase predicha:** etiqueta discreta final obtenida aplicando un *umbral de decisión* (threshold) τ sobre la probabilidad. Por defecto $\tau = 0.5$.

Por qué importa la probabilidad y no solo la etiqueta

Dos instancias con $P(\text{spam}) = 0.99$ y $P(\text{spam}) = 0.51$

reciben la misma etiqueta final, pero el modelo tiene *certeza muy diferente* en cada caso. La probabilidad captura esa incertidumbre; la etiqueta sola la descarta.

2. Matriz de Confusión

Definición — Matriz de Confusión

Tabla de dimensión $n \times n$ (donde n es el número de clases) que organiza las predicciones del modelo frente a los valores reales. Para clasificación binaria es una matriz 2×2 . La diagonal principal contiene los aciertos; las celdas fuera de la diagonal son errores.

2.1 Estructura para clasificación binaria

	Real: Positivo	Real: Negativo
Predice: Positivo	TP — Verdadero Positivo	FP — Falso Positivo

Predice: Negativo	FN — Falso Negativo	TN — Verdadero Negativo
-------------------	---------------------	-------------------------

2.2 Definición de cada celda

- **TP (True Positive — Verdadero Positivo):** instancias positivas correctamente clasificadas como positivas.
- **TN (True Negative — Verdadero Negativo):** instancias negativas correctamente clasificadas como negativas.
- **FP (False Positive — Falso Positivo):** instancias negativas incorrectamente clasificadas como positivas. También llamado *error tipo I*.
- **FN (False Negative — Falso Negativo):** instancias positivas incorrectamente clasificadas como negativas. También llamado *error tipo II*.

Ejemplo — Detección de cáncer

Clase positiva = "tumor maligno". Clase negativa = "benigno".

- **FP:**

paciente sano diagnosticado como enfermo → genera angustia y exámenes adicionales innecesarios. Costoso pero recuperable.

- **FN:**

paciente enfermo diagnosticado como sano → no recibe tratamiento.
Potencialmente fatal.

Los dos errores tienen costos radicalmente distintos. El accuracy global no los distingue.

3. Métricas Derivadas de la Matriz de Confusión

3.1 Accuracy (Tasa de Éxito)

Accuracy

Proporción de predicciones correctas sobre el total de predicciones.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Limitación crítica — El Accuracy con datos desbalanceados

Si el 97% de instancias son de clase negativa, un clasificador que siempre predice "negativo" obtiene Accuracy = 0.97 con TP = 0 y Recall = 0. El modelo es completamente inútil para detectar la clase de interés pero reporta una métrica aparentemente excelente.

3.2 Precision (Precisión) y Recall (Sensibilidad)

Precision — Valor Predictivo Positivo (VPP)

De todas las instancias que el modelo predijo como positivas, ¿cuántas eran realmente positivas?

$$\text{Precision} = \frac{TP}{TP + FP}$$

Un modelo con alta precisión tiene pocas falsas alarmas.

Recall — Sensibilidad — TPR (True Positive Rate)

De todos los positivos reales, ¿cuántos capturó el modelo?

$$\text{Recall} = \frac{TP}{TP + FN}$$

Un modelo con alto recall tiene pocos falsos negativos.

El tradeoff Precision–Recall

Existe una tensión fundamental entre estas dos métricas:

- **Modelo conservador**

(umbral alto): predice positivo solo cuando está muy seguro → alta precisión, bajo recall. Se escapan muchos positivos reales.

- **Modelo agresivo**

(umbral bajo): predice positivo ante cualquier sospecha → alto recall, baja precisión. Genera muchas falsas alarmas.

La elección depende del costo relativo de FP vs. FN en cada contexto.

3.3 F1-Score (F-Measure)

F1-Score

Media armónica entre Precision y Recall. Se usa la media armónica porque penaliza fuertemente cuando cualquiera de los dos componentes es muy bajo.

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

Rango: $[0, 1]$. Valor 1 indica precisión y recall perfectos simultáneamente.

¿Por qué media armónica y no aritmética?

La media aritmética de Precision = 1.0 y Recall = 0.0 daría 0.5, sugiriendo rendimiento moderado. La media armónica daría 0 — reflejo honesto de que el modelo falla completamente en una dimensión crítica. La media armónica no permite que un valor alto "compense" a uno bajo.

3.4 Sensibilidad y Especificidad

Sensibilidad (Sensitivity)

Idéntica al Recall. Proporción de positivos reales correctamente identificados.

$$\text{Sensibilidad} = \frac{TP}{TP + FN}$$

Especificidad (Specificity)

Proporción de negativos reales correctamente identificados.

$$\text{Especificidad} = \frac{TN}{TN + FP}$$

Nota: Especificidad = 1 – FPR (False Positive Rate).

3.5 Tabla resumen de métricas

Métrica	Fórmula	Pregunta que responde	Cuándo priorizar
Accuracy	$\frac{TP + TN}{TP + TN + FP + FN}$	¿Cuántas predigo bien en total?	Clases balanceadas
Precision	$\frac{TP}{TP + FP}$	Cuando digo positivo, ¿acierto?	FP es muy costoso
Recall	$\frac{TP}{TP + FN}$	¿Capturo todos los positivos?	FN es muy costoso
F1-Score		Balance Precision–Recall	Desbalance de clases

	$\frac{2 \cdot TP}{2 \cdot TP + FP + FN}$		
Especificidad	$\frac{TN}{TN + FP}$	¿Identifico bien los negativos?	Junto a Sensibilidad

4. Datasets Desbalanceados

Definición — Dataset Desbalanceado

Conjunto de datos donde la distribución de clases no es uniforme. Una o más clases están significativamente subrepresentadas respecto a otras. Es la norma en problemas reales, no la excepción.

Ejemplo canónico — Predicción de clics

Por cada 99 impresiones sin clic hay 1 con clic. Un clasificador que siempre predice "sin clic" obtiene Accuracy = 99%. Sin embargo, su TP = 0 y Recall = 0. El Accuracy es completamente engañoso.

Métricas recomendadas con datos desbalanceados

- Recall / Sensibilidad para la clase minoritaria
- Precision para la clase minoritaria
- F1-Score por clase
- AUC-ROC (Area Under the ROC Curve)
- Curva Precision-Recall (más informativa que ROC en desbalance severo)

Nunca reportar únicamente Accuracy con datasets desbalanceados.

5. Curva ROC y AUC

Definición — Curva ROC (Receiver Operating Characteristics)

Representación gráfica del rendimiento de un clasificador binario a través de *todos los umbrales de decisión posibles*. Grafica la relación entre TPR (eje Y) y FPR (eje X) para cada

umbral $\tau \in [0, 1]$.

$$TPR = \frac{TP}{TP + FN} \quad (\text{Recall/Sensibilidad})$$

$$FPR = \frac{FP}{FP + TN} = 1 - \text{Especificidad}$$

5.1 Construcción de la curva

Al variar el umbral τ de 1.0 a 0.0 se traza el camino del par (FPR, TPR):

- $\tau = 1.0$: modelo nunca predice positivo $\rightarrow TPR \approx 0$,

$FPR \approx 0$. Punto $(0, 0)$.

- $\tau = 0.0$: modelo siempre predice positivo $\rightarrow TPR = 1$,

$FPR = 1$. Punto $(1, 1)$.

- Cada umbral intermedio genera un punto (FPR_{τ}, TPR_{τ}) .

Efecto del umbral sobre el modelo

Bajar el umbral hace al modelo más "agresivo" o "paranoico": clasifica positivo ante cualquier sospecha mínima, capturando más positivos reales ($\uparrow$ TPR) pero generando más falsas alarmas ($\uparrow$ FPR). Subir el umbral hace al modelo más conservador: pocas falsas alarmas ($\downarrow$ FPR) pero se escapan más positivos reales ($\downarrow$ TPR).

5.2 Interpretación geométrica

Tipo de clasificador	Forma de la curva ROC	AUC
Clasificador perfecto	$(0, 0) \rightarrow (0, 1) \rightarrow (1, 1)$: sube verticalmente, luego horizontal	1.0
Clasificador aleatorio	Diagonal de 45°	0.5
Buen clasificador	Curva hacia la esquina superior izquierda	0.7 – 0.99

5.3 AUC — Area Under the Curve (Área Bajo la Curva)

Definición — AUC

Integral del área bajo la curva ROC:

$$AUC = \int_0^1 TPR(FPR) d(FPR)$$

Rango: $[0.5, 1.0]$ para clasificadores no invertidos.

Interpretación probabilística: el AUC es la probabilidad de que, dado un ejemplo positivo aleatorio y un ejemplo negativo aleatorio, el modelo asigne una puntuación más alta al positivo.

5.4 Escala de referencia AUC

Rango AUC	Interpretación
0.90 – 1.00	Excelente
0.80 – 0.90	Bueno
0.70 – 0.80	Aceptable
0.60 – 0.70	Pobre
0.50 – 0.60	Sin poder predictivo (aleatorio)

Dos modelos con mismo AUC pueden tener curvas ROC distintas

El AUC resume el rendimiento global, pero no captura el comportamiento en zonas específicas de la curva. Dos modelos con $AUC = 0.88$ pueden diferir notablemente en la zona de bajo FPR (alta sensibilidad). Siempre visualizar la curva completa junto al AUC.

ROC en clasificación multiclase

La curva ROC está definida estrictamente para clasificación binaria. Para multiclase se usa la estrategia **One-vs-Rest (OvR)**: se calcula una curva ROC por clase (tratando esa clase como positiva y el resto como negativa) y se promedian los AUC resultantes.

6. Métricas para Clasificación Multiclase

En clasificación multiclase con n clases, la matriz de confusión tiene dimensión

$n \times n$. Todas las métricas binarias se extienden calculándolas clase por clase y promediando.

6.1 Estrategias de promedio

Estrategia	Descripción	Cuándo usar
Macro average	Promedio simple sin ponderar por número de instancias	Todas las clases igualmente importantes
Weighted average	Promedio ponderado por número de instancias de cada clase	Clases desbalanceadas
Micro average	Agrega TP, FP, FN globalmente antes de calcular	Equivale al Accuracy global

7. Implementación en Python con scikit-learn

Comandos clave del módulo sklearn.metrics

```
from sklearn.metrics import (
    confusion_matrix,
    accuracy_score,
    precision_score,
    recall_score,
    f1_score,
    roc_auc_score,
    roc_curve,
    classification_report
)

# Matriz de confusión
cm = confusion_matrix(y_real, y_pred)
tn, fp, fn, tp = confusion_matrix(y_real, y_pred).ravel()

# Métricas individuales
accuracy = accuracy_score(y_real, y_pred)
precision = precision_score(y_real, y_pred)
recall = recall_score(y_real, y_pred)
f1 = f1_score(y_real, y_pred)

# AUC-ROC (requiere probabilidades, no etiquetas)
auc = roc_auc_score(y_real, y_prob)
fpr, tpr, thresholds = roc_curve(y_real, y_prob)

# Reporte completo multiclase
print(classification_report(y_real, y_pred))
```

8. Preguntas Tipo Examen con Respuesta

Pregunta 1

Un clasificador binario reporta $\text{Accuracy} = 99\%$ en un dataset donde el 99% de instancias son de clase negativa. ¿Es un buen modelo?

Respuesta: No necesariamente. Si el modelo siempre predice "negativo", obtiene $\text{Accuracy} = 99\%$ con $\text{TP} = 0$ y $\text{Recall} = 0$. Es completamente inútil para detectar la clase positiva. Hay que revisar Recall , Precision y F1 de la clase positiva antes de concluir nada.

Pregunta 2

En un sistema de detección de fraude bancario, ¿qué es más costoso: un FP o un FN? ¿Qué métrica debe priorizarse?

Respuesta: Un FN es más costoso — una transacción fraudulenta que pasa desapercibida representa una pérdida directa para el banco. Se debe priorizar el **Recall**, garantizando que la mayoría de fraudes reales sean detectados, aunque eso implique generar algunas falsas alarmas (FP) que un analista humano puede revisar.

Pregunta 3

Un clasificador tiene $\text{AUC} = 0.50$. ¿Qué indica esto?

Respuesta: El clasificador no tiene poder predictivo — su rendimiento es equivalente a asignar clases aleatoriamente. Su curva ROC sigue la diagonal de 45° . La probabilidad de que asigne una puntuación más alta a un positivo aleatorio que a un negativo aleatorio es del 50%, igual que lanzar una moneda.

Pregunta 4

¿Por qué el F1-Score usa la media armónica y no la media aritmética?

Respuesta: La media armónica penaliza fuertemente cuando uno de los componentes (Precision o Recall) es muy bajo. Si $\text{Precision} = 1.0$ y $\text{Recall} = 0.0$, la media aritmética daría 0.5 (aparentemente aceptable), mientras que la media armónica da 0 (reflejo honesto del fracaso del modelo en una dimensión crítica).

Pregunta 5

Dos modelos tienen $AUC = 0.88$. El Modelo A alcanza $TPR = 0.90$ con $FPR = 0.15$. El Modelo B alcanza $TPR = 0.90$ con $FPR = 0.35$. Un médico necesita detectar el máximo de tumores malignos. ¿Cuál elegir y por qué?

Respuesta: El Modelo A. Para capturar el 90% de tumores reales ($TPR = 0.90$), genera solo un 15% de falsas alarmas ($FPR = 0.15$), mientras que el Modelo B genera un 35%. Aunque el AUC global es idéntico, la curva del Modelo A es superior en la zona de alta sensibilidad relevante para el médico. Adicionalmente, se debe bajar el umbral de decisión por debajo de 0.5 para maximizar el recall, aceptando conscientemente más FP a cambio de reducir los FN.

9. Mapa Conceptual del Tema

Cadena de conceptos del Tema 5

Datos etiquetados → Clasificador (binario / multiclase)

↓ Predicciones (probabilidad + clase discreta con umbral τ)

↓ Matriz de Confusión → TP, TN, FP, FN

↓ Métricas derivadas: Accuracy · Precision · Recall · F1 · Sensibilidad · Especificidad

↓ Problema de desbalance → Accuracy engañoso → usar métricas por clase

↓ Curva ROC (TPR vs. FPR para todos los umbrales)

↓ AUC = probabilidad de ranking correcto $\in [0.5, 1.0]$

↓ Multiclase: macro / weighted / micro average · One-vs-Rest para ROC

10. Conexión con CS229 Stanford

Puentes con el material de Andrew Ng

- **Regresión logística → clasificación binaria:**

el clasificador más simple que produce probabilidades mediante la función

sigmoide $\sigma(z) = \frac{1}{1 + e^{-z}}$. Base de todo el tema.

- **Umbral de decisión:**

en CS229 se introduce como el punto donde $P(y = 1 | x) \geq \tau$. La

curva ROC es la exploración sistemática de todos los valores de τ .

- **Bias-variance tradeoff (Tema 4):**

reaparece aquí — un modelo con overfitting puede tener AUC artificialmente alto en train y bajo en test.

- **Próximos temas:**

SVM (Máquinas de Vectores Soporte), árboles de decisión, KNN — todos evaluados con estas mismas métricas.