

Guía de Estudio — Tema 5

Detección y Cancelación de Anomalías

Visión Artificial · UNIR · Maestría en Inteligencia Artificial

1. Ubicación en la cadena de procesamiento

Este tema es el tercer eslabón en la preparación de señales para un sistema de visión artificial:

Tema 3: Captura y digitalización (conversión A/D)
↓
Tema 4: Caracterización estadística del ruido
↓
Tema 5: Detección y cancelación de anomalías ← AQUÍ
↓
Temas siguientes: procesamiento sobre señal limpia

Supuesto fundacional del tema: En esta asignatura, las anomalías se asumen como *artefactos ruidosos a eliminar*, no como patrones de interés a analizar. Este supuesto justifica el uso de métodos que destruyen información (como el filtro de mediana): se asume que lo destruido es ruido, no señal útil.

2. Definición de anomalía

Anomalía (outlier)

Patrón inusual que no se ajusta al comportamiento esperado de los datos. Su detección requiere siempre un *modelo implícito de normalidad* contra el que comparar.

Las anomalías en señales e imágenes suelen originarse en:

- **Ruido impulsivo:** picos por campos eléctricos cercanos, descargas.
- **Inestabilidades de captura:** movimiento brusco de cámara, saturación de sensor.

Distinción crítica: el mismo valor puede ser ruido (a eliminar) o información útil (a conservar) según el contexto de la aplicación. Un píxel blanco aislado en una imagen de cartografía es ruido; en astronomía puede ser una estrella real. El algoritmo de detección no puede distinguirlos por sí solo — esa decisión la toma el diseñador del sistema.

3. Tipos de anomalías

Clave para no confundirse: lo que distingue los tres tipos es *contra qué se compara* el valor para decidir si es anómalo.

Tipo	¿Con qué se compara?
Puntual	Con el dataset completo
Contextual	Con la vecindad inmediata
Colectiva	El patrón conjunto, no el valor individual

3.1 Anomalía puntual

Anomalía puntual

Una muestra individual notablemente diferente respecto al resto del conjunto de datos. Se expresa como valores pico que se alejan excesivamente del conjunto de valores observados.

Ejemplo: una transacción de \$50.000 en un historial bancario donde el rango típico es \$20–\$500. Comparada contra todo el historial, es claramente atípica.

3.2 Anomalía contextual

Anomalía contextual

Muestra anómala en un contexto específico (vecindad), aunque su valor absoluto podría ser normal en otro contexto. Requiere distinguir entre dos tipos de atributos:

- **Atributos contextuales:**
definen la posición/vecindad (tiempo en series temporales, coordenadas x,y en imágenes).
- **Atributos de comportamiento:**
el valor de la muestra en sí (amplitud, intensidad de píxel).

Ejemplo: un píxel con intensidad 200 en una zona donde todos los vecinos tienen intensidad 50. El valor 200 existe en otras partes de la imagen (no es puntualmente anómalo), pero es contextualmente anómalo en esa vecindad.

Distinción puntual vs. contextual:

- Si mirás *todo el conjunto* para decidir → buscás anomalías **puntuales**.
- Si mirás solo la *vecindad del punto* → buscás anomalías **contextuales**.

La misma técnica estadística puede detectar ambas: aplicada globalmente detecta puntuales; aplicada con ventana deslizante detecta contextuales.

3.3 Anomalía colectiva

Anomalía colectiva

Colección de instancias de datos relacionadas que es anómala con respecto a todo el conjunto de datos. Las instancias individuales pueden no ser anómalas por sí solas, pero su ocurrencia conjunta como colección es anómala.

Ejemplo: una señal de ECG que permanece plana durante un tiempo inusualmente largo. El valor de la línea base existe normalmente entre picos cardíacos — no es puntualmente anómalo. Lo anómalo es la *duración sostenida* de ese patrón (pausa sinusal).

Característica	Puntual	Contextual	Colectiva
----------------	---------	------------	-----------

Unidad anómala	Una muestra	Una muestra	Un conjunto
Comparación	Todo el dataset	Vecindad local	Patrón conjunto
¿El valor individual es raro?	Sí	No necesariamente	No
¿Requiere noción de contexto?	No	Sí	Sí
Complejidad de detección	Baja	Media	Alta

4. Métodos de identificación de anomalías

La configuración del método depende de las etiquetas disponibles en el dataset:

4.1 Métodos supervisados

Método supervisado

Dispone de un conjunto de entrenamiento con etiquetas de ambas clases (normal / anómala). Se entrena un clasificador tradicional (SVM, ANN) que aprende a separar las dos clases.

Problema del desequilibrio de clases (class imbalance)

Las anomalías son raras por definición ($<1\%$ en fraude bancario, $<0.01\%$ en enfermedades raras). Un clasificador "tonto" que siempre prediga "normal" tendrá accuracy del $99\%+$ siendo completamente inútil. Esto exige:

- Algoritmos robustos: SVM (se enfoca en los support vectors de la frontera), ANN con pesos por clase.
- Métricas apropiadas: F1-score, precision, recall, AUC-ROC — nunca accuracy a secas.
- Técnicas de balanceo: oversampling (SMOTE) o undersampling.

Los árboles de decisión, que maximizan pureza de categorías, *no responden bien* al desequilibrio de clases.

Limitación principal: el supervisado asume que las anomalías son conocidas y etiquetadas. No detecta bien *novedades* (anomalías de tipo nuevo no vistas en entrenamiento). Se usa en fraude bancario y diagnóstico médico, donde los patrones anómalos son conocidos de antemano.

4.2 Métodos semisupervisados

Método semisupervisado (one-class classifier)

El entrenamiento usa *únicamente muestras normales*. El modelo aprende la clase normal, y cualquier desviación del patrón aprendido se detecta como anomalía. También llamados *clasificadores de una sola clase*.

Algoritmos típicos:

- **One-Class SVM:** aprende una hiperesfera que contiene a los datos normales. Puntos fuera de la burbuja → anomalía.
- **Autoencoders:** red neuronal que aprende a comprimir y reconstruir datos normales. Error de reconstrucción alto → anomalía.
- **Modelos de mezcla Gaussiana (GMM):** estiman la densidad de probabilidad de los datos normales.
- **Estimación por funciones núcleo (KDE/Parzen):** ídem, de forma no paramétrica.

Ventaja sobre supervisado: detecta novedades (anomalías nunca vistas). Solo necesita un conjunto limpio de datos normales para entrenar, sin necesidad de ejemplos de anomalías.

4.3 Métodos no supervisados

Método no supervisado

No requiere etiquetas de ningún tipo. Califica los datos según sus propiedades intrínsecas (distancias o densidades). Asume que las anomalías son *minoría* en el dataset. Es el enfoque más flexible y el principal en esta asignatura.

Característica	Supervisado	Semisupervisado	No supervisado
----------------	-------------	-----------------	----------------

Datos de entrenamiento	Normal + anómalo etiquetados	Solo normales	Sin etiquetas
Tipo de salida típica	Etiqueta binaria	Score continuo	Score continuo
Detecta novedades	No bien	Sí	Sí
Problema principal	Desequilibrio de clases	Requiere datos limpios	Anomalías deben ser minoría
Uso en esta asignatura	Poco	Poco	Principal

¿Por qué no supervisado en limpieza de señal? Dos razones:

1. **No hay datos limpios disponibles** para entrenar el modelo de normalidad del semisupervisado.
2. **Costo desproporcionado:** entrenar y desplegar un modelo para limpiar una señal es matar una mosca con un cañón. El filtro de mediana opera directamente sobre la señal sin ningún entrenamiento previo.

5. Eliminación de anomalías: filtro de mediana

Filtro de mediana

Operación punto a punto con ventana deslizante de longitud N (impar). Para cada punto, reemplaza su valor por la *mediana* de los N valores de la ventana centrada en él. El filtro no genera valores nuevos: **selecciona como salida uno de los valores entrantes.**

5.1 Por qué mediana y no promedio

Dado un pico anómalo, comparemos ambos filtros sobre la ventana $[3, 12, 1]$:

Mediana vs. Promedio sobre $[3, 12, 1]$

Ordenada: $[1, 3, 12]$

Mediana = 3 → anomalía **eliminada**

Promedio = $\frac{3 + 12 + 1}{3} = 5.33$ → anomalía **suavizada pero persiste**

Principio de robustez de la mediana

La mediana es **robusta a valores extremos (outliers)** porque solo importa el *orden*, no la magnitud. Un valor extremo siempre queda relegado a los extremos del ordenamiento, nunca en el centro. El promedio *no es robusto*: cada valor pesa proporcional a su magnitud, por lo que los extremos lo arrastran.

5.2 Procedimiento numérico paso a paso

Ejemplo: $N=3$ sobre la serie $[2, 1, 3, 4, 5, 2, 3, \underline{12}, 1, 4, 5, 4, 5]$

Punto a filtrar: valor **12** en posición 7.

Ventana centrada: $[3, 12, 1]$

Ordenada: $[1, 3, 12]$

Mediana: **3** → el 12 es reemplazado por 3.

Ejemplo: $N=5$ sobre la misma serie (pregunta 9 del test)

Ventana centrada en posición 7 (2 vecinos a cada lado):

$[2, 3, 12, 1, 4]$

Ordenada: $[1, 2, 3, 4, 12]$

Mediana (posición central = 3ª): **3** → Respuesta: A

Ejemplo: $N=7$ sobre la misma serie (pregunta 10 del test)

Ventana centrada en posición 7 (3 vecinos a cada lado):

[5, 2, 3, 12, 1, 4, 5]

Ordenada: [1, 2, 3, 4, 5, 5, 12]

Mediana (posición central = 4ª): 4 → Respuesta: B

5.3 En imágenes: ruido sal y pimienta

En imágenes, el ruido impulsivo se denomina **ruido sal y pimienta** (*salt & pepper*): píxeles con valor extremo (0 = pimienta, 255 = sal) distribuidos aleatoriamente. La ventana es

$N \times N$ (típicamente 3×3 o 5×5).

Ejemplo: ventana 3×3 sobre un píxel "sal" (valor 255)

Vecindad (ventana 3×3 centrada en el píxel contaminado):

100	105	110
95	255	102
98	103	107

9 valores: [100, 105, 110, 95, 255, 102, 98, 103, 107]

Ordenados: [95, 98, 100, 102, 103, 105, 107, 110, 255]

Mediana (posición 5): **103** → el píxel pasa de 255 a 103.

5.4 Precio del filtro: distorsión

Limitación fundamental del filtro de mediana:

- Se aplica a *todos* los píxeles, no solo a los contaminados.
- Suaviza bordes nítidos (altas frecuencias espaciales).
- Equivale a un **filtro paso-bajo en frecuencia**: atenúa variaciones rápidas.
- A mayor N → más limpieza, pero más distorsión.

Regla crítica — limitación de escala:

El filtro de mediana elimina cualquier estructura cuya extensión espacial sea **menor que la mitad del tamaño de la ventana**.

Con ventana 3×3 (9 píxeles): una estrella de 1 píxel tiene extensión $1 < 4.5$. La mediana de los 9 píxeles es el negro del fondo → la estrella desaparece.

Consecuencia: el filtro no distingue entre ruido impulsivo y detalles finos legítimos de escala menor a $N/2$.

Usarlo cuando...	No usarlo cuando...
El ruido es impulsivo (sal y pimienta, picos aislados)	El ruido es Gaussiano
Se quieren preservar bordes mejor que con promedio	Hay detalles finos legítimos de escala pequeña
Se necesita un método simple sin entrenamiento	El ruido cubre extensiones grandes

6. Eliminación de anomalías: técnicas estadísticas

Principio fundamental

Dada la función de densidad de probabilidad $f(x)$, la medida de anomalía de

una muestra x_1 es la inversa de su probabilidad:

$$\text{score}(x_1) = \frac{1}{f(x_1)}$$

A mayor score $\rightarrow$ menor probabilidad $\rightarrow$ mayor anomalía.

6.1 Dos estrategias de detección

Estrategia 1 — Por score: se fija un umbral T . Si $\frac{1}{f(x_1)} > T \rightarrow$ anomalía.

Equivalentemente, si $f(x_1) < \frac{1}{T} \rightarrow$ anomalía.

Estrategia 2 — Por extremos de la distribución: se determinan los valores x_a y

x_b tales que:

$$P(x \leq x_a) = P(x \geq x_b) = P_{min}$$

Si $x_1 < x_a$ o $x_1 > x_b \rightarrow$ anomalía.

El umbral lo define el usuario. Tanto T en la estrategia 1 como P_{min} en la estrategia 2 son parámetros de diseño, no valores universales. Esto es una limitación honesta de estos métodos: la definición de "anomalía" depende del criterio del diseñador.

6.2 Escala de aplicación

Escala	$f(x)$ calculada sobre...	Detecta...
Global	Todo el dataset	Anomalías puntuales
Local (ventana deslizante)	Vecindad del punto evaluado	Anomalías contextuales

6.3 El problema: $f(x)$ es desconocida → hay que estimarla

En la práctica no se conoce $f(x)$ directamente. Se dispone solo de una muestra finita de datos, y se necesitan técnicas de estimación:

Histograma → Estimación paramétrica → Funciones núcleo (Parzen)
(más simple) (asume Normal) (más flexible, híbrido)

6.4 Método 1 — Histograma

Histograma

Se divide el dominio de la variable en K intervalos (bins) de igual tamaño. La

estimación de $f(x)$ en el bin k es la frecuencia relativa n_k/n ,

donde n_k es el número de muestras en el bin y n el total.

La elección del número de bins es crítica:

K demasiado pequeño	K demasiado grande
Estimación tosca, no captura la distribución real	Bins vacíos, cambios bruscos, inestable

Regla de Freedman-Diaconis (tamaño óptimo de bin)

$$T = \frac{2 \cdot IQR(x)}{\sqrt[3]{n}}$$

Donde:

- $IQR(x)$: rango intercuartil = percentil 75 – percentil 25 (mide dispersión central)

- n : número de muestras

- T : tamaño de cada bin (el número de bins =

$$(x_{max} - x_{min}) / T)$$

Intuición: datos más dispersos (IQR grande) necesitan bins más anchos. Más muestras (n grande) permiten bins más estrechos.

Ejemplo numérico — Regla de Freedman-Diaconis

$n = 1000$ muestras, $IQR = 30$, rango total $[0, 255]$

$$T = \frac{2 \times 30}{\sqrt[3]{1000}} = \frac{60}{10} = 6$$

Tamaño óptimo de bin: **6 unidades**

Número de bins: $255/6 \approx 43$ bins

6.5 Método 2 — Estimación paramétrica

Estimación paramétrica

Se asume que $f(x)$ es una distribución Normal. Los parámetros se estiman directamente de las muestras disponibles:

$$\mu_x = \frac{1}{n} \sum_{i=1}^n x_i \quad \sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2$$

La estrategia de detección más común es la **regla de las k sigmas**:

Intervalo	Prob. de datos normales dentro
	68.3%

$[\mu - \sigma, \mu + \sigma]$	
$[\mu - 2\sigma, \mu + 2\sigma]$	95.4%
$[\mu - 3\sigma, \mu + 3\sigma]$	99.7%

Ejemplo numérico — Regla de 3 sigmas

Señal de temperatura: $\mu = 20^{\circ}\text{C}$, $\sigma = 2^{\circ}\text{C}$

Intervalo normal: $[20 - 6, 20 + 6] = [14^{\circ}\text{C}, 26^{\circ}\text{C}]$

¿Es anómala una lectura de 26°C ?

$26^{\circ}\text{C} = \mu + 3\sigma$ exactamente. Depende del criterio:

- Si la condición es $x > 26$: **no** es anomalía (no supera el límite).
- Si la condición es $x \geq 26$: **sí** es anomalía (iguala el límite).

El PDF define $P(x \geq x_b) = P_{min}$, lo que incluye la igualdad → **sería anomalía.**

¿Es anómala una lectura de 15°C ?

$15^{\circ}\text{C} > 14^{\circ}\text{C} = \mu - 3\sigma$ → está dentro del intervalo → **no es anomalía.**

Limitación fundamental: si la distribución real no es Normal, la estimación falla. Distribuciones bimodales, asimétricas o con colas pesadas no se modelan bien con una única Gaussiana.

6.6 Método 3 — Funciones núcleo (método de Parzen)

Estimación por funciones núcleo — KDE (Kernel Density Estimation)

Procedimiento híbrido entre histograma y estimación paramétrica. Se coloca una función núcleo suave centrada en *cada muestra* del dataset. La estimación de $f(x)$ es el promedio de todas las contribuciones:

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n g(x - x_i, \theta)$$

Donde $g(x, \theta)$ es la función núcleo con parámetros θ .

Con **núcleo Gaussiano** (el más común):

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x - x_i)^2}{2\sigma^2}\right]$$

El único parámetro a elegir es σ^2 , la varianza de cada campana:

σ pequeño	σ grande
Campanas estrechas → $\hat{f}(x)$ con muchos picos	Campanas anchas → $\hat{f}(x)$ muy suavizada

Análogo a bins pequeños en histograma	Análogo a bins grandes en histograma
Riesgo de sobreajuste	Riesgo de subajuste

Regla para σ óptimo (regla de Silverman)

$$\sigma = 1.06 \cdot \sigma_x \cdot n^{-1/5}$$

Donde σ_x es la desviación estándar de los datos y n el número de muestras.

Intuición: con más datos se pueden usar campanas más estrechas (mayor resolución).

Con datos muy dispersos (σ_x grande), las campanas deben ser más anchas para cubrir el dominio.

Relación histograma ↔ Parzen: el histograma es un caso particular del método de Parzen donde las funciones núcleo son *pulsos uniformes rectangulares* de altura 1 centrados en el punto medio de cada bin. Parzen generaliza esto a funciones núcleo suaves (Gaussianas), eliminando las discontinuidades del histograma.

Característica	Histograma	Paramétrico	Parzen
Supuesto sobre $f(x)$	Ninguno	Normal	Ninguno
Estimación continua	No	Sí	Sí
Parámetro a elegir	Tamaño de bin	Ninguno	σ
Robusta si datos no son Normales	Sí	No	Sí
Costo computacional	Bajo	Muy bajo	Alto (escala con n)

7. Dudas y aclaraciones de sesión

Duda 1: ¿Qué pasa si una "anomalía" detectada no es ruido sino información útil?

Este es el problema fundamental de la detección de anomalías: un algoritmo no puede distinguir entre ruido y señal legítima rara. Detecta solo "cosas que no se parecen al patrón aprendido". La decisión sobre qué hacer con ellas la toma el diseñador según el contexto de la aplicación.

Ejemplo: un píxel blanco aislado es ruido en cartografía pero una estrella real en astronomía. El algoritmo lo detecta igual en ambos casos; la decisión de eliminarlo o conservarlo es externa al algoritmo.

Duda 2: ¿Por qué el supervisado no es popular si es el que tiene más información?

Tener etiquetas de ambas clases es una condición muy restrictiva. En la mayoría de las aplicaciones reales, las anomalías no están catalogadas de antemano o pueden presentarse como *novedades* (patrones de anomalía nunca vistos). Además, el desequilibrio de clases introduce sesgos difíciles de corregir en muchos algoritmos estándar.

Duda 3: ¿Por qué el umbral en los métodos estadísticos lo fija el usuario y no hay uno óptimo universal?

Porque la definición de "anomalía" depende del costo relativo de los dos tipos de error:

- **Falso positivo:** marcar como anomalía algo normal (coste: eliminar información útil).
- **Falso negativo:** no detectar una anomalía real (coste: dejar ruido en la señal).

En una imagen médica, un falso negativo puede tener consecuencias graves → umbral más sensible (más estricto). En limpieza de señal de audio, un falso positivo es preferible → umbral más relajado. No hay un valor universal porque el balance óptimo depende de la aplicación.

Duda 4: ¿Por qué la estrella desaparece con el filtro de mediana?

Con una ventana 3×3 (9 píxeles) centrada sobre la estrella (1 píxel blanco): la ventana contiene 8 píxeles negros y 1 blanco. Al ordenar los 9 valores, el blanco queda en la posición 9 (extremo). La mediana es la posición 5 $\rightarrow$ uno de los negros del fondo. La estrella desaparece porque su extensión (1 píxel) es menor que la mitad de la ventana (4.5). Si la estrella ocupara 5 píxeles o más, habría suficientes blancos para dominar el ordenamiento y la mediana sería un valor claro.

Duda 5: En la regla de 3 sigmas, ¿un valor exactamente en el límite es anomalía o no?

Depende de la convención del umbral:

- Condición estricta $x > \mu + 3\sigma$: el límite exacto *no* es anomalía.
- Condición no estricta $x \geq \mu + 3\sigma$: el límite exacto *sí* es anomalía.

El PDF define $P(x \geq x_b) = P_{min}$, incluyendo la igualdad. En la práctica, un valor exactamente en el límite es un caso extremadamente raro e irrelevante; lo importante es entender que *el umbral lo fija el usuario* y que la definición de anomalía depende de esa decisión de diseño.

8. Resumen rápido de fórmulas

Concepto	Fórmula	Parámetros
Score de anomalía	$\text{score}(x_1) = \frac{1}{f(x_1)}$	$f(x)$: función de densidad de probabilidad

Umbral por extremos	$P(x \leq x_a) = P(x \geq x_b) = P_{min}$	P_{min} : prob. mínima, fijada por el usuario
Media (estimación paramétrica)	$\mu_x = \frac{1}{n} \sum_{i=1}^n x_i$	n : número de muestras
Varianza (estimación paramétrica)	$\sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2$	μ_x : media estimada
Bin óptimo (Freedman- Diaconis)	$T = \frac{2 \cdot IQR(x)}{\sqrt[3]{n}}$	IQR : rango intercuartil (p75 – p25)
KDE general (Parzen)	$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n g(x - x_i, \theta)$	g : función núcleo; θ : parámetros
KDE con núcleo Gaussiano	$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x - x_i)^2}{2\sigma^2}\right]$	σ^2 : varianza del núcleo
	$\sigma = 1.06 \cdot \sigma_x \cdot n^{-1/5}$	

σ óptimo para KDE (Silverman)		σ_x : desv. estándar de los datos
---	--	--

9. Claves del test de autoevaluación

Respuestas del test (UNIR)

1. **A**

— Outlier y anomalía se emplean indistintamente.

2. **C**

— Patrón inusual que no se ajusta al comportamiento esperado.

3. **B**

— Muestra individual notablemente diferente respecto al resto.

4. **A**

— Muestra anómala en un contexto específico (pero no de otro modo).

5. **D**

— Colección de instancias relacionadas con comportamiento inusual conjunto.

6. **D**

— Parten de ejemplos etiquetados; habitual en fraude con tarjeta de crédito.

7. **D**

— Flexibles, basados en distancias para detectar muestras anómalas.

8. **C**

— Filtro de mediana: método estándar para ruido impulsivo.

9. **A — 3**

→ ventana N=5: [2, 3, 12, 1, 4] → ordenada [1, 2, 3, 4, 12] → mediana = 3

10. **B — 4**

→ ventana N=7: [5, 2, 3, 12, 1, 4, 5] → ordenada [1, 2, 3, 4, 5, 5, 12] → mediana = 4